

Infron 与 OpenRouter 路由、缓存、成本与流式性能 A/B 实验报告

摘要与结论大纲

关键词: Prompt Caching; A/B Testing; Provider Routing; Cache Affinity; Latency; Throughput; Cost Attribution; deepseek-v4-flash

摘要


本报告以 deepseek/deepseek-v4-flash 为对象, 评估 Infron 与 OpenRouter 在 Prompt Caching 场景下的缓存复用、实际成本、吞吐、端到端时延和流式 TTFT 表现。

核心结论是: Infron 在所有路由模式下缓存命中率占优; Infron 在 3/4 个路由模式下实际成本占优, OpenRouter 在 1/4 个路由模式下占优; OpenRouter 在所有路由模式下吞吐量占优; Infron 在 3/4 个路由模式下端到端 E2E 时延占优, OpenRouter 在 1/4 个路由模式下占优; Infron 在 3/4 个路由模式下流式 TTFT 占优, OpenRouter 在 1/4 个路由模式下占优。

整体看, Infron 的优势主要体现在缓存复用和成本控制, OpenRouter 在部分路由模式下体现出更强的首包或完整响应速度。平台选择不应只看单一指标, 而应按业务目标在成本、缓存稳定性、吞吐和交互时延之间取舍。

图 0: Inference 平台“不可能四角”归一化综合轮廓

四个方向分别代表吞吐量、价格、端到端 E2E 时延和流式 TTFT。所有指标统一转为 0-100 分, 且越外侧越好。



路由模式与

THR 吞吐
PRI 价格
LAT 端到
TTFT 流式

图例筛选

点击图例项可

粗实线表示平台综合轮廓, 半透明细线和点表示各路由模式下的表现。

结论总览：核心指标与路由模式胜出方

基于严格 A/B 配对样本。蓝色代表 Infron，橙色代表 OpenRouter；金色单元格表示该路由模式的目标指标胜出方。

吞吐量 OpenRouter 4/4 胜出 最大优势 10.17%, 越高越好
实际成本 Infron 3/4 胜出 最大优势 3.22%, 越低越好
端到端 E2E 时延 Infron 3/4 胜出 最大优势 1.99%, 越低越好
流式 TTFT Infron 3/4 胜出 最大优势 107.57%, 越低越好
缓存命中率 Infron 4/4 胜出 最大优势 86.83%, 越高越好

路由模式	吞吐目标	成本目标	时延目标	TTFT 目标	缓存结果
吞吐优先 throughput	OpenRouter 优势 66.98%	OpenRouter 优势 34.41%	OpenRouter 优势 27.66%	OpenRouter 优势 32.83%	Infron 优势 2.11%
价格优先 price	OpenRouter 优势 10.17%	Infron 优势 3.22%	Infron 优势 81.49%	Infron 优势 23.89%	Infron 优势 86.83%
端到端时延优先 latency	OpenRouter 优势 4.87%	Infron 优势 81.94%	Infron 优势 1.99%	Infron 优势 107.57%	Infron 优势 71.12%
流式 TTFT 优先 ttft	OpenRouter 优势 3.78%	Infron 优势 104.11%	Infron 优势 1.72%	Infron 优势 90.76%	Infron 优势 76.78%

结论大纲

研究维度	结论	证据位置
控制变量	同一 <code>sort/group/round</code> 下 <code>first/second</code> <code>usage.prompt_tokens</code> 偏差不超过 50 tokens；总 Input Tokens 使用响应 telemetry。	方法与数据质量章节
缓存复用	Infron 在所有路由模式下缓存命中率占优	总体指标与机制解释章节
实际成本	Infron 在 3/4 个路由模式下实际成本占优，OpenRouter 在 1/4 个路由模式下占优	总体指标与 Provider 下钻章节
性能表现	OpenRouter 在所有路由模式下吞吐量占优；Infron 在 3/4 个路由模式下端到端 E2E 时延占优，OpenRouter 在 1/4 个路由模式下占优；Infron 在 3/4 个路由模式下流式 TTFT 占优，OpenRouter 在 1/4 个路由模式下占优	结果可视化与统计检验章节
归因边界	报告只使用响应中可观测的 <code>usage</code> 、 <code>cost</code> 、 <code>TTFT</code> 、 <code>latency</code> 、 <code>provider</code> 字段和 <code>cache tokens</code> 。	Provider/Route 下钻分析章节
业务含义	长上下文、RAG 前缀、Agent 工具说明和高频模板请求应同时关注缓存命中率、成本、首包和端到端时延。	讨论与结论章节

路由模式级结论

路由模式	目标	缓存胜出	成本胜出	吞吐胜出	E2E 时延胜出	TTFT 胜出	解读
吞吐优先	最大化单位时间输出能力	Infron	OpenRouter	OpenRouter	OpenRouter	OpenRouter	OpenRouter 综合占优（4/5 指标）
价格优先	最小化单位请求和单位 token 成本	Infron	Infron	OpenRouter	Infron	Infron	Infron 综合占优（4/5 指标）
端到端时延优先	最小化完整响应等待时间	Infron	Infron	OpenRouter	Infron	Infron	Infron 综合占优（4/5 指标）
流式 TTFT 优先	最小化流式首包响应时间	Infron	Infron	OpenRouter	Infron	Infron	Infron 综合占优（4/5 指标）

1. 引言：背景、研究问题与贡献

LLM 推理平台的真实性能不仅由模型决定，也由 provider 路由、提示词缓存、流式响应、成本归因和 fallback 策略共同决定。本报告把平台视为可观测系统，以 A/B 配对方式评估速度、成本、缓存和首包体验的多目标权衡。

1.1 研究假设

假设	内容	验证指标
H1	重复稳定长前缀请求中，更强的 provider/cache affinity 会提升 Token 级缓存命中率。	第二次请求 cache read tokens、Token 级命中率
H2	更高缓存命中率会降低真实响应成本，但不必然降低 TTFT 或端到端 latency。	实际成本、平均 TTFT、平均 latency/请求
H3	不同 routing sort 会改变 provider 选择，从而形成不同的成本、吞吐和时延 Pareto 前沿。	provider 分布、throughput、latency、cost

1.2 本文贡献

- 使用响应返回的 `usage.prompt_tokens` 作为真实 input token 控制变量，并允许 50 tokens 内的小幅跨平台计数波动。
- 将 prompt caching 评估扩展到成本、吞吐、E2E latency、TTFT、provider 分布、reasoning telemetry 和配对统计检验。
- 所有结论只基于响应可观测 telemetry，不把平台内部私有 routing trace 当作已观测事实。

2. 方法：实验设计、数据集构造与控制变量

2.1 数据集生成方法

数据集名称为 `business_representative`，覆盖 4 种 routing sort、2 个平台、4 个实验组、每组 50 轮。每轮包含 first/second 两次相同 Chat Completions 请求：第一次建立或刷新缓存状态，第二次观测 cache read tokens、TTFT 和端到端响应。

业务模板覆盖稳定长上下文场景，包括 RAG 客服、Agent 工具说明、营销自动化和代码审查等高复用 prompt 结构。

2.2 控制变量方法



控制变量方法：同一 `sort/group/round` 下，两个平台 first/second 两次请求的 `usage.prompt_tokens` 各自偏差必须不超过 50 tokens。总 Input Tokens 使用响应返回的 `usage.prompt_tokens`，不使用本地 tokenizer 估算。

2.3 指标定义

指标	定义	解释方向
调用级命中率	第二次请求 <code>cache_read_tokens > 0</code> 的轮次占比	越高表示越稳定触发缓存读取
Token 级命中率	第二次请求 cache read tokens / 第二次请求 prompt tokens	越高表示输入 token 复用比例越高
实际成本	first + second 两次请求返回 usage/cost 的合计	越低越好
Throughput	响应 completion tokens / 请求 latency seconds	越高越好
E2E latency	每次请求完整响应耗时均值	越低越好

指标	定义	解释方向
TTFT	streaming 下首包/首 token 到达时间均值	越低越好
Reasoning 口径	响应 usage 中的 reasoning token 字段保留为观测变量	用于解释时延、吞吐和成本，不单独作为业务产出

3. 实验环境与数据质量控制

项目	配置
模型	deepseek/deepseek-v4-flash
平台	Infron、OpenRouter
API 协议	/v1/chat/completions
路由模式	吞吐优先、价格优先、端到端时延优先、流式 TTFT 优先
实验组	4
每组轮数	50
Workers	4
请求方式	流式 Chat Completions，采集 TTFT
Reasoning / Thinking 控制	未显式指定 reasoning/thinking 参数：保留模型与平台默认行为
Prompt 长度分层	short ≈1500、medium ≈8000、long ≈32000
剔除记录	202

4. 结果：总体指标与主要发现

路由模式	平台	严格配对轮数	总 Input Tokens	Token 级缓存命中率	实际成本	吞吐量	端到端 E2E 时延	流式 TTFT
吞吐优先	Infron	197	6154552	96.98%	\$0.21394200	3.29 tok/s	3722.44 ms	3433.18 ms
吞吐优先	OpenRouter	197	6154552	94.98%	\$0.15917012	5.49 tok/s	2915.93 ms	2584.72 ms
价格优先	Infron	120	3921304	99.14%	\$0.06149200	2.84 tok/s	4102.95 ms	3797.36 ms
价格优先	OpenRouter	120	3922001	53.07%	\$0.25940535	31.70 tok/s	7446.27 ms	4704.57 ms
端到端时延优先	Infron	183	5857970	99.45%	\$0.19021600	5.41 tok/s	2291.26 ms	2107.77 ms
端到端时延优先	OpenRouter	183	5859024	58.12%	\$0.34608653	31.75 tok/s	6849.25 ms	4375.07 ms
流式 TTFT 优先	Infron	199	6302520	99.44%	\$0.18822900	5.66 tok/s	2179.19 ms	1994.39 ms
流式 TTFT 优先	OpenRouter	199	6303506	56.25%	\$0.38419688	27.04 tok/s	5916.65 ms	3804.41 ms

4.1 尾延迟与显著性检验

尾延迟分位数补充均值无法表达的尾部风险。

路由模式	平台	P50 Latency	P95 Latency	P99 Latency	P50 TTFT	P95 TTFT	P99 TTFT
吞吐优先	Infron	2845.88 ms	5878.11 ms	15987.90 ms	2557.18 ms	5449.01 ms	15863.06 ms
吞吐优先	OpenRouter	2638.24 ms	4483.40 ms	5746.03 ms	2291.13 ms	4088.84 ms	5251.93 ms
价格优先	Infron	3797.05 ms	6444.47 ms	7568.74 ms	3401.46 ms	5876.37 ms	7439.99 ms
价格优先	OpenRouter	6794.70 ms	13898.24 ms	21771.39 ms	4016.20 ms	8534.63 ms	14244.94 ms
端到端时延优先	Infron	1978.76 ms	3561.10 ms	6345.28 ms	1799.16 ms	3316.43 ms	6093.65 ms
端到端时延优先	OpenRouter	6472.77 ms	12783.34 ms	15660.25 ms	3689.42 ms	9073.42 ms	12794.26 ms
流式 TTFT 优先	Infron	1925.44 ms	3366.16 ms	4477.73 ms	1772.84 ms	3137.69 ms	3932.41 ms
流式 TTFT 优先	OpenRouter	5280.31 ms	12143.61 ms	16557.73 ms	3353.78 ms	7869.26 ms	10092.91 ms

均值差使用 bootstrap 95% CI，p-value 使用 paired sign-flip permutation test。

路由模式	指标	均值差	95% CI	p-value	配对数	解释
吞吐优先	Latency: OpenRouter - Infron	-1613.02 ms	-2714.02 ms to -753.26 ms	<0.001	197	正值表示 Infron latency 更低
吞吐优先	TTFT: OpenRouter - Infron	-1696.92 ms	-2773.72 ms to -848.48 ms	<0.001	197	正值表示 Infron TTFT 更低
吞吐优先	Throughput: Infron - OpenRouter	-1.7109 tok/s	-2.0845 tok/s to -1.3430 tok/s	<0.001	197	正值表示 Infron throughput 更高
吞吐优先	Cost: OpenRouter - Infron	\$-0.00027803	\$-0.00039975 to \$-0.00017090	<0.001	197	正值表示 Infron 成本更低
吞吐优先	Token Cache Hit: Infron - OpenRouter	26.16 pp	20.06 pp to 32.47 pp	<0.001	197	正值表示 Infron cache hit 更高
价格优先	Latency: OpenRouter - Infron	6686.63 ms	5635.73 ms to 7870.36 ms	<0.001	120	正值表示 Infron latency 更低
价格优先	TTFT: OpenRouter - Infron	1814.42 ms	1159.70 ms to 2589.61 ms	<0.001	120	正值表示 Infron TTFT 更低

路由模式	指标	均值差	95% CI	p-value	配对数	解释
价格优先	Throughput: Infron - OpenRouter	-26.4952 tok/s	-29.7806 tok/s to -23.1961 tok/s	<0.001	120	正值表示 Infron throughput 更高
价格优先	Cost: OpenRouter - Infron	\$0.00164928	\$0.00132975 to \$0.00200644	<0.001	120	正值表示 Infron 成本更低
价格优先	Token Cache Hit: Infron - OpenRouter	44.09 pp	36.21 pp to 53.34 pp	<0.001	120	正值表示 Infron cache hit 更高
端到端时延优先	Latency: OpenRouter - Infron	9115.98 ms	8374.46 ms to 9873.56 ms	<0.001	183	正值表示 Infron latency 更低
端到端时延优先	TTFT: OpenRouter - Infron	4534.60 ms	4050.87 ms to 5026.07 ms	<0.001	183	正值表示 Infron TTFT 更低
端到端时延优先	Throughput: Infron - OpenRouter	-22.7209 tok/s	-25.5825 tok/s to -20.0899 tok/s	<0.001	183	正值表示 Infron throughput 更高
端到端时延优先	Cost: OpenRouter - Infron	\$0.00085175	\$0.00062479 to \$0.00109968	<0.001	183	正值表示 Infron 成本更低
端到端时延优先	Token Cache Hit: Infron - OpenRouter	48.46 pp	42.02 pp to 54.93 pp	<0.001	183	正值表示 Infron cache hit 更高
流式 TTFT 优先	Latency: OpenRouter - Infron	7474.93 ms	6624.10 ms to 8345.09 ms	<0.001	199	正值表示 Infron latency 更低
流式 TTFT 优先	TTFT: OpenRouter - Infron	3620.04 ms	3100.43 ms to 4205.85 ms	<0.001	199	正值表示 Infron TTFT 更低
流式 TTFT 优先	Throughput: Infron - OpenRouter	-16.1704 tok/s	-18.8238 tok/s to -13.5470 tok/s	<0.001	199	正值表示 Infron throughput 更高
流式 TTFT 优先	Cost: OpenRouter - Infron	\$0.00098476	\$0.00078639 to \$0.00119703	<0.001	199	正值表示 Infron 成本更低
流式 TTFT 优先	Token Cache Hit: Infron - OpenRouter	54.27 pp	47.70 pp to 60.72 pp	<0.001	199	正值表示 Infron cache hit 更高

4.2 Reasoning / Thinking 控制校验

本轮未显式指定 reasoning/thinking 参数，保留模型与平台默认行为；该表记录默认行为下的 reasoning telemetry。

路由模式	平台	Reasoning Tokens	平均 Reasoning Tokens/请求	Reasoning 请求数	平均首 Reasoning Token	平均 TTFT	平均 E2E 时延
吞吐优先	Infron	0	0.0000	0	0.00 ms	3433.18 ms	3722.44 ms
吞吐优先	OpenRouter	6304	16.0000	394	2584.72 ms	2584.72 ms	2915.93 ms
价格优先	Infron	0	0.0000	0	0.00 ms	3797.36 ms	4102.95 ms
价格优先	OpenRouter	53713	223.8042	188	4574.13 ms	4704.57 ms	7446.27 ms
端到端时延优先	Infron	0	0.0000	0	0.00 ms	2107.77 ms	2291.26 ms
端到端时延优先	OpenRouter	75379	205.9536	290	4419.40 ms	4375.07 ms	6849.25 ms
流式 TTFT 优先	Infron	0	0.0000	0	0.00 ms	1994.39 ms	2179.19 ms
流式 TTFT 优先	OpenRouter	60300	151.5075	279	3834.42 ms	3804.41 ms	5916.65 ms

4.3 API 协议兼容性矩阵

本轮 API 协议为 /v1/chat/completions；本表记录两家平台在该协议下的成功响应、usage、成本和缓存 telemetry 覆盖。



API 协议	Endpoint	平台	配对轮数	请求数	成功率	Usage 覆盖	Token Usage 覆盖	成本覆盖	缓存 Telemetry 覆盖	HTTP 状态	主要错误
chat_completions	/v1/chat/completions	Infron	800	1600	98.06%	100.00%	100.00%	100.00%	100.00%	{\"0\":31,\"200\":1569}	26 x [SSL: UNEXPECTED_EOF, EOF occurred in vic (_ssl.c:1000) 3 x [Errno 54] Conr peer
chat_completions	/v1/chat/completions	OpenRouter	800	1600	90.62%	99.93%	99.93%	99.93%	100.00%	{\"0\":150,\"200\":1450}	93 x [Errno 61] Con 51 x [SSL: UNEXPECTED_EOF, EOF occurred in vic (_ssl.c:1000)

5. 结果可视化：按路由模式的核心指标变化

以下图表使用同一份严格配对后的 summary 数据驱动，统一展示路由模式、平台差异、成本、缓存、端到端 E2E 时延、流式 TTFT 和上游 Provider 分布。

5.1 核心指标图表总览

以下图表使用同一份严格配对后的 summary 数据生成，统一展示路由模式、平台差异、成本、缓存、端到端 E2E 时延、流式 TTFT 和上游 Provider 分布。



Infron OpenRouter

图 3-E3：成本-缓存效率平面

横轴为 Token 级缓存命中率，纵轴为总实际成本。




图 3-E4：端到端 E2E 时延与流式 TTFT

实线表示端到端 E2E 时延，虚线表示流式 TTFT。





图 3-E5：上游 Provider 分布

按路由模式展示主要上游路径占比。



模式级下钻图表

横轴表示相对优势百分比：右侧蓝色代表 Infron 优势，左侧橙色代表 OpenRouter 优势。

图 4-E1：Throughput First 路由模式下的核心指标对比

展示五项核心指标的相对优势方向与幅度。




图 4-E2：Price First 路由模式下的核心指标对比

展示五项核心指标的相对优势方向与幅度（右侧 Infron，左侧 OpenRouter）






图 4-E3：Latency First 路由模式下的核心指标对比

展示五项核心指标的相对优势方向与幅度（右侧 Infron，左侧 OpenRouter）





6.1 多 provider 路由与可观测控制面

请求进入统一 API 后，路由策略层根据 throughput、price、latency 或 ttft 目标选择健康上游路径。稳定长前缀请求是否落在相同缓存域，会直接影响第二次请求的 cache read tokens。

6.2 Provider Stick 与 Cache Affinity

Provider stick 是缓存亲和策略，不等于固定锁死 provider。它的目标是在健康和 SLA 约束下减少缓存域碎片化，使重复 prefix 更容易复用已有缓存。

6.3 成本控制路径

机制	对 cache rate 的影响	对成本的影响	本次实验中的可观测信号
Stable prefix 识别	相同前缀更容易命中已有 cache	降低重复 prefill 的边际成本	同一 payload SHA256、第二次请求 cache read tokens
Provider stick / cache affinity	降低跨 provider/cache domain 的缓存碎片	减少重复暖缓存	provider 分布与 Token 级命中率共同变化
健康检查与 fallback	保护可用性，必要时牺牲部分缓存收益	降低失败成本	HTTP 状态、provider 分布和尾延迟变化
成本感知 routing	在健康约束下偏向低成本路径	降低总成本和每轮成本	实际成本、cost breakdown 覆盖率、cache read tokens

7. Provider/Route 下钻分析

路由模式	平台	总请求数	已归因请求数	Provider 分布
吞吐优先	Infron	394	394	alibaba/jp 303, alibaba/us 73, fireworks 18
吞吐优先	OpenRouter	394	394	Baidu 394
价格优先	Infron	240	240	alibaba/eu 240
价格优先	OpenRouter	240	240	GMICloud 224, DeepInfra 16
端到端时延优先	Infron	366	366	alibaba/jp 366
端到端时延优先	OpenRouter	366	366	GMICloud 335, WandB 30, Baidu 1
流式 TTFT 优先	Infron	398	398	alibaba/jp 398
流式 TTFT 优先	OpenRouter	398	398	GMICloud 260, WandB 71, Parasail 34, Baidu 33

上游 Provider 明细分布

路由模式	平台	上游 Provider	请求数	占比	first/second	覆盖轮次	Avg TTFT	Avg Latency	Prompt Tokens	Completion Tokens	Reasoning Tokens	Cache Read Tokens	观测成本
吞吐优先	Infron	alibaba/jp	303	76.90%	151/152	152	2749.35 ms	3024.49 ms	4743679	3748	0	4525568	\$0.16228700
吞吐优先	Infron	alibaba/us	73	18.53%	36/37	38	3541.33 ms	3849.94 ms	1157175	835	0	956928	\$0.02780000
吞吐优先	Infron	fireworks	18	4.57%	10/8	10	14505.73 ms	14954.33 ms	253698	237	0	107413	\$0.02385500
吞吐优先	OpenRouter	Baidu	394	100.00%	197/197	197	2584.72 ms	2915.93 ms	6154552	6304	6304	5687808	\$0.15917012
价格优先	Infron	alibaba/eu	240	100.00%	120/120	120	3797.36 ms	4102.95 ms	3921304	2796	0	3842816	\$0.06149200
价格优先	OpenRouter	GMICloud	224	93.33%	110/114	118	4856.64 ms	7738.61 ms	3782820	56449	53713	1727360	\$0.24704628
价格优先	OpenRouter	DeepInfra	16	6.67%	10/6	14	2575.58 ms	3353.36 ms	139181	199	0	2820	\$0.01235907
端到端时延优先	Infron	alibaba/jp	366	100.00%	183/183	183	2107.77 ms	2291.26 ms	5857970	4534	0	5681920	\$0.19021600
端到端时延优先	OpenRouter	GMICloud	335	91.53%	167/168	169	4597.62 ms	7234.79 ms	5730944	79171	75363	3192704	\$0.32811912
端到端时延优先	OpenRouter	WandB	30	8.20%	16/14	17	1598.96 ms	2330.18 ms	126214	396	0	0	\$0.01778084
端到端时延优先	OpenRouter	Baidu	1	0.27%	0/1	1	13102.11 ms	13265.61 ms	1866	16	16	0	\$0.00018657
流式 TTFT 优先	Infron	alibaba/jp	398	100.00%	199/199	199	1994.39 ms	2179.19 ms	6302520	4908	0	6263808	\$0.18822900
流式 TTFT 优先	OpenRouter	GMICloud	260	65.33%	132/128	133	4738.77 ms	7472.09 ms	5407771	61568	58807	2939008	\$0.31278626
流式 TTFT 优先	OpenRouter	WandB	71	17.84%	35/36	43	2398.50 ms	3569.34 ms	293532	1030	0	0	\$0.04138288
流式 TTFT 优先	OpenRouter	Parasail	34	8.54%	15/19	27	1871.42 ms	3051.15 ms	135502	544	965	8960	\$0.01849540
流式 TTFT 优先	OpenRouter	Baidu	33	8.29%	17/16	22	1459.16 ms	1664.29 ms	466701	528	528	438272	\$0.01153233

7.1 缓存命中率与实际成本反向表现下钻

该表把 cache、cost、provider 分布和 reasoning telemetry 放在同一层级，解释每个路由模式的主要差异来源。

路由模式	缓存命中差值	Infron 成本倍数	Infron 主要路径	OpenRouter 主要路径	Reasoning Tokens 差异	主要归因
吞吐优先	+2.00 pp	1.34x	alibaba/jp 76.90%	Baidu 100.00%	-6304	Infron 缓存更高但成本更高，需检查上游单价、completion/reasoning tokens
价格优先	+46.07 pp	0.24x	alibaba/eu 100.00%	GMICloud 93.33%	-53713	Infron 缓存与成本同向占优
端到端时延优先	+41.33 pp	0.55x	alibaba/jp 100.00%	GMICloud 91.53%	-75379	Infron 缓存与成本同向占优
流式 TTFT 优先	+43.19 pp	0.49x	alibaba/jp 100.00%	GMICloud 65.33%	-60300	Infron 缓存与成本同向占优

8. 分层结果：按 Prompt 长度的缓存表现

本节按 prompt 长度 tier 聚合第二次请求的 cache read tokens、Token 级缓存命中率、实际成本、端到端时延和流式 TTFT。加粗单元表示同一长度 tier 下表现更优的一方。

Prompt 长度分层总览

Prompt 长度 tier	目标 tokens	平台	轮数	第二次 Prompt Tokens	第二次 Cache Read Tokens	Token 级命中率	实际成本	平均 E2E 时延	平均 TTFT
short	1500	Infron	235	437636	412621	94.28%	\$0.03085400	2009.88 ms	1797.20 ms
short	1500	OpenRouter	235	437942	120704	27.56%	\$0.08781002	3997.19 ms	2226.81 ms
medium	8000	Infron	234	2173233	2156751	99.24%	\$0.12927300	2821.46 ms	2605.96 ms
medium	8000	OpenRouter	234	2173726	1453696	66.88%	\$0.23653369	5504.25 ms	3534.99 ms
long	32000	Infron	230	8507304	8405241	98.80%	\$0.49375200	4113.44 ms	3836.90 ms
long	32000	OpenRouter	230	8507882	5864448	68.93%	\$0.82451518	7267.33 ms	5569.41 ms

Prompt 长度 x 路由模式缓存命中率

Prompt 长度 tier	路由模式	Infron	OpenRouter	胜出方
short	吞吐优先	94.34%	21.54%	Infron
short	价格优先	87.76%	45.57%	Infron
short	端到端时延优先	96.23%	35.21%	Infron
short	流式 TTFT 优先	96.23%	16.00%	Infron
medium	吞吐优先	99.27%	92.16%	Infron
medium	价格优先	99.23%	56.18%	Infron
medium	端到端时延优先	99.23%	54.53%	Infron
medium	流式 TTFT 优先	99.23%	59.05%	Infron
long	吞吐优先	96.51%	99.66%	OpenRouter
long	价格优先	99.66%	52.66%	Infron
long	端到端时延优先	99.66%	60.17%	Infron
long	流式 TTFT 优先	99.66%	57.62%	Infron

9. 分层结果：按实验组的稳定性检查

吞吐优先

平台	组别	轮数	成功轮数	Token 命中率	实际成本	P95 Latency	P95 TTFT
Infron	1	50	50	89.76%	\$0.06641800	10258.42 ms	9548.11 ms
Infron	2	50	50	99.46%	\$0.05927200	4951.09 ms	4795.32 ms
Infron	3	49	49	99.44%	\$0.04602400	5943.80 ms	5231.14 ms
Infron	4	48	48	99.41%	\$0.04222800	4151.44 ms	3916.11 ms
OpenRouter	1	50	50	90.98%	\$0.05382399	4284.67 ms	3926.96 ms
OpenRouter	2	50	50	96.38%	\$0.03664421	4541.40 ms	3877.62 ms
OpenRouter	3	49	49	96.65%	\$0.03579419	4714.34 ms	4199.33 ms
OpenRouter	4	48	48	95.94%	\$0.03290773	4547.92 ms	4196.36 ms

价格优先

平台	组别	轮数	成功轮数	Token 命中率	实际成本	P95 Latency	P95 TTFT
Infron	1	48	48	99.01%	\$0.02470300	5810.26 ms	5417.96 ms
Infron	2	1	1	99.66%	\$0.00108600	5709.77 ms	5573.80 ms
Infron	3	24	24	99.48%	\$0.01253500	6545.68 ms	6167.62 ms
Infron	4	47	47	99.06%	\$0.02316800	6464.19 ms	5964.53 ms
OpenRouter	1	48	48	56.43%	\$0.10281902	13259.29 ms	8304.91 ms
OpenRouter	2	1	1	47.06%	\$0.00564022	9942.21 ms	7977.84 ms
OpenRouter	3	24	24	52.77%	\$0.05067317	15546.80 ms	8150.99 ms
OpenRouter	4	47	47	50.30%	\$0.10027294	14354.48 ms	8381.70 ms

端到端时延优先

平台	组别	轮数	成功轮数	Token 命中率	实际成本	P95 Latency	P95 TTFT
Infron	1	34	34	99.44%	\$0.04714700	3885.47 ms	3652.00 ms
Infron	2	50	50	99.46%	\$0.04883400	3465.78 ms	3174.67 ms
Infron	3	50	50	99.45%	\$0.04820900	3568.15 ms	3377.68 ms
Infron	4	49	49	99.44%	\$0.04602600	3427.98 ms	3139.49 ms
OpenRouter	1	34	34	60.49%	\$0.05264480	11778.21 ms	7889.89 ms
OpenRouter	2	50	50	55.60%	\$0.10097224	12982.23 ms	7737.01 ms
OpenRouter	3	50	50	57.51%	\$0.09324252	12067.22 ms	9309.78 ms
OpenRouter	4	49	49	59.77%	\$0.09922697	12926.26 ms	9326.37 ms

流式 TTFT 优先

平台	组别	轮数	成功轮数	Token 命中率	实际成本	P95 Latency	P95 TTFT
Infron	1	50	50	99.44%	\$0.04697700	3344.00 ms	3056.57 ms
Infron	2	49	49	99.44%	\$0.04645400	3326.43 ms	3053.64 ms
Infron	3	50	50	99.45%	\$0.04820800	3361.89 ms	3133.43 ms
Infron	4	50	50	99.44%	\$0.04659000	3549.31 ms	3225.87 ms
OpenRouter	1	50	50	61.12%	\$0.10069327	12294.78 ms	8058.92 ms
OpenRouter	2	49	49	47.25%	\$0.10840604	12682.66 ms	8600.37 ms
OpenRouter	3	50	50	66.63%	\$0.07893070	10297.88 ms	6829.86 ms
OpenRouter	4	50	50	49.63%	\$0.09616686	11491.85 ms	7724.52 ms

10. 讨论：业务价值、适用边界与工程启示

业务决策不应只看单一指标。稳定长上下文和高频模板请求优先关注缓存命中率与成本；实时交互应同时约束 TTFT 和端到端时延；后台批处理更重视吞吐与失败成本。

路由模式	主要业务目标	本轮数据体现	适用场景	注意事项
吞吐优先	最大化单位时间输出能力	OpenRouter 综合占优（4/5 指标）	批量内容生成、离线摘要、后台数据加工	首包与完整响应更快，但需检查缓存和成本
价格优先	最小化单位请求和单位 token 成本	Infron 综合占优（4/5 指标）	高频模板化请求、客服自动化、营销触达、RAG 固定前缀	缓存和成本更稳，但仍需检查速度 SLA
端到端时延优先	最小化完整响应等待时间	Infron 综合占优（4/5 指标）	在线聊天、Agent 调用链、IDE/写作辅助、实时运营工具	缓存和成本更稳，但仍需检查速度 SLA
流式 TTFT 优先	最小化流式首包响应时间	Infron 综合占优（4/5 指标）	流式聊天、实时 Copilot、首屏反馈、长任务进度感知	缓存和成本更稳，但仍需检查速度 SLA

11. 结论

路由模式级结论

路由模式	目标	缓存胜出	成本胜出	吞吐胜出	E2E 时延胜出	TTFT 胜出	解读
吞吐优先	最大化单位时间输出能力	Infron	OpenRouter	OpenRouter	OpenRouter	OpenRouter	OpenRouter 综合占优（4/5 指标）
价格优先	最小化单位请求和单位 token 成本	Infron	Infron	OpenRouter	Infron	Infron	Infron 综合占优（4/5 指标）
端到端时延优先	最小化完整响应等待时间	Infron	Infron	OpenRouter	Infron	Infron	Infron 综合占优（4/5 指标）
流式 TTFT 优先	最小化流式首包响应时间	Infron	Infron	OpenRouter	Infron	Infron	Infron 综合占优（4/5 指标）

12. 局限性、缺失数据与后续实验计划

缺失或不足	对结论的影响	后续补充方式	当前处理方式
完整 routing trace	无法逐跳证明每次请求的 provider 选择、fallback 和重试路径	补充 provider routing trace、decision log 和 fallback reason	只使用响应中真实返回的 provider 字段和 provider 分布
更长时间窗口	4x50 能观察短期稳定性，但不能覆盖日线波动	增加 soak test 和跨时段重复实验	报告限定在本轮窗口内解释
真实生产语料	内置模板不能覆盖全部业务分布	使用脱敏生产语料分层抽样	当前只讨论代表性长上下文业务模板
成本字段一致性	不同平台 cost 字段覆盖率和口径可能不同	结合账单回查和 provider cost breakdown	只统计响应明确返回的成本字段

13. 可复现性附录

工件	路径
Summary	export/deepseek_v4_flash_all_experiments/routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completio
配对数据集	export/deepseek_v4_flash_all_experiments/routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completio
请求级数据集	export/deepseek_v4_flash_all_experiments/routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completio
过滤后结构化记录	export/deepseek_v4_flash_all_experiments/routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completio
剔除记录审计	export/deepseek_v4_flash_all_experiments/routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completio
测试源码	tests/test_rerun_routing_sort_cache_cost_ab.py
Benchmark 执行源码	scripts/rerun_routing_sort_cache_cost_ab.py
HTML 报告渲染源码	scripts/render_glm52_deepseek_style_report.py
数据集引用	business_representative 内置代表性业务模板；请求级导出见 benchmark_requests.jsonl