

Infron 与 OpenRouter 路由、缓存、成本与流式性能 A/B 实验报告

摘要与结论大纲

关键词: Prompt Caching; A/B Testing; Provider Routing; Cache Affinity; Latency; Throughput; Cost Attribution; gemma-4-26b-a4b

摘要

本报告以 `google/gemma-4-26b-a4b` 为对象, 评估 Infron 与 OpenRouter 在 Prompt Caching 场景下的缓存复用、实际成本、吞吐、端到端时延和流式 TTFT 表现。

核心结论是: OpenRouter 在所有路由模式下缓存命中率占优; OpenRouter 在所有路由模式下实际成本占优; OpenRouter 在所有路由模式下吞吐量占优; OpenRouter 在所有路由模式下端到端 E2E 时延占优; OpenRouter 在所有路由模式下流式 TTFT 占优。

整体看, Infron 本轮未形成明确跨模式优势, OpenRouter 的跨模式优势主要体现在吞吐、流式 TTFT、端到端 E2E 时延、实际成本、缓存复用。平台选择不应只看单一指标, 而应按业务目标在成本、缓存稳定性、吞吐和交互时延之间取舍。

图 0：核心能力归一化雷达图

五个雷达轴分别代表吞吐量、价格、端到端 E2E 时延、流式 TTFT 和缓存命中率。所有指标统一转为 0-100 分，且越外侧越好。

粗实线表示平台综合轮廓，半透明细线和点表示各路由模式下的表现。

结论总览：核心指标与路由模式胜出方

基于严格 A/B 配对样本。蓝色代表 Infron，橙色代表 OpenRouter；金色单元格表示该路由模式的目标指标胜出方。

吞吐量	实际成本	端到端 E2E 时延	流式 TTFT	缓存命中率
OpenRouter 4/4 胜出	OpenRouter 4/4 胜出	OpenRouter 4/4 胜出	OpenRouter 4/4 胜出	OpenRouter 4/4 胜出
最大优势 101.85%，越高越好	最大优势 99.04%，越低越好	最大优势 101.87%，越低越好	最大优势 103.64%，越低越好	最大优势 50.70%，越高越好

路由模式	吞吐目标	成本目标	时延目标	TTFT 目标	缓存结果
吞吐优先 throughput	OpenRouter 优势 15.57%	OpenRouter 优势 31.29%	OpenRouter 优势 15.58%	OpenRouter 优势 11.60%	OpenRouter 优势 0.00%
价格优先 price	OpenRouter 优势 28.16%	OpenRouter 优势 36.73%	OpenRouter 优势 28.16%	OpenRouter 优势 23.13%	OpenRouter 优势 50.70%
端到端时延优先 latency	OpenRouter 优势 76.57%	OpenRouter 优势 99.04%	OpenRouter 优势 76.64%	OpenRouter 优势 78.36%	OpenRouter 优势 68.15%
流式 TTFT 优先 ttft	OpenRouter 优势 101.85%	OpenRouter 优势 24.59%	OpenRouter 优势 101.87%	OpenRouter 优势 103.64%	OpenRouter 优势 4.11%

结论大纲

研究维度	结论	证据位置
控制变量	同一 <code>sort/group/round</code> 下 <code>first/second usage.prompt_tokens</code> 偏差不超过 50 tokens；总 Input Tokens 使用响应 telemetry。	方法与数据质量章节
缓存复用	OpenRouter 在所有路由模式下缓存命中率占优	总体指标与机制解释章节
实际成本	OpenRouter 在所有路由模式下实际成本占优	总体指标与 Provider 下钻章节
性能表现	OpenRouter 在所有路由模式下吞吐量占优；OpenRouter 在所有路由模式下端到端 E2E 时延占优；OpenRouter 在所有路由模式下流式 TTFT 占优	结果可视化与统计检验章节
归因边界	报告只使用响应中可观测的 <code>usage</code> 、 <code>cost</code> 、 <code>TTFT</code> 、 <code>latency</code> 、 <code>provider</code> 字段和 <code>cache tokens</code> 。	Provider/Route 下钻分析章节
业务含义	长上下文、RAG 前缀、Agent 工具说明和高频模板请求应同时关注缓存命中率、成本、首包和端到端时延。	讨论与结论章节

[illegible]

路由模式	目标	缓存胜出	成本胜出	吞吐胜出	E2E 时延胜出	TTFT 胜出	解读
价格优先	最小化单位请求和单位 token 成本	OpenRouter	OpenRouter	OpenRouter	OpenRouter	OpenRouter	OpenRouter 综合占优 (5/5 指标)
端到端时延优先	最小化完整响应等待时间	OpenRouter	OpenRouter	OpenRouter	OpenRouter	OpenRouter	OpenRouter 综合占优 (5/5 指标)
流式 TTFT 优先	最小化流式首包响应时间	OpenRouter	OpenRouter	OpenRouter	OpenRouter	OpenRouter	OpenRouter 综合占优 (5/5 指标)

1. 引言：背景、研究问题与贡献

LLM 推理平台的真实性能不仅由模型决定，也由 provider 路由、提示词缓存、流式响应、成本归因和 fallback 策略共同决定。本报告把平台视为可观测系统，以 A/B 配对方式评估速度、成本、缓存和首包体验的多目标权衡。

1.1 研究假设

假设	内容	验证指标
H1	重复稳定长前缀请求中，更强的 provider/cache affinity 会提升 Token 级缓存命中率。	第二次请求 cache read tokens、Token 级命中率
H2	更高缓存命中率会降低真实响应成本，但不必然降低 TTFT 或端到端 latency。	实际成本、平均 TTFT、平均 latency/请求
H3	不同 routing sort 会改变 provider 选择，从而形成不同的成本、吞吐和时延 Pareto 前沿。	provider 分布、throughput、latency、cost

1.2 本文贡献

- 使用响应返回的 `usage.prompt_tokens` 作为真实 input token 控制变量，并允许 50 tokens 内的小幅跨平台计数波动。
- 将 prompt caching 评估扩展到成本、吞吐、E2E latency、TTFT、provider 分布、reasoning telemetry 和配对统计检验。
- 所有结论只基于响应可观测 telemetry，不把平台内部私有 routing trace 当作已观测事实。

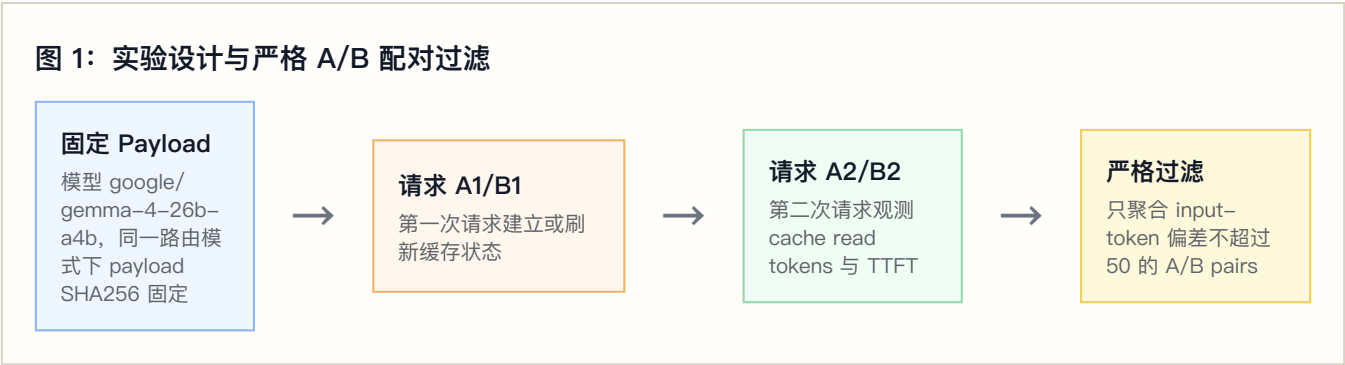
2. 方法：实验设计、数据集构造与控制变量

2.1 数据集生成方法

数据集名称为 `controlled_cache_probe`，覆盖 4 种 routing sort、2 个平台、4 个实验组、每组 50 轮。每轮包含 first/second 两次相同 Chat Completions 请求：第一次建立或刷新缓存状态，第二次观测 cache read tokens、TTFT 和端到端响应。

业务模板覆盖稳定长上下文场景，包括 RAG 客服、Agent 工具说明、营销自动化和代码审查等高复用 prompt 结构。

2.2 控制变量方法



控制变量方法：同一 sort/group/round 下，两个平台 first/second 两次请求的 usage.prompt_tokens 各自偏差必须不超过 50 tokens。总 Input Tokens 使用响应返回的 usage.prompt_tokens，不使用本地 tokenizer 估算。

2.3 指标定义

指标	定义	解释方向
调用级命中率	第二次请求 cache_read_tokens > 0 的轮次占比	越高表示越稳定触发缓存读取
Token 级命中率	第二次请求 cache read tokens / 第二次请求 prompt tokens	越高表示输入 token 复用比例越高
实际成本	first + second 两次请求返回 usage/cost 的合计	越低越好
Throughput	响应 completion tokens / 请求 latency seconds	越高越好
E2E latency	每次请求完整响应耗时均值	越低越好
TTFT	streaming 下首包/首 token 到达时间均值	越低越好
Reasoning 口径	响应 usage 中的 reasoning token 字段保留为观测变量	用于解释时延、吞吐和成本，不单独作为业务产出

3. 实验环境与数据质量控制

项目	配置
模型	google/gemma-4-26b-a4b
平台实际模型 ID	infron: google/gemma-4-26b-a4b ; openrouter: google/gemma-4-26b-a4b-it （平台别名映射已记录）
平台	Infron、OpenRouter
API 协议	/v1/chat/completions
路由模式	吞吐优先、价格优先、端到端时延优先、流式 TTFT 优先
实验组	4
每组轮数	50

项目	配置
Workers	24
请求方式	流式 Chat Completions, 采集 TTFT
Reasoning / Thinking 控制	未显式指定 reasoning/thinking 参数; 保留模型与平台默认行为
Prompt 长度分层	short ≈1500、medium ≈8000、long ≈32000
剔除记录	108

4. 结果：总体指标与主要发现

路由模式	平台	严格配对轮数	总 Input Tokens	Token 级缓存命中率	实际成本	吞吐量	端到端 E2E 时延	流式 TTFT
吞吐优先	Infron	186	7013376	0.00%	\$0.49143800	1.14 tok/s	3518.51 ms	3198.14 ms
吞吐优先	OpenRouter	186	7013004	99.36%	\$0.37430218	1.31 tok/s	3044.12 ms	2865.78 ms
价格优先	Infron	165	5938290	1.81%	\$0.42155500	0.93 tok/s	4283.03 ms	3875.66 ms
价格优先	OpenRouter	165	5937978	93.45%	\$0.30830935	1.20 tok/s	3342.00 ms	3147.68 ms
端到端时延优先	Infron	195	7187631	51.00%	\$0.91559200	0.73 tok/s	5452.12 ms	5187.90 ms
端到端时延优先	OpenRouter	195	7184700	85.75%	\$0.46001202	1.30 tok/s	3086.54 ms	2908.68 ms
流式 TTFT 优先	Infron	200	7407473	81.56%	\$0.62097300	0.70 tok/s	5707.61 ms	5390.37 ms
流式 TTFT 优先	OpenRouter	200	7404114	84.91%	\$0.49840228	1.42 tok/s	2827.30 ms	2647.02 ms

4.1 尾延迟与显著性检验

尾延迟分位数补充均值无法表达的尾部风险。

路由模式	平台	P50 Latency	P95 Latency	P99 Latency	P50 TTFT	P95 TTFT	P99 TTFT
吞吐优先	Infron	2537.70 ms	10988.81 ms	17290.74 ms	2252.29 ms	10797.79 ms	16680.14 ms
吞吐优先	OpenRouter	2571.20 ms	5819.18 ms	13868.07 ms	2417.63 ms	5716.57 ms	13614.74 ms
价格优先	Infron	3409.92 ms	9601.64 ms	21455.50 ms	2910.42 ms	9373.30 ms	20757.24 ms
价格优先	OpenRouter	2546.55 ms	8403.99 ms	16002.68 ms	2401.96 ms	8337.77 ms	15772.69 ms
端到端时延优先	Infron	4471.93 ms	10126.98 ms	17210.69 ms	4254.40 ms	9630.82 ms	17007.03 ms
端到端时延优先	OpenRouter	2482.57 ms	5164.90 ms	8160.89 ms	2221.57 ms	4925.94 ms	8140.31 ms

路由模式	平台	P50 Latency	P95 Latency	P99 Latency	P50 TTFT	P95 TTFT	P99 TTFT
流式 TTFT 优先	Infron	4817.81 ms	11790.30 ms	18591.58 ms	4424.24 ms	11326.14 ms	18067.71 ms
流式 TTFT 优先	OpenRouter	2327.37 ms	5387.84 ms	11818.53 ms	2151.59 ms	5242.32 ms	11016.61 ms

均值差使用 bootstrap 95% CI, p-value 使用 paired sign-flip permutation test。

路由模式	指标	均值差	95% CI	p-value	配对数	解释
吞吐优先	Latency: OpenRouter – Infron	–948.78 ms	–1810.24 ms to –125.80 ms	0.0242	186	正值表示 Infron latency 更低
吞吐优先	TTFT: OpenRouter – Infron	–664.72 ms	–1522.67 ms to 122.59 ms	0.1115	186	正值表示 Infron TTFT 更低
吞吐优先	Throughput: Infron – OpenRouter	–0.0611 tok/s	–0.1694 tok/s to 0.0458 tok/s	0.2652	186	正值表示 Infron throughput 更高
吞吐优先	Cost: OpenRouter – Infron	\$–0.00062976	\$–0.00074307 to \$–0.00051465	<0.001	186	正值表示 Infron 成本更低
吞吐优先	Token Cache Hit: Infron – OpenRouter	–98.13 pp	–99.24 pp to –96.51 pp	<0.001	186	正值表示 Infron cache hit 更高
价格优先	Latency: OpenRouter – Infron	–1882.06 ms	–2865.51 ms to –901.88 ms	<0.001	165	正值表示 Infron latency 更低
价格优先	TTFT: OpenRouter – Infron	–1455.95 ms	–2437.73 ms to –481.50 ms	0.0027	165	正值表示 Infron TTFT 更低
价格优先	Throughput: Infron – OpenRouter	–0.3721 tok/s	–0.4702 tok/s to –0.2626 tok/s	<0.001	165	正值表示 Infron throughput 更高
价格优先	Cost: OpenRouter – Infron	\$–0.00068634	\$–0.00081721 to \$–0.00056262	<0.001	165	正值表示 Infron 成本更低
价格优先	Token Cache Hit: Infron – OpenRouter	–89.57 pp	–93.78 pp to –84.76 pp	<0.001	165	正值表示 Infron cache hit 更高
端到端时延优先	Latency: OpenRouter – Infron	–4731.16 ms	–6219.92 ms to –3184.34 ms	<0.001	195	正值表示 Infron latency 更低
端到端时延优先	TTFT: OpenRouter – Infron	–4558.45 ms	–6074.58 ms to –2988.64 ms	<0.001	195	正值表示 Infron TTFT 更低
端到端时延优先	Throughput: Infron – OpenRouter	–0.7792 tok/s	–0.8619 tok/s to –0.6932 tok/s	<0.001	195	正值表示 Infron throughput 更高
端到端时延优先	Cost: OpenRouter – Infron	\$–0.00233631	\$–0.00272666 to \$–0.00195797	<0.001	195	正值表示 Infron 成本更低
端到端时延优先	Token Cache Hit: Infron – OpenRouter	–30.61 pp	–38.88 pp to –21.65 pp	<0.001	195	正值表示 Infron cache hit 更高
流式 TTFT 优先	Latency: OpenRouter – Infron	–5760.62 ms	–6875.31 ms to –4760.89 ms	<0.001	200	正值表示 Infron latency 更低
流式 TTFT 优先	TTFT: OpenRouter – Infron	–5486.69 ms	–6570.88 ms to –4505.71 ms	<0.001	200	正值表示 Infron TTFT 更低

路由模式	指标	均值差	95% CI	p-value	配对数	解释
流式 TTFT 优先	Throughput: Infron – OpenRouter	-0.8170 tok/s	-0.9051 tok/s to -0.7328 tok/s	<0.001	200	正值表示 Infron throughput 更高
流式 TTFT 优先	Cost: OpenRouter – Infron	\$-0.00061285	\$-0.00088470 to \$-0.00033943	<0.001	200	正值表示 Infron 成本更低
流式 TTFT 优先	Token Cache Hit: Infron – OpenRouter	-6.23 pp	-13.66 pp to 1.21 pp	0.1312	200	正值表示 Infron cache hit 更高

4.2 Reasoning / Thinking 控制校验

本轮未显式指定 reasoning/thinking 参数，保留模型与平台默认行为；该表记录默认行为下的 reasoning telemetry。

路由模式	平台	Reasoning Tokens	平均 Reasoning Tokens/请求	Reasoning 请求数	平均首 Reasoning Token	平均 TTFT	平均 E2E 时延
吞吐优先	Infron	0	0.0000	0	0.00 ms	3198.14 ms	3518.51 ms
吞吐优先	OpenRouter	0	0.0000	0	0.00 ms	2865.78 ms	3044.12 ms
价格优先	Infron	0	0.0000	0	0.00 ms	3875.66 ms	4283.03 ms
价格优先	OpenRouter	0	0.0000	0	0.00 ms	3147.68 ms	3342.00 ms
端到端时延优先	Infron	0	0.0000	0	0.00 ms	5187.90 ms	5452.12 ms
端到端时延优先	OpenRouter	0	0.0000	0	0.00 ms	2908.68 ms	3086.54 ms
流式 TTFT 优先	Infron	0	0.0000	0	0.00 ms	5390.37 ms	5707.61 ms
流式 TTFT 优先	OpenRouter	0	0.0000	0	0.00 ms	2647.02 ms	2827.30 ms

4.3 API 协议兼容性矩阵

本轮 API 协议为 /v1/chat/completions；本表记录两家平台在该协议下的成功响应、usage、成本和缓存 telemetry 覆盖。

API 协议	Endpoint	平台	配对 轮数	请求 数	成功率	Usage 覆盖	Token Usage 覆盖	成本覆盖	缓存 Telemetry 覆盖	HTTP 状 态
chat_completions	/v1/chat/ completions	Infron	800	1600	98.56%	99.94%	99.94%	99.94%	100.00%	{"0": 23,"200 1577}
chat_completions	/v1/chat/ completions	OpenRouter	800	1600	97.75%	100.00%	100.00%	100.00%	100.00%	{"0": 36,"200 1564}

5. 结果可视化：按路由模式的核心指标变化

以下图表使用同一份严格配对后的 summary 数据驱动，统一展示路由模式、平台差异、成本、缓存、端到端 E2E 时延、流式 TTFT 和上游 Provider 分布。

5.1 核心指标图表总览

以下图表使用同一份严格配对后的 summary 数据生成，统一展示路由模式、平台差异、成本、缓存、端到端 E2E 时延、流式 TTFT 和上游 Provider 分布。

图 3-E2：归一化
综合轮廓

五项指标统一转为
0-100 且越高越好。

图 3-E3：成本-缓存
效率平面

横轴为 Token 级缓存命中
率，纵轴为总实际成本。

图 3-E1：路由模式级核心指标对比
按路由模式并列展示 Infron 与 OpenRouter。

图 3-E4：端到端 E2E 时延与流式 TTFT

实线表示端到端 E2E 时延，虚线表示流式 TTFT。

图 3-E5：上游 Provider 分布

按路由模式展示主要上游路径占比。

模式级下钻图表

横轴表示相对优势百分比：右侧蓝色代表 Infron 优势，左侧橙色代表 OpenRouter 优势。

图 4-E1: Throughput First 路由模式下的核心指标对比

展示五项核心指标的相对优势方向与幅度。

图 4-E2: Price First 路由模式下的核心指标对比

展示五项核心指标的相对优势方向与幅度。

图 4-E3: Latency First 路由模式下的核心指标对比

展示五项核心指标的相对优势方向与幅度。

图 4-E4: TTFT First 路由模式下的核心指标对比

展示五项核心指标的相对优势方向与幅度。

6. Infron 技术架构与缓存/成本机制解释



6.1 多 provider 路由与可观测控制面

请求进入统一 API 后，路由策略层根据 throughput、price、latency 或 tftt 目标选择健康上游路径。稳定长前缀请求是否落在相同缓存域，会直接影响第二次请求的 cache read tokens。

6.2 Provider Stick 与 Cache Affinity

Provider stick 是缓存亲和策略，不等于固定锁死 provider。它的目标是在健康和 SLA 约束下减少缓存域碎片化，使重复 prefix 更容易复用已有缓存。

6.3 成本控制路径

机制	对 cache rate 的影响	对成本的影响	本次实验中的可观测信号
Stable prefix 识别	相同前缀更容易命中已有 cache	降低重复 prefill 的边际成本	同一 payload SHA256、第二次请求 cache read tokens
Provider stick / cache affinity	降低跨 provider/cache domain 的缓存碎片	减少重复暖缓存	provider 分布与 Token 级命中率共同变化
健康检查与 fallback	保护可用性，必要时牺牲部分缓存收益	降低失败成本	HTTP 状态、provider 分布和尾延迟变化
成本感知 routing	在健康约束下偏向低成本路径	降低总成本和每轮成本	实际成本、cost breakdown 覆盖率、cache read tokens

7. Provider/Route 下钻分析

路由模式	平台	总请求数	已归因请求数	Provider 分布
吞吐优先	Infron	372	372	deepinfra 372
吞吐优先	OpenRouter	372	372	Wafer 369, Google 3
价格优先	Infron	330	330	deepinfra 324, parasail 6
价格优先	OpenRouter	330	330	Wafer 312, DeepInfra 7, SiliconFlow 7, DekaLLM 4
端到端时延优先	Infron	390	390	novita 326, nextbit 64

路由模式	平台	总请求数	已归因请求数	Provider 分布
端到端时延优先	OpenRouter	390	390	Wafer 331, Google 59
流式 TTFT 优先	Infron	400	400	nextbit 267, parasail 78, deepinfra 53, novita 2
流式 TTFT 优先	OpenRouter	400	400	Wafer 327, Google 73

上游 Provider 明细分布

路由模式	平台	上游 Provider	请求数	占比	first/second	覆盖轮次	Avg TTFT	Avg Latency	Prompt Tokens	Completion Tokens	Reasoning Tokens	C R T
吞吐优先	Infron	deepinfra	372	100.00%	186/186	186	3198.14 ms	3518.51 ms	7013376	1488	0	0
吞吐优先	OpenRouter	Wafer	369	99.19%	184/185	186	2869.08 ms	3047.20 ms	6980589	1476	0	6
吞吐优先	OpenRouter	Google	3	0.81%	2/1	3	2459.38 ms	2664.83 ms	32415	12	0	12
价格优先	Infron	deepinfra	324	98.18%	165/159	165	3793.26 ms	4203.11 ms	5776852	1296	0	0
价格优先	Infron	parasail	6	1.82%	0/6	6	8324.74 ms	8598.95 ms	161438	24	0	5
价格优先	OpenRouter	Wafer	312	94.55%	161/151	161	3009.99 ms	3197.16 ms	5734063	1248	0	5
价格优先	OpenRouter	DeepInfra	7	2.12%	2/5	5	5368.65 ms	5925.45 ms	40764	28	0	0
价格优先	OpenRouter	SiliconFlow	7	2.12%	2/5	6	6547.58 ms	6700.35 ms	105165	28	0	0
价格优先	OpenRouter	DekaLLM	4	1.21%	0/4	4	4050.88 ms	4241.61 ms	57986	16	0	0
端到端时延优先	Infron	novita	326	83.59%	167/159	184	4636.06 ms	4906.26 ms	6075350	1304	0	3
端到端时延优先	Infron	nextbit	64	16.41%	28/36	53	7998.84 ms	8232.57 ms	1112281	256	0	5
端到端时延优先	OpenRouter	Wafer	331	84.87%	168/163	169	2942.47 ms	3118.98 ms	6337857	1324	0	6

路由模式	平台	上游 Provider	请求数	占比	first/second	覆盖轮次	Avg TTFT	Avg Latency	Prompt Tokens	Completion Tokens	Reasoning Tokens	C R T
端到端时延优先	OpenRouter	Google	59	15.13%	27/32	33	2719.10 ms	2904.55 ms	846843	236	0	1
流式 TTFT 优先	Infron	nextbit	267	66.75%	132/135	143	5852.33 ms	6183.27 ms	5027624	1068	0	4
流式 TTFT 优先	Infron	parasail	78	19.50%	35/43	43	4328.70 ms	4607.51 ms	1485600	312	0	12
流式 TTFT 优先	Infron	deepinfra	53	13.25%	32/21	32	4578.76 ms	4893.44 ms	840415	212	0	0
流式 TTFT 优先	Infron	novita	2	0.50%	1/1	2	6630.99 ms	6687.21 ms	53834	8	0	0
流式 TTFT 优先	OpenRouter	Wafer	327	81.75%	165/162	165	2526.51 ms	2685.14 ms	6151069	1308	0	6
流式 TTFT 优先	OpenRouter	Google	73	18.25%	35/38	38	3186.82 ms	3464.13 ms	1253045	292	0	10

7.1 缓存命中率与实际成本反向表现下钻

该表把 cache、cost、provider 分布和 reasoning telemetry 放在同一层级，解释每个路由模式的主要差异来源。

路由模式	缓存命中差值	Infron 成本倍数	Infron 主要路径	OpenRouter 主要路径	Reasoning Tokens 差异	主要归因
吞吐优先	-99.36 pp	1.31x	deepinfra 100.00%	Wafer 99.19%	+0	OpenRouter 缓存更高且成本更低，主要看 provider/cache 域差异
价格优先	-91.64 pp	1.37x	deepinfra 98.18%	Wafer 94.55%	+0	OpenRouter 缓存更高且成本更低，主要看 provider/cache 域差异
端到端时延优先	-34.75 pp	1.99x	novita 83.59%	Wafer 84.87%	+0	OpenRouter 缓存更高且成本更低，主要看 provider/cache 域差异
流式 TTFT 优先	-3.35 pp	1.25x	nextbit 66.75%	Wafer 81.75%	+0	OpenRouter 缓存更高且成本更低，主要看 provider/cache 域差异

8. 分层结果：按 Prompt 长度的缓存表现

本节按 prompt 长度 tier 聚合第二次请求的 cache read tokens、Token 级缓存命中率、实际成本、端到端时延和流式 TTFT。加粗单元表示同一长度 tier 下表现更优的一方。

Prompt 长度分层总览

Prompt 长度 tier	目标 tokens	平台	轮数	第二次 Prompt Tokens	第二次 Cache Read Tokens	Token 级命中率	实际成本	平均 E2E 时延	平均 TTFT
short	1500	Infron	250	522652	184416	35.28%	\$0.09358700	3671.92 ms	3335.98 ms
short	1500	OpenRouter	250	521463	448719	86.05%	\$0.06677004	2042.67 ms	1852.01 ms
medium	8000	Infron	251	2713228	939376	34.62%	\$0.48702400	4735.61 ms	4421.16 ms
medium	8000	OpenRouter	251	2712013	2457340	90.61%	\$0.33247589	3038.25 ms	2848.47 ms
long	32000	Infron	245	10537582	3783408	35.90%	\$1.86894700	5955.96 ms	5634.06 ms
long	32000	OpenRouter	245	10536427	9576674	90.89%	\$1.24177990	4129.40 ms	3963.38 ms

Prompt 长度 x 路由模式缓存命中率

Prompt 长度 tier	路由模式	Infron	OpenRouter	胜出方
short	吞吐优先	0.00%	96.58%	OpenRouter
short	价格优先	0.00%	85.91%	OpenRouter
short	端到端时延优先	57.10%	80.39%	OpenRouter
short	流式 TTFT 优先	75.20%	82.16%	OpenRouter
medium	吞吐优先	0.00%	97.91%	OpenRouter
medium	价格优先	1.74%	92.53%	OpenRouter
medium	端到端时延优先	53.78%	86.55%	OpenRouter
medium	流式 TTFT 优先	76.01%	86.17%	OpenRouter
long	吞吐优先	0.00%	99.86%	OpenRouter
long	价格优先	1.92%	94.10%	OpenRouter
long	端到端时延优先	49.98%	85.82%	OpenRouter
long	流式 TTFT 优先	83.29%	84.73%	OpenRouter

9. 分层结果：按实验组的稳定性检查

吞吐优先

平台	组别	轮数	成功轮数	Token 命中率	实际成本	P95 Latency	P95 TTFT
Infron	1	48	48	0.00%	\$0.12534400	16802.11 ms	16542.71 ms
Infron	2	47	47	0.00%	\$0.12505000	14416.81 ms	13478.74 ms
Infron	3	47	47	0.00%	\$0.12955800	10571.42 ms	10237.77 ms
Infron	4	44	44	0.00%	\$0.11148600	8992.76 ms	8572.44 ms
OpenRouter	1	48	48	99.73%	\$0.10265040	7391.17 ms	6595.85 ms
OpenRouter	2	47	47	99.73%	\$0.09459054	5114.44 ms	5055.18 ms
OpenRouter	3	47	47	98.58%	\$0.09405886	5945.15 ms	5642.38 ms
OpenRouter	4	44	44	99.46%	\$0.08300238	5575.85 ms	5552.48 ms

价格优先

平台	组别	轮数	成功轮数	Token 命中率	实际成本	P95 Latency	P95 TTFT
Infron	1	40	40	0.00%	\$0.10072000	9530.75 ms	8840.43 ms
Infron	2	38	38	0.00%	\$0.10605600	7790.75 ms	7419.75 ms
Infron	3	42	42	0.00%	\$0.10845400	14506.44 ms	13923.42 ms
Infron	4	45	45	7.41%	\$0.10632500	13316.27 ms	12789.29 ms
OpenRouter	1	40	40	98.21%	\$0.07195559	6190.24 ms	6127.13 ms
OpenRouter	2	38	38	80.76%	\$0.08333400	8902.37 ms	8853.82 ms
OpenRouter	3	42	42	97.28%	\$0.07875651	8700.04 ms	8666.29 ms
OpenRouter	4	45	45	97.93%	\$0.07426325	6595.52 ms	5836.52 ms

端到端时延优先

平台	组别	轮数	成功轮数	Token 命中率	实际成本	P95 Latency	P95 TTFT
Infron	1	47	47	63.33%	\$0.22159300	13148.44 ms	12680.91 ms
Infron	2	48	48	28.09%	\$0.23387100	9313.01 ms	8892.90 ms
Infron	3	50	50	49.14%	\$0.23907800	9401.61 ms	9256.44 ms
Infron	4	50	50	63.93%	\$0.22105000	15370.09 ms	15123.91 ms
OpenRouter	1	47	47	72.52%	\$0.12828628	5909.73 ms	5674.95 ms
OpenRouter	2	48	48	79.55%	\$0.12797190	5378.67 ms	5352.42 ms
OpenRouter	3	50	50	96.36%	\$0.10237124	3832.10 ms	3198.89 ms

路由模式	目标	缓存胜出	成本胜出	吞吐胜出	E2E 时延胜出	TTFT 胜出	解读
价格优先	最小化单位请求和单位 token 成本	OpenRouter	OpenRouter	OpenRouter	OpenRouter	OpenRouter	OpenRouter 综合占优 (5/5 指标)
端到端时延优先	最小化完整响应等待时间	OpenRouter	OpenRouter	OpenRouter	OpenRouter	OpenRouter	OpenRouter 综合占优 (5/5 指标)
流式 TTFT 优先	最小化流式首包响应时间	OpenRouter	OpenRouter	OpenRouter	OpenRouter	OpenRouter	OpenRouter 综合占优 (5/5 指标)

12. 局限性、缺失数据与后续实验计划

缺失或不足	对结论的影响	后续补充方式	当前处理方式
完整 routing trace	无法逐跳证明每次请求的 provider 选择、fallback 和重试路径	补充 provider routing trace、decision log 和 fallback reason	只使用响应中真实返回的 provider 字段和 provider 分布
更长时间窗口	4x50 能观察短期稳定性，但不能覆盖日级波动	增加 soak test 和跨时段重复实验	报告限定在本轮窗口内解释
真实生产语料	内置模板不能覆盖全部业务分布	使用脱敏生产语料分层抽样	当前只讨论代表性长上下文业务模板
成本字段一致性	不同平台 cost 字段覆盖率和口径可能不同	结合账单回查和 provider cost breakdown	只统计响应明确返回的成本字段

13. 可复现性附录

工件	路径
Summary	export/gemma_4_26b_a4b_all_experiments/routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions_summary.json
配对数据集	export/gemma_4_26b_a4b_all_experiments/routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions_benchmark_pairs.csv
请求级数据集	export/gemma_4_26b_a4b_all_experiments/routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions_benchmark_requests.jsonl
过滤后结构化记录	export/gemma_4_26b_a4b_all_experiments/routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions_records.json
剔除记录审计	export/gemma_4_26b_a4b_all_experiments/routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions_records_excluded.json
测试源码	tests/test_rerun_routing_sort_cache_cost_ab.py

工件	路径
Benchmark 执行源码	<code>scripts/rerun_routing_sort_cache_cost_ab.py</code>
HTML 报告 渲染源码	<code>scripts/render_glm52_deepseek_style_report.py</code>
数据集引用	<code>business_representative</code> 内置代表性业务模板：请求级导出见 <code>benchmark_requests.jsonl</code>