

Infron 与 OpenRouter 路由、缓存、成本与流式性能 A/B 实验报告

模型： `minimax/minimax-m3`

本报告沿用标准 A/B benchmark 矩阵：4 个实验组、每组 50 轮、开启 streaming、使用 Chat Completions 协议、reasoning 保持默认行为，并覆盖 short / medium / long 三档 prompt 长度。

数据质量

- 请求级记录数：3196
- 可比较 A/B 配对样本：799
- 剔除记录：共 2 条；其中 incomplete 1 条，anomalous usage 0 条，input tokens 不一致 1 条。
- Request JSONL SHA256： `333491a80a3af487f260ea9b9f6b7cd3f863e3b150f025ea62796a345bf8caa0`
- Pair CSV SHA256： `04e9799be91b7b05670e88c20259466bba36f0132affa8f618fe73864239406d`

聚合结果

路由目标	平台	有效轮次	Token 缓存命中率	实际成本	平均 Latency (ms)	P95 Latency (ms)	平均 TTFT (ms)	P95 TTFT (ms)	输出 TPS
throughput	infron	199	99.75%	\$0.44453200	4,187.992	6,968.981	3,906.654	6,495.255	3.820
throughput	openrouter	199	97.78%	\$0.42616452	3,520.482	5,479.748	3,320.929	5,200.601	4.480
price	infron	200	87.07%	\$0.86923800	4,215.047	7,121.548	3,970.207	6,674.128	5.706
price	openrouter	200	99.71%	\$0.38910666	3,183.654	4,902.943	2,988.125	4,725.499	5.026
latency	infron	200	99.56%	\$0.38928600	3,610.426	5,793.898	3,345.935	5,363.684	4.432
latency	openrouter	200	97.80%	\$0.50588802	3,322.030	5,299.352	3,069.540	4,975.527	4.816
ttft	infron	200	99.56%	\$0.38928600	3,405.387	5,775.962	3,123.363	5,550.827	4.698
ttft	openrouter	200	99.71%	\$0.49761108	3,616.816	5,975.508	3,377.282	5,208.558	4.424

结论解读

- `throughput`：缓存命中胜出 Infron；成本胜出 OpenRouter；Latency 胜出 OpenRouter；TTFT 胜出 OpenRouter；吞吐胜出 OpenRouter。
- `price`：缓存命中胜出 OpenRouter；成本胜出 OpenRouter；Latency 胜出 OpenRouter；TTFT 胜出 OpenRouter；吞吐胜出 Infron。
- `latency`：缓存命中胜出 Infron；成本胜出 Infron；Latency 胜出 OpenRouter；TTFT 胜出 OpenRouter；吞吐胜出 OpenRouter。

- `ttft`：缓存命中胜出 OpenRouter；成本胜出 Infron；Latency 胜出 Infron；TTFT 胜出 Infron；吞吐胜出 Infron。

整体看，本轮实验没有出现单一平台在所有指标上绝对领先。Infron 在 4 个路由目标中的 3 个目标上缓存复用更强，并且在 latency / TTFT 模式下实际成本更低；OpenRouter 在 throughput、price、latency 三个模式下平均时延更低；在显式 TTFT 目标下，Infron 的平均 TTFT 更低。`price` 模式是 Infron 成本侧的主要异常点，原因是该组缓存复用明显低于 OpenRouter。

源数据与产物

- 实验目录： `export/minimax_m3_all_experiments/
routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions_2026070`
- 原始记录： `export/minimax_m3_all_experiments/
routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions_2026070
records.json`
- 请求明细： `export/minimax_m3_all_experiments/
routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions_2026070
benchmark_requests.jsonl`
- 配对样本： `export/minimax_m3_all_experiments/
routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions_2026070
benchmark_pairs.csv`
- 汇总文件： `export/minimax_m3_all_experiments/
routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions_2026070
summary.json`