

Infron 与 OpenRouter 路由、缓存、成本与流式性能 A/B 实验报告

摘要与结论大纲

关键词: Prompt Caching; A/B Testing; Provider Routing; Cache Affinity; Latency; Throughput; Cost Attribution; kimi-k2.5

摘要

本报告以 moonshotai/kimi-k2.5 为对象, 评估 Infron 与 OpenRouter 在 Prompt Caching 场景下的缓存复用、实际成本、吞吐、端到端时延和流式 TTFT 表现。

核心结论是: Infron 在 0/4 个路由模式下缓存命中率占优, OpenRouter 在 2/4 个路由模式下占优, 2/4 个路由模式持平; Infron 在 1/4 个路由模式下实际成本占优, OpenRouter 在 1/4 个路由模式下占优, 2/4 个路由模式持平; Infron 在 0/4 个路由模式下吞吐量占优, OpenRouter 在 2/4 个路由模式下占优, 2/4 个路由模式持平; Infron 在 0/4 个路由模式下端到端 E2E 时延占优, OpenRouter 在 2/4 个路由模式下占优, 2/4 个路由模式持平; Infron 在 0/4 个路由模式下流式 TTFT 占优, OpenRouter 在 2/4 个路由模式下占优, 2/4 个路由模式持平。

整体看, Infron 本轮未形成明确跨模式优势, OpenRouter 的跨模式优势主要体现在吞吐、流式 TTFT、端到端 E2E 时延、缓存复用。平台选择不应只看单一指标, 而应按业务目标在成本、缓存稳定性、吞吐和交互时延之间取舍。

图 0：核心能力归一化雷达图

五个雷达轴分别代表吞吐量、价格、端到端 E2E 时延、流式 TTFT 和缓存命中率。所有指标统一转为 0-100 分，且越外侧越好。

粗实线表示平台综合轮廓，半透明细线和点表示各路由模式下的表现。

结论总览：核心指标与路由模式胜出方

基于严格 A/B 配对样本。蓝色代表 Infron，橙色代表 OpenRouter；金色单元格表示该路由模式的目标指标胜出方。

吞吐量 双方 4/4 持平 最大优势 4.30%，越高越好	实际成本 双方 4/4 持平 最大优势 5.10%，越低越好	端到端 E2E 时延 双方 4/4 持平 最大优势 105.13%，越低越好	流式 TTFT 双方 4/4 持平 最大优势 135.09%，越低越好	缓存命中率 双方 4/4 持平 最大优势 5.46%，越高越好
--	---	---	--	--

路由模式	吞吐目标	成本目标	时延目标	TTFT 目标	缓存结果
吞吐优先 throughput	OpenRouter 优势 2.51%	OpenRouter 优势 5.10%	OpenRouter 优势 8.10%	OpenRouter 优势 48.82%	OpenRouter 优势 5.46%
价格优先 price	Tie 持平	Tie 持平	Tie 持平	Tie 持平	Tie 持平
端到端时延优先 latency	Tie 持平	Tie 持平	Tie 持平	Tie 持平	Tie 持平
流式 TTFT 优先 tftt	OpenRouter 优势 4.30%	Infron 优势 73.04%	OpenRouter 优势 105.13%	OpenRouter 优势 135.09%	OpenRouter 优势 0.77%

结论大纲

研究维度	结论	证据位置
控制变量	同一 sort/group/round 下 first/second usage.prompt_tokens 偏差不超过 50 tokens；总 Input Tokens 使用响应 telemetry。	方法与数据质量章节
缓存复用	Infron 在 0/4 个路由模式下缓存命中率占优，OpenRouter 在 2/4 个路由模式下占优，2/4 个路由模式持平	总体指标与机制解释章节
实际成本	Infron 在 1/4 个路由模式下实际成本占优，OpenRouter 在 1/4 个路由模式下占优，2/4 个路由模式持平	总体指标与 Provider 下钻章节
性能表现	Infron 在 0/4 个路由模式下吞吐量占优，OpenRouter 在 2/4 个路由模式下占优，2/4 个路由模式持平；Infron 在 0/4 个路由模式下端到端 E2E 时延占优，OpenRouter 在 2/4 个路由模式下占优，2/4 个路由模式持平；Infron 在 0/4 个路由模式下流式 TTFT占优，OpenRouter 在 2/4 个路由模式下占优，2/4 个路由模式持平	结果可视化与统计检验章节
归因边界	报告只使用响应中可观测的 usage、cost、TTFT、latency、provider 字段和 cache tokens。	Provider/Route 下钻分析章节

研究维度	结论	证据位置
业务含义	长上下文、RAG 前缀、Agent 工具说明和高频模板请求应同时关注缓存命中率、成本、首包和端到端时延。	讨论与结论章节

路由模式级结论

路由模式	目标	缓存胜出	成本胜出	吞吐胜出	E2E 时延胜出	TTFT 胜出	解读
吞吐优先	最大化单位时间输出能力	OpenRouter	OpenRouter	OpenRouter	OpenRouter	OpenRouter	OpenRouter 综合占优 (5/5 指标)
价格优先	最小化单位请求和单位 token 成本	Tie	Tie	Tie	Tie	Tie	双方各有优势
端到端时延优先	最小化完整响应等待时间	Tie	Tie	Tie	Tie	Tie	双方各有优势
流式 TTFT 优先	最小化流式首包响应时间	OpenRouter	Infron	OpenRouter	OpenRouter	OpenRouter	OpenRouter 综合占优 (4/5 指标)

1. 引言：背景、研究问题与贡献

LLM 推理平台的真实性能不仅由模型决定，也由 provider 路由、提示词缓存、流式响应、成本归因和 fallback 策略共同决定。本报告把平台视为可观测系统，以 A/B 配对方式评估速度、成本、缓存和首包体验的多目标权衡。

1.1 研究假设

假设	内容	验证指标
H1	重复稳定长前缀请求中，更强的 provider/cache affinity 会提升 Token 级缓存命中率。	第二次请求 cache read tokens、Token 级命中率
H2	更高缓存命中率会降低真实响应成本，但不必然降低 TTFT 或端到端 latency。	实际成本、平均 TTFT、平均 latency/请求
H3	不同 routing sort 会改变 provider 选择，从而形成不同的成本、吞吐和时延 Pareto 前沿。	provider 分布、throughput、latency、cost

1.2 本文贡献

- 使用响应返回的 `usage.prompt_tokens` 作为真实 input token 控制变量，并允许 50 tokens 内的小幅跨平台计数波动。

- 将 prompt caching 评估扩展到成本、吞吐、E2E latency、TTFT、provider 分布、reasoning telemetry 和配对统计检验。
- 所有结论只基于响应可观测 telemetry，不把平台内部私有 routing trace 当作已观测事实。


2. 方法：实验设计、数据集构造与控制变量

2.1 数据集生成方法

数据集名称为 `controlled_cache_probe`，覆盖 4 种 routing sort、2 个平台、4 个实验组、每组 50 轮。每轮包含 first/second 两次相同 Chat Completions 请求：第一次建立或刷新缓存状态，第二次观测 cache read tokens、TTFT 和端到端响应。

业务模板覆盖稳定长上下文场景，包括 RAG 客服、Agent 工具说明、营销自动化和代码审查等高复用 prompt 结构。

2.2 控制变量方法



控制变量方法：同一 `sort/group/round` 下，两个平台 first/second 两次请求的 `usage.prompt_tokens` 各自偏差必须不超过 50 tokens。总 Input Tokens 使用响应返回的 `usage.prompt_tokens`，不使用本地 tokenizer 估算。

2.3 指标定义

指标	定义	解释方向
调用级命中率	第二次请求 <code>cache_read_tokens > 0</code> 的轮次占比	越高表示越稳定触发缓存读取
Token 级命中率	第二次请求 <code>cache read tokens</code> / 第二次请求 <code>prompt tokens</code>	越高表示输入 token 复用比例越高
实际成本	first + second 两次请求返回 <code>usage/cost</code> 的合计	越低越好
Throughput	响应 <code>completion tokens</code> / 请求 <code>latency seconds</code>	越高越好
E2E latency	每次请求完整响应耗时均值	越低越好
TTFT	streaming 下首包/首 token 到达时间均值	越低越好
Reasoning 口径	响应 <code>usage</code> 中的 <code>reasoning token</code> 字段保留为观测变量	用于解释时延、吞吐和成本，不单独作为业务产出

3. 实验环境与数据质量控制

项目	配置
模型	moonshotai/kimi-k2.5
平台实际模型 ID	infron: moonshotai/kimi-k2.5 ; openrouter: moonshotai/kimi-k2.5
平台	Infron、OpenRouter
API 协议	/v1/chat/completions
路由模式	吞吐优先、价格优先、端到端时延优先、流式 TTFT 优先
实验组	4
每组轮数	50
Workers	24
请求方式	流式 Chat Completions, 采集 TTFT
Reasoning / Thinking 控制	未显式指定 reasoning/thinking 参数; 保留模型与平台默认行为
Prompt 长度分层	short ≈1500、medium ≈8000、long ≈32000
剔除记录	1450

4. 结果： 总体指标与主要发现

路由模式	平台	严格配对轮数	总 Input Tokens	Token 级缓存命中率	实际成本	吞吐量	端到端 E2E 时延	流式 TTFT
吞吐优先	Infron	2	21804	15.26%	\$0.01313000	1.13 tok/s	3529.01 ms	3362.17 ms
吞吐优先	OpenRouter	2	21800	98.64%	\$0.00215256	3.98 tok/s	3264.43 ms	2259.22 ms
价格优先	Infron	0	0	0.00%	\$0.00000000	0.00 tok/s	0.00 ms	0.00 ms
价格优先	OpenRouter	0	0	0.00%	\$0.00000000	0.00 tok/s	0.00 ms	0.00 ms
端到端时延优先	Infron	0	0	0.00%	\$0.00000000	0.00 tok/s	0.00 ms	0.00 ms
端到端时延优先	OpenRouter	0	0	0.00%	\$0.00000000	0.00 tok/s	0.00 ms	0.00 ms
流式 TTFT 优先	Infron	73	2203077	98.84%	\$0.14219200	0.89 tok/s	6604.17 ms	6317.80 ms
流式 TTFT 优先	OpenRouter	73	2202954	99.60%	\$0.24604531	4.72 tok/s	3219.54 ms	2687.39 ms

4.1 尾延迟与显著性检验

尾延迟分位数补充均值无法表达的尾部风险。

路由模式	平台	P50 Latency	P95 Latency	P99 Latency	P50 TTFT	P95 TTFT	P99 TTFT
吞吐优先	Infron	3575.51 ms	4584.96 ms	4631.99 ms	3342.05 ms	4476.37 ms	4525.71 ms
吞吐优先	OpenRouter	3106.35 ms	5481.42 ms	5622.76 ms	2229.86 ms	3348.97 ms	3425.96 ms
价格优先	Infron	N/A	N/A	N/A	N/A	N/A	N/A
价格优先	OpenRouter	N/A	N/A	N/A	N/A	N/A	N/A
端到端时延优先	Infron	N/A	N/A	N/A	N/A	N/A	N/A
端到端时延优先	OpenRouter	N/A	N/A	N/A	N/A	N/A	N/A
流式 TTFT 优先	Infron	4544.57 ms	15517.55 ms	20824.11 ms	4335.68 ms	15382.81 ms	19942.85 ms
流式 TTFT 优先	OpenRouter	2527.21 ms	8827.67 ms	9735.58 ms	2061.95 ms	8105.85 ms	9149.96 ms

均值差使用 bootstrap 95% CI, p-value 使用 paired sign-flip permutation test。

路由模式	指标	均值差	95% CI	p-value	配对数	解释
吞吐优先	Latency: OpenRouter – Infron	-529.16 ms	-1505.05 ms to 446.73 ms	1.0000	2	正值表示 Infron latency 更低
吞吐优先	TTFT: OpenRouter – Infron	-2205.89 ms	-4205.20 ms to -206.57 ms	0.4994	2	正值表示 Infron TTFT 更低
吞吐优先	Throughput: Infron – OpenRouter	-2.8370 tok/s	-3.0554 tok/s to -2.6187 tok/s	0.4994	2	正值表示 Infron throughput 更高
吞吐优先	Cost: OpenRouter – Infron	-\$-0.00548872	-\$-0.00926436 to \$-0.00171308	0.4994	2	正值表示 Infron 成本更低
吞吐优先	Token Cache Hit: Infron – OpenRouter	-49.76 pp	-99.47 pp to -0.05 pp	0.4994	2	正值表示 Infron cache hit 更高
价格优先	Latency: OpenRouter – Infron	N/A	N/A to N/A	N/A	0	正值表示 Infron latency 更低
价格优先	TTFT: OpenRouter – Infron	N/A	N/A to N/A	N/A	0	正值表示 Infron TTFT 更低
价格优先	Throughput: Infron – OpenRouter	N/A	N/A to N/A	N/A	0	正值表示 Infron throughput 更高
价格优先	Cost: OpenRouter – Infron	N/A	N/A to N/A	N/A	0	正值表示 Infron 成本更低
价格优先	Token Cache Hit: Infron – OpenRouter	N/A	N/A to N/A	N/A	0	正值表示 Infron cache hit 更高
端到端时延优先	Latency: OpenRouter – Infron	N/A	N/A to N/A	N/A	0	正值表示 Infron latency 更低
端到端时延优先	TTFT: OpenRouter – Infron	N/A	N/A to N/A	N/A	0	正值表示 Infron TTFT 更低

路由模式	指标	均值差	95% CI	p-value	配对数	解释
端到端时延优先	Throughput: Infron – OpenRouter	N/A	N/A to N/A	N/A	0	正值表示 Infron throughput 更高
端到端时延优先	Cost: OpenRouter – Infron	N/A	N/A to N/A	N/A	0	正值表示 Infron 成本更低
端到端时延优先	Token Cache Hit: Infron – OpenRouter	N/A	N/A to N/A	N/A	0	正值表示 Infron cache hit 更高
流式 TTFT 优先	Latency: OpenRouter – Infron	-6769.25 ms	-8636.13 ms to -5068.44 ms	<0.001	73	正值表示 Infron latency 更低
流式 TTFT 优先	TTFT: OpenRouter – Infron	-7260.84 ms	-9115.20 ms to -5591.96 ms	<0.001	73	正值表示 Infron TTFT 更低
流式 TTFT 优先	Throughput: Infron – OpenRouter	-4.2878 tok/s	-5.0085 tok/s to -3.6878 tok/s	<0.001	73	正值表示 Infron throughput 更高
流式 TTFT 优先	Cost: OpenRouter – Infron	\$0.00142265	\$0.00096758 to \$0.00194698	<0.001	73	正值表示 Infron 成本更低
流式 TTFT 优先	Token Cache Hit: Infron – OpenRouter	-1.50 pp	-4.43 pp to 0.13 pp	0.2369	73	正值表示 Infron cache hit 更高

4.2 Reasoning / Thinking 控制校验

本轮未显式指定 reasoning/thinking 参数，保留模型与平台默认行为；该表记录默认行为下的 reasoning telemetry。

路由模式	平台	Reasoning Tokens	平均 Reasoning Tokens/请求	Reasoning 请求数	平均首 Reasoning Token	平均 TTFT	平均 E2E 时延
吞吐优先	Infron	0	0.0000	0	0.00 ms	3362.17 ms	3529.01 ms
吞吐优先	OpenRouter	52	13.0000	4	2259.22 ms	2259.22 ms	3264.43 ms
价格优先	Infron	0	0.0000	0	0.00 ms	0.00 ms	0.00 ms
价格优先	OpenRouter	0	0.0000	0	0.00 ms	0.00 ms	0.00 ms
端到端时延优先	Infron	0	0.0000	0	0.00 ms	0.00 ms	0.00 ms
端到端时延优先	OpenRouter	0	0.0000	0	0.00 ms	0.00 ms	0.00 ms
流式 TTFT 优先	Infron	0	0.0000	0	8054.65 ms	6317.80 ms	6604.17 ms
流式 TTFT 优先	OpenRouter	2207	15.1164	146	2687.39 ms	2687.39 ms	3219.54 ms

4.3 API 协议兼容性矩阵

本轮 API 协议为 `/v1/chat/completions`；本表记录两家平台在该协议下的成功响应、usage、成本和缓存 telemetry 覆盖。

API 协议	Endpoint	平台	配对 轮数	请求 数	成功率	Usage 覆盖	Token Usage 覆盖	成本覆盖	缓存 Telemetry 覆盖	HTTP 状
<code>chat_completions</code>	<code>/v1/chat/completions</code>	Infron	800	1600	33.62%	100.00%	100.00%	100.00%	100.00%	{"0": 1062,"20 538}
<code>chat_completions</code>	<code>/v1/chat/completions</code>	OpenRouter	800	1600	30.50%	100.00%	100.00%	100.00%	100.00%	{"0": 1112,"20 488}

5. 结果可视化：按路由模式的核心指标变化

以下图表使用同一份严格配对后的 summary 数据驱动，统一展示路由模式、平台差异、成本、缓存、端到端 E2E 时延、流式 TTFT 和上游 Provider 分布。

5.1 核心指标图表总览

以下图表使用同一份严格配对后的 summary 数据生成，统一展示路由模式、平台差异、成本、缓存、端到端 E2E 时延、流式 TTFT 和上游 Provider 分布。

图 3-E2：归一化
综合轮廓

五项指标统一转为
0-100 且越高越好。

图 3-E3：成本-缓存
效率平面

横轴为 Token 级缓存命中
率，纵轴为总实际成本。

图 3-E1：路由模式级核心指标对比
按路由模式并列展示 Infron 与 OpenRouter。

图 3-E4：端到端 E2E 时延与流式 TTFT

实线表示端到端 E2E 时延，虚线表示流式 TTFT。

图 3-E5：上游 Provider 分布

按路由模式展示主要上游路径占比。

模式级下钻图表

横轴表示相对优势百分比：右侧蓝色代表 Infron 优势，左侧橙色代表 OpenRouter 优势。

图 4-E1: Throughput First 路由模式下的核心指标对比

展示五项核心指标的相对优势方向与幅度。

图 4-E2: Price First 路由模式下的核心指标对比

展示五项核心指标的相对优势方向与幅度。

图 4-E3: Latency First 路由模式下的核心指标对比

展示五项核心指标的相对优势方向与幅度。

图 4-E4: TTFT First 路由模式下的核心指标对比

展示五项核心指标的相对优势方向与幅度。

6. Infron 技术架构与缓存/成本机制解释



6.1 多 provider 路由与可观测控制面

请求进入统一 API 后，路由策略层根据 throughput、price、latency 或 ttft 目标选择健康上游路径。稳定长前缀请求是否落在相同缓存域，会直接影响第二次请求的 cache read tokens。

6.2 Provider Stick 与 Cache Affinity

Provider stick 是缓存亲和策略，不等于固定锁死 provider。它的目标是在健康和 SLA 约束下减少缓存域碎片化，使重复 prefix 更容易复用已有缓存。

6.3 成本控制路径

机制	对 cache rate 的影响	对成本的影响	本次实验中的可观测信号
Stable prefix 识别	相同前缀更容易命中已有 cache	降低重复 prefill 的边际成本	同一 payload SHA256、第二次请求 cache read tokens
Provider stick / cache affinity	降低跨 provider/cache domain 的缓存碎片	减少重复暖缓存	provider 分布与 Token 级命中率共同变化
健康检查与 fallback	保护可用性，必要时牺牲部分缓存收益	降低失败成本	HTTP 状态、provider 分布和尾延迟变化
成本感知 routing	在健康约束下偏向低成本路径	降低总成本和每轮成本	实际成本、cost breakdown 覆盖率、cache read tokens

7. Provider/Route 下钻分析

路由模式	平台	总请求数	已归因请求数	Provider 分布
吞吐优先	Infron	4	4	novita 4
吞吐优先	OpenRouter	4	4	ModelRun 4
价格优先	Infron	0	0	未返回
价格优先	OpenRouter	0	0	未返回

路由模式	平台	总请求数	已归因请求数	Provider 分布
端到端时延优先	Infron	0	0	未返回
端到端时延优先	OpenRouter	0	0	未返回
流式 TTFT 优先	Infron	146	146	alibaba/cn 123, deepinfra 23
流式 TTFT 优先	OpenRouter	146	146	ModelRun 116, DigitalOcean 26, DeepInfra 2, SiliconFlow 2

上游 Provider 明细分布

路由模式	平台	上游 Provider	请求数	占比	first/second	覆盖轮次	Avg TTFT	Avg Latency	Prompt Tokens	Completion Tokens	Reasoning Tokens	C R T
吞吐优先	Infron	novita	4	100.00%	2/2	2	3362.17 ms	3529.01 ms	21804	16	0	12
吞吐优先	OpenRouter	ModelRun	4	100.00%	2/2	2	2259.22 ms	3264.43 ms	21800	52	52	2
价格优先	Infron	未返回	0	0.00%	0/0	0	N/A	N/A	0	0	0	0
价格优先	OpenRouter	未返回	0	0.00%	0/0	0	N/A	N/A	0	0	0	0
端到端时延优先	Infron	未返回	0	0.00%	0/0	0	N/A	N/A	0	0	0	0
端到端时延优先	OpenRouter	未返回	0	0.00%	0/0	0	N/A	N/A	0	0	0	0
流式 TTFT 优先	Infron	alibaba/cn	123	84.25%	65/58	68	6037.20 ms	6199.51 ms	1888563	492	0	18
流式 TTFT 优先	Infron	deepinfra	23	15.75%	8/15	18	7818.43 ms	8768.19 ms	314514	368	0	2
流式 TTFT 优先	OpenRouter	ModelRun	116	79.45%	61/55	61	2632.83 ms	2986.61 ms	1757551	1514	1514	17
流式 TTFT 优先	OpenRouter	DigitalOcean	26	17.81%	10/16	16	2296.73 ms	3405.60 ms	369149	416	417	3

路由模式	平台	上游 Provider	请求数	占比	first/second	覆盖轮次	Avg TTFT	Avg Latency	Prompt Tokens	Completion Tokens	Reasoning Tokens	C R T
流式 TTFT 优先	OpenRouter	DeepInfra	2	1.37%	1/1	1	11668.90 ms	11906.07 ms	72726	32	23	7
流式 TTFT 优先	OpenRouter	SiliconFlow	2	1.37%	1/1	1	1948.52 ms	5624.29 ms	3528	259	253	3

7.1 缓存命中率与实际成本反向表现下钻

该表把 cache、cost、provider 分布和 reasoning telemetry 放在同一层级，解释每个路由模式的主要差异来源。

路由模式	缓存命中差值	Infron 成本倍数	Infron 主要路径	OpenRouter 主要路径	Reasoning Tokens 差异	主要归因
吞吐优先	-83.38 pp	6.10x	novita 100.00%	ModelRun 100.00%	-52	OpenRouter 缓存更高且成本更低，主要看 provider/cache 域差异
价格优先	+0.00 pp	N/A	未返回	未返回	+0	缓存和成本方向存在分化，需结合速度指标判断
端到端时延优先	+0.00 pp	N/A	未返回	未返回	+0	缓存和成本方向存在分化，需结合速度指标判断
流式 TTFT 优先	-0.76 pp	0.58x	alibaba/cn 84.25%	ModelRun 79.45%	-2207	缓存和成本方向存在分化，需结合速度指标判断

8. 分层结果：按 Prompt 长度的缓存表现

本节按 prompt 长度 tier 聚合第二次请求的 cache read tokens、Token 级缓存命中率、实际成本、端到端时延和流式 TTFT。加粗单元表示同一长度 tier 下表现更优的一方。

Prompt 长度分层总览

Prompt 长度 tier	目标 tokens	平台	轮数	第二次 Prompt Tokens	第二次 Cache Read Tokens	Token 级命中率	实际成本	平均 E2E 时延	平均 TTFT
short	1500	Infron	27	47650	45312	95.09%	\$0.00995100	5294.39 ms	4885.33 ms
short	1500	OpenRouter	27	47628	45504	95.54%	\$0.01343926	2545.05 ms	1971.02 ms
medium	8000	Infron	25	228419	209184	91.58%	\$0.04532000	6429.55 ms	6203.25 ms

Prompt 长度 tier	目标 tokens	平台	轮数	第二次 Prompt Tokens	第二次 Cache Read Tokens	Token 级命中率	实际成本	平均 E2E 时延	平均 TTFT
medium	8000	OpenRouter	25	228400	227392	99.56%	\$0.05440489	3054.37 ms	2516.64 ms
long	32000	Infron	23	836368	835872	99.94%	\$0.10005100	8064.13 ms	7866.91 ms
long	32000	OpenRouter	23	836349	834928	99.83%	\$0.18035371	4194.78 ms	3676.69 ms

Prompt 长度 x 路由模式缓存命中率

Prompt 长度 tier	路由模式	Infron	OpenRouter	胜出方
short	吞吐优先	94.28%	94.33%	OpenRouter
short	价格优先	0.00%	0.00%	tie
short	端到端时延优先	0.00%	0.00%	tie
short	流式 TTFT 优先	95.12%	95.59%	OpenRouter
medium	吞吐优先	0.00%	99.47%	OpenRouter
medium	价格优先	0.00%	0.00%	tie
medium	端到端时延优先	0.00%	0.00%	tie
medium	流式 TTFT 优先	95.39%	99.56%	OpenRouter
long	吞吐优先	0.00%	0.00%	tie
long	价格优先	0.00%	0.00%	tie
long	端到端时延优先	0.00%	0.00%	tie
long	流式 TTFT 优先	99.94%	99.83%	Infron

9. 分层结果：按实验组的稳定性检查

吞吐优先

平台	组别	轮数	成功轮数	Token 命中率	实际成本	P95 Latency	P95 TTFT
Infron	1	0	0	0.00%	\$0.00000000	N/A	N/A
Infron	2	2	2	15.26%	\$0.01313000	4584.96 ms	4476.37 ms
Infron	3	0	0	0.00%	\$0.00000000	N/A	N/A
Infron	4	0	0	0.00%	\$0.00000000	N/A	N/A
OpenRouter	1	0	0	0.00%	\$0.00000000	N/A	N/A
OpenRouter	2	2	2	98.64%	\$0.00215256	5481.42 ms	3348.97 ms

平台	组别	轮数	成功轮数	Token 命中率	实际成本	P95 Latency	P95 TTFT
OpenRouter	3	0	0	0.00%	\$0.00000000	N/A	N/A
OpenRouter	4	0	0	0.00%	\$0.00000000	N/A	N/A

价格优先

平台	组别	轮数	成功轮数	Token 命中率	实际成本	P95 Latency	P95 TTFT
Infron	1	0	0	0.00%	\$0.00000000	N/A	N/A
Infron	2	0	0	0.00%	\$0.00000000	N/A	N/A
Infron	3	0	0	0.00%	\$0.00000000	N/A	N/A
Infron	4	0	0	0.00%	\$0.00000000	N/A	N/A
OpenRouter	1	0	0	0.00%	\$0.00000000	N/A	N/A
OpenRouter	2	0	0	0.00%	\$0.00000000	N/A	N/A
OpenRouter	3	0	0	0.00%	\$0.00000000	N/A	N/A
OpenRouter	4	0	0	0.00%	\$0.00000000	N/A	N/A

端到端时延优先

平台	组别	轮数	成功轮数	Token 命中率	实际成本	P95 Latency	P95 TTFT
Infron	1	0	0	0.00%	\$0.00000000	N/A	N/A
Infron	2	0	0	0.00%	\$0.00000000	N/A	N/A
Infron	3	0	0	0.00%	\$0.00000000	N/A	N/A
Infron	4	0	0	0.00%	\$0.00000000	N/A	N/A
OpenRouter	1	0	0	0.00%	\$0.00000000	N/A	N/A
OpenRouter	2	0	0	0.00%	\$0.00000000	N/A	N/A
OpenRouter	3	0	0	0.00%	\$0.00000000	N/A	N/A
OpenRouter	4	0	0	0.00%	\$0.00000000	N/A	N/A

流式 TTFT 优先

平台	组别	轮数	成功轮数	Token 命中率	实际成本	P95 Latency	P95 TTFT
Infron	1	3	3	99.46%	\$0.00471600	29866.65 ms	29687.25 ms
Infron	2	2	2	99.87%	\$0.00527600	4976.74 ms	4781.97 ms
Infron	3	18	18	99.57%	\$0.02929800	15322.95 ms	15190.38 ms
Infron	4	50	50	98.50%	\$0.10290200	15592.71 ms	15468.08 ms
OpenRouter	1	3	3	99.47%	\$0.01569255	3869.88 ms	3196.18 ms
OpenRouter	2	2	2	99.59%	\$0.00840456	2719.96 ms	2629.10 ms

平台	组别	轮数	成功轮数	Token 命中率	实际成本	P95 Latency	P95 TTFT
OpenRouter	3	18	18	99.57%	\$0.04695015	5050.03 ms	4569.76 ms
OpenRouter	4	50	50	99.62%	\$0.17499804	9080.67 ms	8423.71 ms

10. 讨论：业务价值、适用边界与工程启示

业务决策不应只看单一指标。稳定长上下文和高频模板请求优先关注缓存命中率与成本；实时交互应同时约束 TTFT 和端到端时延；后台批处理更重视吞吐与失败成本。

路由模式	主要业务目标	本轮数据体现	适用场景	注意事项
吞吐优先	最大化单位时间输出能力	OpenRouter 综合占优 (5/5 指标)	批量内容生成、离线摘要、后台数据加工	首包与完整响应更快，但需检查缓存和成本
价格优先	最小化单位请求和单位 token 成本	双方各有优势	高频模板化请求、客服自动化、营销触达、RAG 固定前缀	需要结合预算、SLA 和缓存稳定性决策
端到端时延优先	最小化完整响应等待时间	双方各有优势	在线聊天、Agent 调用链、IDE/写作辅助、实时运营工具	需要结合预算、SLA 和缓存稳定性决策
流式 TTFT 优先	最小化流式首包响应时间	OpenRouter 综合占优 (4/5 指标)	流式聊天、实时 Copilot、首屏反馈、长任务进度感知	首包与完整响应更快，但需检查缓存和成本

11. 结论

路由模式级结论

路由模式	目标	缓存胜出	成本胜出	吞吐胜出	E2E 时延胜出	TTFT 胜出	解读
吞吐优先	最大化单位时间输出能力	OpenRouter	OpenRouter	OpenRouter	OpenRouter	OpenRouter	OpenRouter 综合占优 (5/5 指标)
价格优先	最小化单位请求和单位 token 成本	Tie	Tie	Tie	Tie	Tie	双方各有优势
端到端时延优先	最小化完整响应等待时间	Tie	Tie	Tie	Tie	Tie	双方各有优势
流式 TTFT 优先	最小化流式首包响应时间	OpenRouter	Infron	OpenRouter	OpenRouter	OpenRouter	OpenRouter 综合占优 (4/5 指标)

12. 局限性、缺失数据与后续实验计划

缺失或不足	对结论的影响	后续补充方式	当前处理方式
完整 routing trace	无法逐跳证明每次请求的 provider 选择、fallback 和重试路径	补充 provider routing trace、decision log 和 fallback reason	只使用响应中真实返回的 provider 字段和 provider 分布

缺失或不足	对结论的影响	后续补充方式	当前处理方式
更长时间窗口	4x50 能观察短期稳定性，但不能覆盖日级波动	增加 soak test 和跨时段重复实验	报告限定在本轮窗口内解释
真实生产语料	内置模板不能覆盖全部业务分布	使用脱敏生产语料分层抽样	当前只讨论代表性长上下文业务模板
成本字段一致性	不同平台 cost 字段覆盖率和口径可能不同	结合账单回查和 provider cost breakdown	只统计响应明确返回的成本字段

13. 可复现性附录

工件	路径
Summary	export/kimi_k25_all_experiments/ routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions summary.json
配对数据集	export/kimi_k25_all_experiments/ routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions benchmark_pairs.csv
请求级数据集	export/kimi_k25_all_experiments/ routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions benchmark_requests.jsonl
过滤后结构化记录	export/kimi_k25_all_experiments/ routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions records.json
剔除记录审计	export/kimi_k25_all_experiments/ routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions records_excluded.json
测试源码	tests/test_rerun_routing_sort_cache_cost_ab.py
Benchmark 执行源码	scripts/rerun_routing_sort_cache_cost_ab.py
HTML 报告渲染源码	scripts/render_glm52_deepseek_style_report.py
数据集引用	business_representative 内置代表性业务模板；请求级导出见 benchmark_requests.jsonl