

Infron 与 OpenRouter 路由、缓存、成本与流式性能 A/B 实验报告

摘要与结论大纲

关键词: Prompt Caching; A/B Testing; Provider Routing; Cache Affinity; Latency; Throughput; Cost Attribution; moonshotai/kimi-k2.7-code

摘要

本报告以 moonshotai/kimi-k2.7-code 为对象, 对比 Infron 与 OpenRouter 在 Prompt Caching 场景下的路由策略、缓存命中、实际成本、吞吐量、TTFT 首包响应时间和端到端时延。实验包含 4 个实验组、每组 50 轮, 覆盖 4 种 routing sort 策略; 其中 TTFT First 中, Infron 使用 provider.sort=ttft, OpenRouter 使用其支持的 provider.sort=latency 作为对照。经过异常 usage、HTTP 异常和 A/B input tokens 偏差超过 50 tokens 的样本剔除后, 最终保留 800 个配对样本、3200 次请求级观测记录, 剔除 0 条记录。

核心结论是: 在 usage.prompt_tokens 偏差不超过 50 tokens 的配对样本中, Infron 在 price 和 ttft 模式下, Token 级缓存命中率更高, OpenRouter 在 throughput 和 latency 模式下, Token 级缓存命中率更高; Infron 在所有路由模式下, 实际成本都更低; Infron 在所有路由模式下, 吞吐量都更高; Infron 在 price 模式下, 时延更低, OpenRouter 在 throughput、latency 和 ttft 模式下, 时延更低; Infron 在 price 模式下, TTFT 首包响应时间更低, OpenRouter 在 throughput、latency 和 ttft 模式下, TTFT 首包响应时间更低。整体看, Infron 的优势集中在成本控制、部分模式的低时延路径, OpenRouter 的优势集中在 TTFT、部分模式的端到端时延表现。平台选择应围绕业务目标展开, 单一指标不足以代表整体效果。

本轮未显式控制 reasoning/thinking, 响应中的 reasoning tokens 作为观测变量记录。

图 0: Inference 平台“不可能四角”。吞吐量、价格、端到端时延和 TTFT 很难同时达到最优, 平台路由通常会在四个方向之间做取舍; 图中将四项归一化指标投影为路由模式点, 并将同一平台的四个点连接成区域。

图 A: 结论总览图。上方卡片概括跨路由模式的总体胜出方, 下方矩阵按 throughput、price、latency、TTFT 的路由目标顺序组织列, 金色对角线表示各路由模式目标指标的 A/B 胜出方。

结论大纲

研究维度	结论	证据位置
控制变量	进入统计的 A/B 样本满足同一 sort/group/round 下 first/second 请求 usage.prompt_tokens 各自偏差不超过 50 tokens; 各模式 Input Tokens 对照为 throughput =6260516/6260360; price =6260516/6260332; latency =6260499/6260378; ttft =6260516/6260377	方法与数据质量章节
缓存复用	Infron 在 price 和 ttft 模式下, Token 级缓存命中率更高, OpenRouter 在 throughput 和 latency 模式下, Token 级缓存命中率更高, 说明本轮 provider stick/cache affinity 已转化为可观测的缓存命中差异	结果与机制分析章节

研究维度	结论	证据位置
实际成本	Infron 在所有路由模式下，实际成本都更低，成本差异与 cache read tokens 同向变化	结果与结论章节
性能表现	Infron 在所有路由模式下，吞吐量都更高；Infron 在 price 模式下，时延更低，OpenRouter 在 throughput、latency 和 ttft 模式下，时延更低；Infron 在 price 模式下，TTFT 首包响应时间更低，OpenRouter 在 throughput、latency 和 ttft 模式下，TTFT 首包响应时间更低	结果可视化与结论章节
Reasoning 控制	本轮未显式控制 reasoning/thinking，响应中的 reasoning tokens 作为观测变量记录。	Reasoning / Thinking 控制校验章节
归因边界	报告只使用响应可观测 telemetry，包括 provider 字段、usage、cost breakdown、TTFT、latency 和 cache tokens；未把平台内部私有 routing trace 当作已观测事实	机制分析、下钻分析与局限性章节
业务含义	对稳定长上下文、RAG 前缀、Agent 工具说明和批处理任务，缓存命中率与成本可预测性是核心收益；对实时交互任务，latency 仍需作为独立约束	讨论与结论章节

路由模式级结论

Throughput First

指标	Infron / OpenRouter 并列对比	胜出方
缓存命中率	Infron 95.46% OpenRouter 97.60%	OpenRouter (高 2.24%)
实际成本	Infron \$0.98032600 OpenRouter \$2.01653450	Infron (低 51.39%)
Throughput	Infron 5.37 tok/s OpenRouter 5.15 tok/s	Infron (高 4.19%)
Latency	Infron 5605.98 ms OpenRouter 2759.59 ms	OpenRouter (低 50.77%)
TTFT	Infron 4769.42 ms OpenRouter 2593.43 ms	OpenRouter (低 45.62%)

Price First

指标	Infron / OpenRouter 并列对比	胜出方
缓存命中率	Infron 98.29% OpenRouter 92.95%	Infron (高 5.74%)
实际成本	Infron \$0.94488100 OpenRouter \$1.80949315	Infron (低 47.78%)
Throughput	Infron 4.29 tok/s OpenRouter 1.37 tok/s	Infron (高 213.30%)
Latency	Infron 6081.99 ms OpenRouter 10768.47 ms	Infron (低 43.52%)

指标	Infron / OpenRouter 并列对比	胜出方
TTFT	Infron 5360.05 ms OpenRouter 9952.85 ms	Infron (低 46.15%)

Latency First

指标	Infron / OpenRouter 并列对比	胜出方
缓存命中率	Infron 91.64% OpenRouter 97.46%	OpenRouter (高 6.35%)
实际成本	Infron \$1.40999200 OpenRouter \$1.62574241	Infron (低 13.27%)
Throughput	Infron 2.41 tok/s OpenRouter 2.00 tok/s	Infron (高 20.29%)
Latency	Infron 8638.23 ms OpenRouter 7154.68 ms	OpenRouter (低 17.17%)
TTFT	Infron 7891.78 ms OpenRouter 6888.81 ms	OpenRouter (低 12.71%)

TTFT First

指标	Infron / OpenRouter 并列对比	胜出方
缓存命中率	Infron 99.83% OpenRouter 99.78%	Infron (高 0.05%)
实际成本	Infron \$0.94184500 OpenRouter \$1.56776450	Infron (低 39.92%)
Throughput	Infron 2.87 tok/s OpenRouter 2.08 tok/s	Infron (高 37.52%)
Latency	Infron 7862.92 ms OpenRouter 6955.34 ms	OpenRouter (低 11.54%)
TTFT	Infron 7231.29 ms OpenRouter 6741.56 ms	OpenRouter (低 6.77%)

说明：每个区块对应一种路由模式；同一指标行内的 Infron 与 OpenRouter 柱条按两者最大值归一化。缓存命中率和 throughput 越高越好，实际成本、latency 和 TTFT 越低越好。

可复现性链接

- Summary: <<https://github.com/InfronAI/prompt-cache-bench/blob/main/experiments/moonshotai/kimi-k2.7-code/infron-vs-openrouter-routing-sort-cache-cost-4x50-stream-ttft-reasoning-default-length-tiers-chat-completions-2026-07-10/data/summary.json>>
- 配对数据集 CSV: <https://github.com/InfronAI/prompt-cache-bench/blob/main/experiments/moonshotai/kimi-k2.7-code/infron-vs-openrouter-routing-sort-cache-cost-4x50-stream-ttft-reasoning-default-length-tiers-chat-completions-2026-07-10/data/benchmark_pairs.csv>

- 请求级数据集 JSONL: <https://github.com/InfronAI/prompt-cache-bench/blob/main/experiments/moonshotai/kimi-k2.7-code/infron-vs-openrouter-routing-sort-cache-cost-4x50-stream-ttft-reasoning-default-length-tiers-chat-completions-2026-07-10/data/benchmark_requests.jsonl>
- 过滤后结构化记录: <<https://github.com/InfronAI/prompt-cache-bench/blob/main/experiments/moonshotai/kimi-k2.7-code/infron-vs-openrouter-routing-sort-cache-cost-4x50-stream-ttft-reasoning-default-length-tiers-chat-completions-2026-07-10/data/records.json>>
- 剔除记录审计: <https://github.com/InfronAI/prompt-cache-bench/blob/main/experiments/moonshotai/kimi-k2.7-code/infron-vs-openrouter-routing-sort-cache-cost-4x50-stream-ttft-reasoning-default-length-tiers-chat-completions-2026-07-10/data/records_excluded.json>
- Benchmark 执行源码: <https://github.com/InfronAI/prompt-cache-bench/blob/main/experiments/moonshotai/kimi-k2.7-code/infron-vs-openrouter-routing-sort-cache-cost-4x50-stream-ttft-reasoning-default-length-tiers-chat-completions-2026-07-10/code/rerun_routing_sort_cache_cost_ab.py>
- HTML 报告渲染源码: <https://github.com/InfronAI/prompt-cache-bench/blob/main/experiments/moonshotai/kimi-k2.7-code/infron-vs-openrouter-routing-sort-cache-cost-4x50-stream-ttft-reasoning-default-length-tiers-chat-completions-2026-07-10/code/render_glm52_deepseek_style_report.py>
- 测试源码: <https://github.com/InfronAI/prompt-cache-bench/blob/main/experiments/moonshotai/kimi-k2.7-code/infron-vs-openrouter-routing-sort-cache-cost-4x50-stream-ttft-reasoning-default-length-tiers-chat-completions-2026-07-10/code/test_rerun_routing_sort_cache_cost_ab.py>
- A/B 报告标准: <<https://github.com/InfronAI/prompt-cache-bench/blob/main/experiments/moonshotai/kimi-k2.7-code/infron-vs-openrouter-routing-sort-cache-cost-4x50-stream-ttft-reasoning-default-length-tiers-chat-completions-2026-07-10/code/ab-report-standard.md>>
- 数据目录: <<https://github.com/InfronAI/prompt-cache-bench/tree/main/experiments/moonshotai/kimi-k2.7-code/infron-vs-openrouter-routing-sort-cache-cost-4x50-stream-ttft-reasoning-default-length-tiers-chat-completions-2026-07-10/data>>
- 代码快照: <<https://github.com/InfronAI/prompt-cache-bench/tree/main/experiments/moonshotai/kimi-k2.7-code/infron-vs-openrouter-routing-sort-cache-cost-4x50-stream-ttft-reasoning-default-length-tiers-chat-completions-2026-07-10/code>>
- English HTML 报告: <https://infronai.github.io/prompt-cache-bench/experiments/moonshotai/kimi-k2.7-code/infron-vs-openrouter-routing-sort-cache-cost-4x50-stream-ttft-reasoning-default-length-tiers-chat-completions-2026-07-10/reports/routing-cache-cost-streaming-performance-ab-study__kimi-k2-7-code__infron-vs-openrouter__4x50-stream-ttft-reasoning-default-length-tiers-chat-completions__2026-07-10.en.html>
- 中文 HTML 报告: <https://infronai.github.io/prompt-cache-bench/experiments/moonshotai/kimi-k2.7-code/infron-vs-openrouter-routing-sort-cache-cost-4x50-stream-ttft-reasoning-default-length-tiers-chat-completions-2026-07-10/reports/routing-cache-cost-streaming-performance-ab-study__kimi-k2-7-code__infron-vs-openrouter__4x50-stream-ttft-reasoning-default-length-tiers-chat-completions__2026-07-10.zh.html>