

Infron 与 OpenRouter 路由、缓存、成本与流式性能 A/B 实验报告

摘要与结论大纲

关键词: Prompt Caching; A/B Testing; Provider Routing; Cache Affinity; Latency; Throughput; Cost Attribution; qwen3-next-80b-a3b-instruct

摘要

本报告以 `qwen/qwen3-next-80b-a3b-instruct` 为对象, 评估 Infron 与 OpenRouter 在 Prompt Caching 场景下的缓存复用、实际成本、吞吐、端到端时延和流式 TTFT 表现。

核心结论是: Infron 在 0/4 个路由模式下缓存命中率占优, OpenRouter 在 2/4 个路由模式下占优, 2/4 个路由模式持平; Infron 在所有路由模式下实际成本占优; Infron 在 1/4 个路由模式下吞吐量占优, OpenRouter 在 3/4 个路由模式下占优, 0/4 个路由模式持平; Infron 在 1/4 个路由模式下端到端 E2E 时延占优, OpenRouter 在 3/4 个路由模式下占优, 0/4 个路由模式持平; Infron 在 1/4 个路由模式下流式 TTFT 占优, OpenRouter 在 3/4 个路由模式下占优, 0/4 个路由模式持平。

整体看, Infron 的跨模式优势主要体现在实际成本, OpenRouter 的跨模式优势主要体现在吞吐、流式 TTFT、端到端 E2E 时延、缓存复用。平台选择不应只看单一指标, 而应按业务目标在成本、缓存稳定性、吞吐和交互时延之间取舍。

图 0：核心能力归一化雷达图

五个雷达轴分别代表吞吐量、价格、端到端 E2E 时延、流式 TTFT 和缓存命中率。所有指标统一转为 0-100 分，且越外侧越好。

粗实线表示平台综合轮廓，半透明细线和点表示各路由模式下的表现。

结论总览：核心指标与路由模式胜出方

基于严格 A/B 配对样本。蓝色代表 Infron，橙色代表 OpenRouter；金色单元格表示该路由模式的目标指标胜出方。

吞吐量 OpenRouter 3/4 胜出 最大优势 2.02%，越高越好	实际成本 Infron 4/4 胜出 最大优势 98.09%，越低越好	端到端 E2E 时延 OpenRouter 3/4 胜出 最大优势 130.58%，越低越好	流式 TTFT OpenRouter 3/4 胜出 最大优势 135.42%，越低越好	缓存命中率 双方 4/4 持平 最大优势 0.00%，越高越好
--	--	---	--	--

路由模式	吞吐目标	成本目标	时延目标	TTFT 目标	缓存结果
吞吐优先 throughput	OpenRouter 优势 2.02%	Infron 优势 98.09%	OpenRouter 优势 130.58%	OpenRouter 优势 135.42%	Tie 持平
价格优先 price	Infron 优势 59.17%	Infron 优势 21.59%	Infron 优势 107.74%	Infron 优势 31.55%	Tie 持平
端到端时延优先 latency	OpenRouter 优势 44.48%	Infron 优势 94.25%	OpenRouter 优势 9.60%	OpenRouter 优势 7.77%	OpenRouter 优势 0.00%
流式 TTFT 优先 tft	OpenRouter 优势 68.94%	Infron 优势 89.62%	OpenRouter 优势 27.77%	OpenRouter 优势 28.89%	OpenRouter 优势 0.00%

结论大纲

研究维度	结论	证据位置
控制变量	同一 sort/group/round 下 first/second usage.prompt_tokens 偏差不超过 50 tokens；总 Input Tokens 使用响应 telemetry。	方法与数据质量章节
缓存复用	Infron 在 0/4 个路由模式下缓存命中率占优，OpenRouter 在 2/4 个路由模式下占优，2/4 个路由模式持平	总体指标与机制解释章节
实际成本	Infron 在所有路由模式下实际成本占优	总体指标与 Provider 下钻章节
性能表现	Infron 在 1/4 个路由模式下吞吐量占优，OpenRouter 在 3/4 个路由模式下占优，0/4 个路由模式持平；Infron 在 1/4 个路由模式下端到端 E2E 时延占优，OpenRouter 在 3/4 个路由模式下占优，0/4 个路由模式持平；Infron 在 1/4 个路由模式下流式 TTFT 占优，OpenRouter 在 3/4 个路由模式下占优，0/4 个路由模式持平	结果可视化与统计检验章节
归因边界	报告只使用响应中可观测的 usage、cost、TTFT、latency、provider 字段和 cache tokens。	Provider/Route 下钻分析章节

研究维度	结论	证据位置
业务含义	长上下文、RAG 前缀、Agent 工具说明和高频模板请求应同时关注缓存命中率、成本、首包和端到端时延。	讨论与结论章节

路由模式级结论

路由模式	目标	缓存胜出	成本胜出	吞吐胜出	E2E 时延胜出	TTFT 胜出	解读
吞吐优先	最大化单位时间输出能力	Tie	Infron	OpenRouter	OpenRouter	OpenRouter	OpenRouter 综合占优 (3/5 指标)
价格优先	最小化单位请求和单位 token 成本	Tie	Infron	Infron	Infron	Infron	Infron 综合占优 (4/5 指标)
端到端时延优先	最小化完整响应等待时间	OpenRouter	Infron	OpenRouter	OpenRouter	OpenRouter	OpenRouter 综合占优 (4/5 指标)
流式 TTFT 优先	最小化流式首包响应时间	OpenRouter	Infron	OpenRouter	OpenRouter	OpenRouter	OpenRouter 综合占优 (4/5 指标)

1. 引言：背景、研究问题与贡献

LLM 推理平台的真实性能不仅由模型决定，也由 provider 路由、提示词缓存、流式响应、成本归因和 fallback 策略共同决定。本报告把平台视为可观测系统，以 A/B 配对方式评估速度、成本、缓存和首包体验的多目标权衡。

1.1 研究假设

假设	内容	验证指标
H1	重复稳定长前缀请求中，更强的 provider/cache affinity 会提升 Token 级缓存命中率。	第二次请求 cache read tokens、Token 级命中率
H2	更高缓存命中率会降低真实响应成本，但不必然降低 TTFT 或端到端 latency。	实际成本、平均 TTFT、平均 latency/请求
H3	不同 routing sort 会改变 provider 选择，从而形成不同的成本、吞吐和时延 Pareto 前沿。	provider 分布、throughput、latency、cost

1.2 本文贡献

- 使用响应返回的 `usage.prompt_tokens` 作为真实 input token 控制变量，并允许 50 tokens 内的小幅跨平台计数波动。
- 将 prompt caching 评估扩展到成本、吞吐、E2E latency、TTFT、provider 分布、reasoning telemetry 和配对统计检验。

- 所有结论只基于响应可观测 telemetry，不把平台内部私有 routing trace 当作已观测事实。


2. 方法：实验设计、数据集构造与控制变量

2.1 数据集生成方法

数据集名称为 `controlled_cache_probe`，覆盖 4 种 routing sort、2 个平台、4 个实验组、每组 50 轮。每轮包含 first/second 两次相同 Chat Completions 请求：第一次建立或刷新缓存状态，第二次观测 cache read tokens、TTFT 和端到端响应。

业务模板覆盖稳定长上下文场景，包括 RAG 客服、Agent 工具说明、营销自动化和代码审查等高复用 prompt 结构。

2.2 控制变量方法



控制变量方法：同一 `sort/group/round` 下，两个平台 first/second 两次请求的 `usage.prompt_tokens` 各自偏差必须不超过 50 tokens。总 Input Tokens 使用响应返回的 `usage.prompt_tokens`，不使用本地 tokenizer 估算。

2.3 指标定义

指标	定义	解释方向
调用级命中率	第二次请求 <code>cache_read_tokens > 0</code> 的轮次占比	越高表示越稳定触发缓存读取
Token 级命中率	第二次请求 <code>cache read tokens / 第二次请求 prompt tokens</code>	越高表示输入 token 复用比例越高
实际成本	first + second 两次请求返回 <code>usage/cost</code> 的合计	越低越好
Throughput	响应 <code>completion tokens / 请求 latency seconds</code>	越高越好
E2E latency	每次请求完整响应耗时均值	越低越好
TTFT	streaming 下首包/首 token 到达时间均值	越低越好
Reasoning 口径	响应 <code>usage</code> 中的 <code>reasoning token</code> 字段保留为观测变量	用于解释时延、吞吐和成本，不单独作为业务产出

3. 实验环境与数据质量控制

项目	配置
模型	qwen/qwen3-next-80b-a3b-instruct
平台实际模型 ID	infron: qwen/qwen3-next-80b-a3b-instruct ; openrouter: qwen/qwen3-next-80b-a3b-instruct
平台	Infron、OpenRouter
API 协议	/v1/chat/completions
路由模式	吞吐优先、价格优先、端到端时延优先、流式 TTFT 优先
实验组	4
每组轮数	50
Workers	24
请求方式	流式 Chat Completions, 采集 TTFT
Reasoning / Thinking 控制	未显式指定 reasoning/thinking 参数; 保留模型与平台默认行为
Prompt 长度分层	short ≈1500、medium ≈8000、long ≈32000
剔除记录	14

4. 结果：总体指标与主要发现

路由模式	平台	严格配对轮数	总 Input Tokens	Token 级缓存命中率	实际成本	吞吐量	端到端 E2E 时延	流式 TTFT
吞吐优先	Infron	196	6808718	0.00%	\$0.50653900	0.58 tok/s	5184.23 ms	4972.69 ms
吞吐优先	OpenRouter	196	6808718	0.00%	\$1.00339906	1.75 tok/s	2248.38 ms	2112.23 ms
价格优先	Infron	199	6993788	0.00%	\$0.52312900	0.95 tok/s	3155.45 ms	2988.21 ms
价格优先	OpenRouter	199	6993788	0.00%	\$0.63608411	0.60 tok/s	6555.00 ms	3931.02 ms
端到端时延优先	Infron	199	6993788	0.00%	\$0.52877600	0.95 tok/s	3190.53 ms	2949.53 ms
端到端时延优先	OpenRouter	199	6993788	4.15%	\$1.02712370	1.37 tok/s	2911.03 ms	2736.88 ms
流式 TTFT 优先	Infron	199	6993788	0.00%	\$0.52771800	0.94 tok/s	3217.63 ms	3038.02 ms
流式 TTFT 优先	OpenRouter	199	6993788	8.35%	\$1.00066019	1.59 tok/s	2518.37 ms	2357.02 ms

4.1 尾延迟与显著性检验

尾延迟分位数补充均值无法表达的尾部风险。

路由模式	平台	P50 Latency	P95 Latency	P99 Latency	P50 TTFT	P95 TTFT	P99 TTFT
吞吐优先	Infron	2956.76 ms	20035.53 ms	50249.60 ms	2744.43 ms	19643.82 ms	50096.43 ms
吞吐优先	OpenRouter	2102.93 ms	3296.77 ms	4321.05 ms	1980.08 ms	3036.83 ms	3875.76 ms
价格优先	Infron	2663.26 ms	5692.40 ms	7365.39 ms	2470.18 ms	5453.06 ms	7122.57 ms
价格优先	OpenRouter	6553.93 ms	9569.13 ms	16845.84 ms	3557.95 ms	7327.31 ms	9054.06 ms
端到端时延优先	Infron	2867.81 ms	5614.51 ms	6958.13 ms	2596.48 ms	5037.12 ms	6535.45 ms
端到端时延优先	OpenRouter	2592.89 ms	5074.47 ms	8870.71 ms	2442.70 ms	4477.98 ms	8866.02 ms
流式 TTFT 优先	Infron	2874.59 ms	5337.00 ms	7121.96 ms	2656.78 ms	4956.22 ms	6899.57 ms
流式 TTFT 优先	OpenRouter	2387.41 ms	4141.73 ms	4911.39 ms	2231.37 ms	3585.24 ms	4849.19 ms

均值差使用 bootstrap 95% CI, p-value 使用 paired sign-flip permutation test。

路由模式	指标	均值差	95% CI	p-value	配对数	解释
吞吐优先	Latency: OpenRouter – Infron	-5871.72 ms	-7879.69 ms to -4134.11 ms	<0.001	196	正值表示 Infron latency 更低
吞吐优先	TTFT: OpenRouter – Infron	-5720.93 ms	-7729.48 ms to -3985.93 ms	<0.001	196	正值表示 Infron TTFT 更低
吞吐优先	Throughput: Infron – OpenRouter	-0.8962 tok/s	-0.9707 tok/s to -0.8253 tok/s	<0.001	196	正值表示 Infron throughput 更高
吞吐优先	Cost: OpenRouter – Infron	\$0.00253500	\$0.00220121 to \$0.00288778	<0.001	196	正值表示 Infron 成本更低
吞吐优先	Token Cache Hit: Infron – OpenRouter	0.00 pp	0.00 pp to 0.00 pp	1.0000	196	正值表示 Infron cache hit 更高
价格优先	Latency: OpenRouter – Infron	6799.09 ms	6136.33 ms to 7459.24 ms	<0.001	199	正值表示 Infron latency 更低
价格优先	TTFT: OpenRouter – Infron	1885.62 ms	1354.79 ms to 2385.67 ms	<0.001	199	正值表示 Infron TTFT 更低
价格优先	Throughput: Infron – OpenRouter	0.4544 tok/s	0.4004 tok/s to 0.5084 tok/s	<0.001	199	正值表示 Infron throughput 更高
价格优先	Cost: OpenRouter – Infron	\$0.00056761	\$0.00049651 to \$0.00064362	<0.001	199	正值表示 Infron 成本更低
价格优先	Token Cache Hit: Infron – OpenRouter	0.00 pp	0.00 pp to 0.00 pp	1.0000	199	正值表示 Infron cache hit 更高
端到端时延优先	Latency: OpenRouter – Infron	-558.98 ms	-958.23 ms to -144.12 ms	0.0047	199	正值表示 Infron latency 更低
端到端时延优先	TTFT: OpenRouter – Infron	-425.31 ms	-799.83 ms to -17.22 ms	0.0275	199	正值表示 Infron TTFT 更低

路由模式	指标	均值差	95% CI	p-value	配对数	解释
端到端时延优先	Throughput: Infron – OpenRouter	–0.5006 tok/s	–0.5607 tok/s to –0.4439 tok/s	<0.001	199	正值表示 Infron throughput 更高
端到端时延优先	Cost: OpenRouter – Infron	\$0.00250426	\$0.00216994 to \$0.00286112	<0.001	199	正值表示 Infron 成本更低
端到端时延优先	Token Cache Hit: Infron – OpenRouter	–3.27 pp	–5.90 pp to –0.98 pp	0.0162	199	正值表示 Infron cache hit 更高
流式 TTFT 优先	Latency: OpenRouter – Infron	–1398.51 ms	–1642.75 ms to –1147.43 ms	<0.001	199	正值表示 Infron latency 更低
流式 TTFT 优先	TTFT: OpenRouter – Infron	–1362.00 ms	–1607.44 ms to –1116.06 ms	<0.001	199	正值表示 Infron TTFT 更低
流式 TTFT 优先	Throughput: Infron – OpenRouter	–0.6766 tok/s	–0.7220 tok/s to –0.6302 tok/s	<0.001	199	正值表示 Infron throughput 更高
流式 TTFT 优先	Cost: OpenRouter – Infron	\$0.00237659	\$0.00203795 to \$0.00273003	<0.001	199	正值表示 Infron 成本更低
流式 TTFT 优先	Token Cache Hit: Infron – OpenRouter	–6.96 pp	–10.60 pp to –3.69 pp	<0.001	199	正值表示 Infron cache hit 更高

4.2 Reasoning / Thinking 控制校验

本轮未显式指定 reasoning/thinking 参数，保留模型与平台默认行为；该表记录默认行为下的 reasoning telemetry。

路由模式	平台	Reasoning Tokens	平均 Reasoning Tokens/请求	Reasoning 请求数	平均首 Reasoning Token	平均 TTFT	平均 E2E 时延
吞吐优先	Infron	0	0.0000	0	0.00 ms	4972.69 ms	5184.23 ms
吞吐优先	OpenRouter	0	0.0000	0	0.00 ms	2112.23 ms	2248.38 ms
价格优先	Infron	0	0.0000	0	0.00 ms	2988.21 ms	3155.45 ms
价格优先	OpenRouter	0	0.0000	0	0.00 ms	3931.02 ms	6555.00 ms
端到端时延优先	Infron	0	0.0000	0	0.00 ms	2949.53 ms	3190.53 ms
端到端时延优先	OpenRouter	0	0.0000	0	0.00 ms	2736.88 ms	2911.03 ms
流式 TTFT 优先	Infron	0	0.0000	0	0.00 ms	3038.02 ms	3217.63 ms

路由模式	平台	Reasoning Tokens	平均 Reasoning Tokens/请求	Reasoning 请求数	平均首 Reasoning Token	平均 TTFT	平均 E2E 时延
流式 TTFT 优先	OpenRouter	0	0.0000	0	0.00 ms	2357.02 ms	2518.37 ms

4.3 API 协议兼容性矩阵

本轮 API 协议为 /v1/chat/completions；本表记录两家平台在该协议下的成功响应、usage、成本和缓存 telemetry 覆盖。

API 协议	Endpoint	平台	配对轮数	请求数	成功率	Usage 覆盖	Token Usage 覆盖	成本覆盖	缓存 Telemetry 覆盖	HTTP 状态
chat_completions	/v1/chat/completions	Infron	800	1600	99.62%	100.00%	100.00%	100.00%	100.00%	{"0": 6,"200": 1594}
chat_completions	/v1/chat/completions	OpenRouter	800	1600	99.94%	100.00%	100.00%	100.00%	100.00%	{"0": 1,"200": 1599}

5. 结果可视化：按路由模式的核心指标变化

以下图表使用同一份严格配对后的 summary 数据驱动，统一展示路由模式、平台差异、成本、缓存、端到端 E2E 时延、流式 TTFT 和上游 Provider 分布。

5.1 核心指标图表总览

以下图表使用同一份严格配对后的 summary 数据生成，统一展示路由模式、平台差异、成本、缓存、端到端 E2E 时延、流式 TTFT 和上游 Provider 分布。

图 3-E2：归一化
综合轮廓

五项指标统一转为
0-100 且越高越好。

图 3-E3：成本-缓存
效率平面

横轴为 Token 级缓存命中
率，纵轴为总实际成本。

图 3-E1：路由模式级核心指标对比
按路由模式并列展示 Infron 与 OpenRouter。

图 3-E4：端到端 E2E 时延与流式 TTFT

实线表示端到端 E2E 时延，虚线表示流式 TTFT。

图 3-E5：上游 Provider 分布

按路由模式展示主要上游路径占比。

模式级下钻图表

横轴表示相对优势百分比：右侧蓝色代表 Infron 优势，左侧橙色代表 OpenRouter 优势。

图 4-E1: Throughput First 路由模式下的核心指标对比

展示五项核心指标的相对优势方向与幅度。

图 4-E2: Price First 路由模式下的核心指标对比

展示五项核心指标的相对优势方向与幅度。

图 4-E3: Latency First 路由模式下的核心指标对比

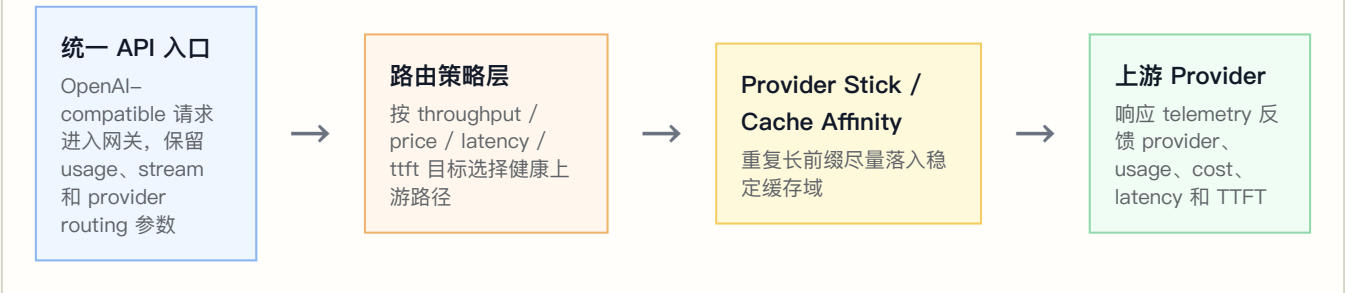
展示五项核心指标的相对优势方向与幅度。

图 4-E4: TTFT First 路由模式下的核心指标对比

展示五项核心指标的相对优势方向与幅度。

6. Infron 技术架构与缓存/成本机制解释

图 12: Infron 多 provider 路由与缓存控制面



6.1 多 provider 路由与可观测控制面

请求进入统一 API 后，路由策略层根据 throughput、price、latency 或 tftt 目标选择健康上游路径。稳定长前缀请求是否落在相同缓存域，会直接影响第二次请求的 cache read tokens。

6.2 Provider Stick 与 Cache Affinity

Provider stick 是缓存亲和策略，不等于固定锁死 provider。它的目标是在健康和 SLA 约束下减少缓存域碎片化，使重复 prefix 更容易复用已有缓存。

6.3 成本控制路径

机制	对 cache rate 的影响	对成本的影响	本次实验中的可观测信号
Stable prefix 识别	相同前缀更容易命中已有 cache	降低重复 prefill 的边际成本	同一 payload SHA256、第二次请求 cache read tokens
Provider stick / cache affinity	降低跨 provider/cache domain 的缓存碎片	减少重复暖缓存	provider 分布与 Token 级命中率共同变化
健康检查与 fallback	保护可用性，必要时牺牲部分缓存收益	降低失败成本	HTTP 状态、provider 分布和尾延迟变化
成本感知 routing	在健康约束下偏向低成本路径	降低总成本和每轮成本	实际成本、cost breakdown 覆盖率、cache read tokens

7. Provider/Route 下钻分析

路由模式	平台	总请求数	已归因请求数	Provider 分布
吞吐优先	Infron	392	392	alibaba/sg 261, alibaba/us 75, alibaba/cn 53, deepinfra 3
吞吐优先	OpenRouter	392	392	Google 370, Alibaba 22
价格优先	Infron	398	398	alibaba/sg 327, alibaba/us 66, deepinfra 5
价格优先	OpenRouter	398	398	DeepInfra 371, Alibaba 27

路由模式	平台	总请求数	已归因请求数	Provider 分布
端到端时延优先	Infron	398	398	alibaba/sg 385, deepinfra 13
端到端时延优先	OpenRouter	398	398	Google 384, Parasail 14
流式 TTFT 优先	Infron	398	398	alibaba/sg 388, deepinfra 10
流式 TTFT 优先	OpenRouter	398	398	Google 365, Parasail 33

上游 Provider 明细分布

路由模式	平台	上游 Provider	请求数	占比	first/second	覆盖轮次	Avg TTFT	Avg Latency	Prompt Tokens	Completion Tokens	Reasoning Tokens	Cad Rea Tok
吞吐优先	Infron	alibaba/sg	261	66.58%	126/135	138	2530.39ms	2697.00ms	4686618	783	0	0
吞吐优先	Infron	alibaba/us	75	19.13%	41/34	41	3758.29ms	3881.56ms	1148242	225	0	0
吞吐优先	Infron	alibaba/cn	53	13.52%	29/24	36	18772.90ms	19283.08ms	889659	159	0	0
吞吐优先	Infron	deepinfra	3	0.77%	0/3	3	4009.01ms	5060.31ms	84199	12	0	0
吞吐优先	OpenRouter	Google	370	94.39%	185/185	194	2099.79ms	2238.41ms	6432792	1480	0	0
吞吐优先	OpenRouter	Alibaba	22	5.61%	11/11	20	2321.36ms	2416.05ms	375926	66	0	0
价格优先	Infron	alibaba/sg	327	82.16%	163/164	176	2748.39ms	2914.26ms	5791943	981	0	0
价格优先	Infron	alibaba/us	66	16.58%	34/32	43	4165.89ms	4320.57ms	1127777	198	0	0
价格优先	Infron	deepinfra	5	1.26%	2/3	5	3127.10ms	3550.16ms	74068	20	0	0
价格优先	OpenRouter	DeepInfra	371	93.22%	183/188	199	3980.12ms	6787.40ms	6334107	1484	0	0
价格优先	OpenRouter	Alibaba	27	6.78%	16/11	27	3256.37ms	3361.58ms	659681	81	0	0
端到端时延优先	Infron	alibaba/sg	385	96.73%	195/190	198	2935.31ms	3166.78ms	6778119	1155	0	0

路由模式	平台	上游 Provider	请求数	占比	first/second	覆盖轮次	Avg TTFT	Avg Latency	Prompt Tokens	Completion Tokens	Reasoning Tokens	Cache Read Tokens
端到端时延优先	Infron	deepinfra	13	3.27%	4/9	12	3370.71 ms	3893.94 ms	215669	52	0	0
端到端时延优先	OpenRouter	Google	384	96.48%	193/191	196	2723.43 ms	2899.30 ms	6658786	1536	0	0
端到端时延优先	OpenRouter	Parasail	14	3.52%	6/8	11	3105.56 ms	3232.86 ms	335002	56	0	236
流式 TTFT 优先	Infron	alibaba/sg	388	97.49%	194/194	199	3007.16 ms	3170.11 ms	6848208	1164	0	0
流式 TTFT 优先	Infron	deepinfra	10	2.51%	5/5	10	4235.33 ms	5061.04 ms	145580	40	0	0
流式 TTFT 优先	OpenRouter	Google	365	91.71%	183/182	186	2347.05 ms	2507.22 ms	6336279	1460	0	0
流式 TTFT 优先	OpenRouter	Parasail	33	8.29%	16/17	20	2467.34 ms	2641.71 ms	657509	132	0	580

7.1 缓存命中率与实际成本反向表现下钻

该表把 cache、cost、provider 分布和 reasoning telemetry 放在同一层级，解释每个路由模式的主要差异来源。

路由模式	缓存命中差值	Infron 成本倍数	Infron 主要路径	OpenRouter 主要路径	Reasoning Tokens 差异	主要归因
吞吐优先	+0.00 pp	0.50x	alibaba/sg 66.58%	Google 94.39%	+0	双方缓存持平，Infron 成本占优
价格优先	+0.00 pp	0.82x	alibaba/sg 82.16%	DeepInfra 93.22%	+0	双方缓存持平，Infron 成本占优
端到端时延优先	-4.15 pp	0.51x	alibaba/sg 96.73%	Google 96.48%	+0	缓存和成本方向存在分化，需结合速度指标判断
流式 TTFT 优先	-8.35 pp	0.53x	alibaba/sg 97.49%	Google 91.71%	+0	缓存和成本方向存在分化，需结合速度指标判断

8. 分层结果：按 Prompt 长度的缓存表现

本节按 prompt 长度 tier 聚合第二次请求的 cache read tokens、Token 级缓存命中率、实际成本、端到端时延和流式 TTFT。加粗单元表示同一长度 tier 下表现更优的一方。

Prompt 长度分层总览

Prompt 长度 tier	目标 tokens	平台	轮数	第二次 Prompt Tokens	第二次 Cache Read Tokens	Token 级命中率	实际成本	平均 E2E 时延	平均 TTFT
short	1500	Infron	268	533272	0	0.00%	\$0.08124100	2405.17 ms	2215.13 ms
short	1500	OpenRouter	268	533272	11424	2.14%	\$0.14393625	2869.80 ms	2042.66 ms
medium	8000	Infron	267	2756727	0	0.00%	\$0.41399600	3183.35 ms	2998.93 ms
medium	8000	OpenRouter	267	2756727	58752	2.13%	\$0.73276781	3541.90 ms	2662.11 ms
long	32000	Infron	258	10605042	0	0.00%	\$1.59092500	5522.19 ms	5296.33 ms
long	32000	OpenRouter	258	10605042	367200	3.46%	\$2.79056300	4305.37 ms	3688.91 ms

Prompt 长度 x 路由模式缓存命中率

Prompt 长度 tier	路由模式	Infron	OpenRouter	胜出方
short	吞吐优先	0.00%	0.00%	tie
short	价格优先	0.00%	0.00%	tie
short	端到端时延优先	0.00%	2.45%	OpenRouter
short	流式 TTFT 优先	0.00%	6.12%	OpenRouter
medium	吞吐优先	0.00%	0.00%	tie
medium	价格优先	0.00%	0.00%	tie
medium	端到端时延优先	0.00%	2.83%	OpenRouter
medium	流式 TTFT 优先	0.00%	5.66%	OpenRouter
long	吞吐优先	0.00%	0.00%	tie
long	价格优先	0.00%	0.00%	tie
long	端到端时延优先	0.00%	4.58%	OpenRouter
long	流式 TTFT 优先	0.00%	9.16%	OpenRouter

9. 分层结果：按实验组的稳定性检查

吞吐优先

平台	组别	轮数	成功轮数	Token 命中率	实际成本	P95 Latency	P95 TTFT
Infron	1	49	49	0.00%	\$0.11936700	36281.15 ms	36203.82 ms
Infron	2	48	48	0.00%	\$0.12747500	44657.15 ms	44514.54 ms
Infron	3	49	49	0.00%	\$0.12877800	4338.02 ms	4218.15 ms
Infron	4	50	50	0.00%	\$0.13091900	3809.54 ms	3656.68 ms
OpenRouter	1	49	49	0.00%	\$0.24587236	3498.90 ms	3387.04 ms
OpenRouter	2	48	48	0.00%	\$0.25416911	3059.15 ms	2860.55 ms
OpenRouter	3	49	49	0.00%	\$0.25315975	3189.21 ms	2904.47 ms
OpenRouter	4	50	50	0.00%	\$0.25019785	3108.18 ms	2829.80 ms

价格优先

平台	组别	轮数	成功轮数	Token 命中率	实际成本	P95 Latency	P95 TTFT
Infron	1	49	49	0.00%	\$0.12383900	4669.25 ms	4152.30 ms
Infron	2	50	50	0.00%	\$0.13310900	6510.02 ms	6154.40 ms
Infron	3	50	50	0.00%	\$0.13588100	4930.64 ms	4180.06 ms
Infron	4	50	50	0.00%	\$0.13030000	4333.30 ms	4217.16 ms
OpenRouter	1	49	49	0.00%	\$0.14909698	16772.30 ms	6710.55 ms
OpenRouter	2	50	50	0.00%	\$0.16423321	9564.35 ms	7229.66 ms
OpenRouter	3	50	50	0.00%	\$0.16407179	9037.89 ms	7185.26 ms
OpenRouter	4	50	50	0.00%	\$0.15868213	9067.03 ms	8462.85 ms

端到端时延优先

平台	组别	轮数	成功轮数	Token 命中率	实际成本	P95 Latency	P95 TTFT
Infron	1	49	49	0.00%	\$0.12590300	4579.91 ms	4346.15 ms
Infron	2	50	50	0.00%	\$0.13765700	5188.43 ms	4807.22 ms
Infron	3	50	50	0.00%	\$0.13491600	5539.01 ms	5369.55 ms
Infron	4	50	50	0.00%	\$0.13030000	5939.77 ms	5619.08 ms
OpenRouter	1	49	49	0.00%	\$0.24814680	6887.25 ms	6453.01 ms
OpenRouter	2	50	50	4.50%	\$0.26698700	4688.96 ms	4440.95 ms
OpenRouter	3	50	50	6.00%	\$0.25958222	3830.05 ms	3612.86 ms

平台	组别	轮数	成功轮数	Token 命中率	实际成本	P95 Latency	P95 TTFT
OpenRouter	4	50	50	5.84%	\$0.25240768	4725.16 ms	4239.98 ms

流式 TTFT 优先

平台	组别	轮数	成功轮数	Token 命中率	实际成本	P95 Latency	P95 TTFT
Infron	1	50	50	0.00%	\$0.13030000	5178.89 ms	4599.93 ms
Infron	2	49	49	0.00%	\$0.13129800	5831.73 ms	5283.54 ms
Infron	3	50	50	0.00%	\$0.13520100	4810.97 ms	4573.64 ms
Infron	4	50	50	0.00%	\$0.13091900	5478.90 ms	5353.08 ms
OpenRouter	1	50	50	5.84%	\$0.25137438	4190.14 ms	3487.44 ms
OpenRouter	2	49	49	6.04%	\$0.25145242	3770.40 ms	3562.88 ms
OpenRouter	3	50	50	10.91%	\$0.25198491	3929.62 ms	3611.54 ms
OpenRouter	4	50	50	10.54%	\$0.24584848	4061.76 ms	3491.50 ms

10. 讨论：业务价值、适用边界与工程启示

业务决策不应只看单一指标。稳定长上下文和高频模板请求优先关注缓存命中率与成本；实时交互应同时约束 TTFT 和端到端时延；后台批处理更重视吞吐与失败成本。

路由模式	主要业务目标	本轮数据体现	适用场景	注意事项
吞吐优先	最大化单位时间输出能力	OpenRouter 综合占优 (3/5 指标)	批量内容生成、离线摘要、后台数据加工	首包与完整响应更快，但需检查缓存和成本
价格优先	最小化单位请求和单位 token 成本	Infron 综合占优 (4/5 指标)	高频模板化请求、客服自动化、营销触达、RAG 固定前缀	需要结合预算、SLA 和缓存稳定性决策
端到端时延优先	最小化完整响应等待时间	OpenRouter 综合占优 (4/5 指标)	在线聊天、Agent 调用链、IDE/写作辅助、实时运营工具	首包与完整响应更快，但需检查缓存和成本
流式 TTFT 优先	最小化流式首包响应时间	OpenRouter 综合占优 (4/5 指标)	流式聊天、实时 Copilot、首屏反馈、长任务进度感知	首包与完整响应更快，但需检查缓存和成本

11. 结论

路由模式级结论

路由模式	目标	缓存胜出	成本胜出	吞吐胜出	E2E 时延胜出	TTFT 胜出	解读
吞吐优先	最大化单位时间输出能力	Tie	Infron	OpenRouter	OpenRouter	OpenRouter	OpenRouter 综合占优 (3/5 指标)
价格优先	最小化单位请求和单位 token 成本	Tie	Infron	Infron	Infron	Infron	Infron 综合占优 (4/5 指标)

路由模式	目标	缓存胜出	成本胜出	吞吐胜出	E2E 时延胜出	TTFT 胜出	解读
端到端时延优先	最小化完整响应等待时间	OpenRouter	Infron	OpenRouter	OpenRouter	OpenRouter	OpenRouter 综合占优 (4/5 指标)
流式 TTFT 优先	最小化流式首包响应时间	OpenRouter	Infron	OpenRouter	OpenRouter	OpenRouter	OpenRouter 综合占优 (4/5 指标)

12. 局限性、缺失数据与后续实验计划

缺失或不足	对结论的影响	后续补充方式	当前处理方式
完整 routing trace	无法逐跳证明每次请求的 provider 选择、fallback 和重试路径	补充 provider routing trace、decision log 和 fallback reason	只使用响应中真实返回的 provider 字段和 provider 分布
更长时间窗口	4x50 能观察短期稳定性，但不能覆盖日级波动	增加 soak test 和跨时段重复实验	报告限定在本轮窗口内解释
真实生产语料	内置模板不能覆盖全部业务分布	使用脱敏生产语料分层抽样	当前只讨论代表性长上下文业务模板
成本字段一致性	不同平台 cost 字段覆盖率和口径可能不同	结合账单回查和 provider cost breakdown	只统计响应明确返回的成本字段

13. 可复现性附录

工件	路径
Summary	export/qwen3_next_80b_all_experiments/ routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions summary.json
配对数据集	export/qwen3_next_80b_all_experiments/ routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions benchmark_pairs.csv
请求级数据集	export/qwen3_next_80b_all_experiments/ routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions benchmark_requests.jsonl
过滤后结构化记录	export/qwen3_next_80b_all_experiments/ routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions records.json
剔除记录审计	export/qwen3_next_80b_all_experiments/ routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions records_excluded.json
测试源码	tests/test_rerun_routing_sort_cache_cost_ab.py
Benchmark 执行源码	scripts/rerun_routing_sort_cache_cost_ab.py

工件	路径
HTML 报告 渲染源码	<code>scripts/render_glm52_deepseek_style_report.py</code>
数据集引用	<code>business_representative</code> 内置代表性业务模板；请求级导出见 <code>benchmark_requests.jsonl</code>