

Infron 与 OpenRouter A/B 实验报告：qwen/qwen3.5-27b

本报告是本次实验的短版摘要；完整中文 Markdown、标准中英文 HTML、PDF、summary JSON、配对 CSV 和请求级 JSONL 均保存在同一 export 目录。

- 模型： `qwen/qwen3.5-27b`
- API： `/v1/chat/completions`
- 实验规模：4 组 x 50 轮 x 4 个 routing sort x 2 平台 x first/second replay
- Reasoning / Thinking：平台默认行为，payload 未显式设置 `reasoning.effort`
- 有效配对：800；请求级记录：3200
- 排除记录：0 (`incomplete=0`, `anomalous_usage=0`, `unequal_input_tokens=0`)
- 报告日期：2026-07-13

路由模式结果摘要

路由模式	配对数	缓存胜出	成本胜出	吞吐胜出	E2E 时延胜出	TTFT 胜出
Throughput First	200	Tie (0.00%)	Infron (\$1.584584)	Infron (12.067 tok/s)	OpenRouter (6786.48 ms)	OpenRouter (6047.10 ms)
Price First	200	Tie (0.00%)	Infron (\$0.931282)	Infron (27.608 tok/s)	Infron (18616.78 ms)	OpenRouter (6789.28 ms)
Latency First	200	Tie (0.00%)	Infron (\$1.087530)	Infron (27.556 tok/s)	OpenRouter (14778.19 ms)	OpenRouter (7395.33 ms)
TTFT First	200	Tie (0.00%)	Infron (\$1.284133)	Infron (28.635 tok/s)	OpenRouter (13060.52 ms)	OpenRouter (6161.58 ms)

数据与报告工件

工件	路径
完整中文 Markdown	<code>routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions_report-zh.md</code>
中文摘要 Markdown	<code>routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions_summary-zh.md</code>
English summary Markdown	<code>routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions_summary-en.md</code>
标准中文 HTML	<code>routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions_standard-ab-report-zh.html</code>

工件	路径
Standard English HTML	routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions_standard-ab-report-en.html
Summary JSON	routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions_summary.json
Paired CSV	routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions_benchmark_pairs.csv
Request JSONL	routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions_benchmark_requests.jsonl