

# Infron 与 OpenRouter 路由、缓存、成本与流式性能 A/B 实验报告

---

## 摘要与结论大纲

关键词: Prompt Caching; A/B Testing; Provider Routing; Cache Affinity; Latency; Throughput; Cost Attribution; qwen3.7-flash

### 摘要

本报告以 `qwen/qwen3.7-flash` 为对象, 评估 Infron 与 OpenRouter 在 Prompt Caching 场景下的缓存复用、实际成本、吞吐、端到端时延和流式 TTFT 表现。

核心结论是: Infron 在 1/4 个路由模式下缓存命中率占优, OpenRouter 在 3/4 个路由模式下占优, 0/4 个路由模式持平; Infron 在所有路由模式下实际成本占优; Infron 在所有路由模式下吞吐量占优; OpenRouter 在所有路由模式下端到端 E2E 时延占优; Infron 在 1/4 个路由模式下流式 TTFT 占优, OpenRouter 在 3/4 个路由模式下占优, 0/4 个路由模式持平。

整体看, Infron 的跨模式优势主要体现在吞吐、实际成本, OpenRouter 的跨模式优势主要体现在流式 TTFT、端到端 E2E 时延、缓存复用。平台选择不应只看单一指标, 而应按业务目标在成本、缓存稳定性、吞吐和交互时延之间取舍。

**图 0：核心能力归一化雷达图**

五个雷达轴分别代表吞吐量、价格、端到端 E2E 时延、流式 TTFT 和缓存命中率。所有指标统一转为 0-100 分，且越外侧越好。

粗实线表示平台综合轮廓，半透明细线和点表示各路由模式下的表现。

结论总览：核心指标与路由模式胜出方

基于严格 A/B 配对样本。蓝色代表 Infron，橙色代表 OpenRouter；金色单元格表示该路由模式的目标指标胜出方。

|                                                 |                                                  |                                                            |                                                        |                                                       |
|-------------------------------------------------|--------------------------------------------------|------------------------------------------------------------|--------------------------------------------------------|-------------------------------------------------------|
| <b>吞吐量</b><br>Infron 4/4 胜出<br>最大优势 12.24%，越高越好 | <b>实际成本</b><br>Infron 4/4 胜出<br>最大优势 75.91%，越低越好 | <b>端到端 E2E 时延</b><br>OpenRouter 4/4 胜出<br>最大优势 97.35%，越低越好 | <b>流式 TTFT</b><br>OpenRouter 3/4 胜出<br>最大优势 4.02%，越低越好 | <b>缓存命中率</b><br>OpenRouter 3/4 胜出<br>最大优势 25.07%，越高越好 |
|-------------------------------------------------|--------------------------------------------------|------------------------------------------------------------|--------------------------------------------------------|-------------------------------------------------------|

| 路由模式               | 吞吐目标                | 成本目标                | 时延目标                    | TTFT 目标                | 缓存结果                    |
|--------------------|---------------------|---------------------|-------------------------|------------------------|-------------------------|
| 吞吐优先<br>throughput | Infron<br>优势 10.97% | Infron<br>优势 37.92% | OpenRouter<br>优势 95.81% | OpenRouter<br>优势 4.02% | OpenRouter<br>优势 25.07% |
| 价格优先<br>price      | Infron<br>优势 12.24% | Infron<br>优势 67.92% | OpenRouter<br>优势 82.73% | Infron<br>优势 1.19%     | OpenRouter<br>优势 3.92%  |
| 端到端时延优先<br>latency | Infron<br>优势 11.57% | Infron<br>优势 68.27% | OpenRouter<br>优势 97.35% | OpenRouter<br>优势 3.40% | Infron<br>优势 0.23%      |
| 流式 TTFT 优先<br>tft  | Infron<br>优势 10.93% | Infron<br>优势 75.91% | OpenRouter<br>优势 96.15% | OpenRouter<br>优势 1.43% | OpenRouter<br>优势 4.88%  |

结论大纲

| 研究维度 | 结论                                                                                                                       | 证据位置                  |
|------|--------------------------------------------------------------------------------------------------------------------------|-----------------------|
| 控制变量 | 同一 sort/group/round 下 first/second usage.prompt_tokens 偏差不超过 50 tokens；总 Input Tokens 使用响应 telemetry。                    | 方法与数据质量章节             |
| 缓存复用 | Infron 在 1/4 个路由模式下缓存命中率占优，OpenRouter 在 3/4 个路由模式下占优，0/4 个路由模式持平                                                         | 总体指标与机制解释章节           |
| 实际成本 | Infron 在所有路由模式下实际成本占优                                                                                                    | 总体指标与 Provider 下钻章节   |
| 性能表现 | Infron 在所有路由模式下吞吐量占优；OpenRouter 在所有路由模式下端到端 E2E 时延占优；Infron 在 1/4 个路由模式下流式 TTFT 占优，OpenRouter 在 3/4 个路由模式下占优，0/4 个路由模式持平 | 结果可视化与统计检验章节          |
| 归因边界 | 报告只使用响应中可观测的 usage、cost、TTFT、latency、provider 字段和 cache tokens。                                                          | Provider/Route 下钻分析章节 |
| 业务含义 | 长上下文、RAG 前缀、Agent 工具说明和高频模板请求应同时关注缓存命中率、成本、首包和端到端时延。                                                                     | 讨论与结论章节               |

路由模式级结论

| 路由模式 | 目标          | 缓存胜出       | 成本胜出   | 吞吐胜出   | E2E 时延胜出   | TTFT 胜出    | 解读                       |
|------|-------------|------------|--------|--------|------------|------------|--------------------------|
| 吞吐优先 | 最大化单位时间输出能力 | OpenRouter | Infron | Infron | OpenRouter | OpenRouter | OpenRouter 综合占优 (3/5 指标) |

| 路由模式       | 目标                  | 缓存胜出       | 成本胜出   | 吞吐胜出   | E2E 时延胜出   | TTFT 胜出    | 解读                       |
|------------|---------------------|------------|--------|--------|------------|------------|--------------------------|
| 价格优先       | 最小化单位请求和单位 token 成本 | OpenRouter | Infron | Infron | OpenRouter | Infron     | Infron 综合占优 (3/5 指标)     |
| 端到端时延优先    | 最小化完整响应等待时间         | Infron     | Infron | Infron | OpenRouter | OpenRouter | Infron 综合占优 (3/5 指标)     |
| 流式 TTFT 优先 | 最小化流式首包响应时间         | OpenRouter | Infron | Infron | OpenRouter | OpenRouter | OpenRouter 综合占优 (3/5 指标) |

## 1. 引言：背景、研究问题与贡献

LLM 推理平台的真实性能不仅由模型决定，也由 provider 路由、提示词缓存、流式响应、成本归因和 fallback 策略共同决定。本报告把平台视为可观测系统，以 A/B 配对方式评估速度、成本、缓存和首包体验的多目标权衡。

### 1.1 研究假设

| 假设 | 内容                                                         | 验证指标                                |
|----|------------------------------------------------------------|-------------------------------------|
| H1 | 重复稳定长前缀请求中，更强的 provider/cache affinity 会提升 Token 级缓存命中率。   | 第二次请求 cache read tokens、Token 级命中率  |
| H2 | 更高缓存命中率会降低真实响应成本，但不必然降低 TTFT 或端到端 latency。                 | 实际成本、平均 TTFT、平均 latency/请求          |
| H3 | 不同 routing sort 会改变 provider 选择，从而形成不同的成本、吞吐和时延 Pareto 前沿。 | provider 分布、throughput、latency、cost |

### 1.2 本文贡献

- 使用响应返回的 `usage.prompt_tokens` 作为真实 input token 控制变量，并允许 50 tokens 内的小幅跨平台计数波动。
- 将 prompt caching 评估扩展到成本、吞吐、E2E latency、TTFT、provider 分布、reasoning telemetry 和配对统计检验。
- 所有结论只基于响应可观测 telemetry，不把平台内部私有 routing trace 当作已观测事实。

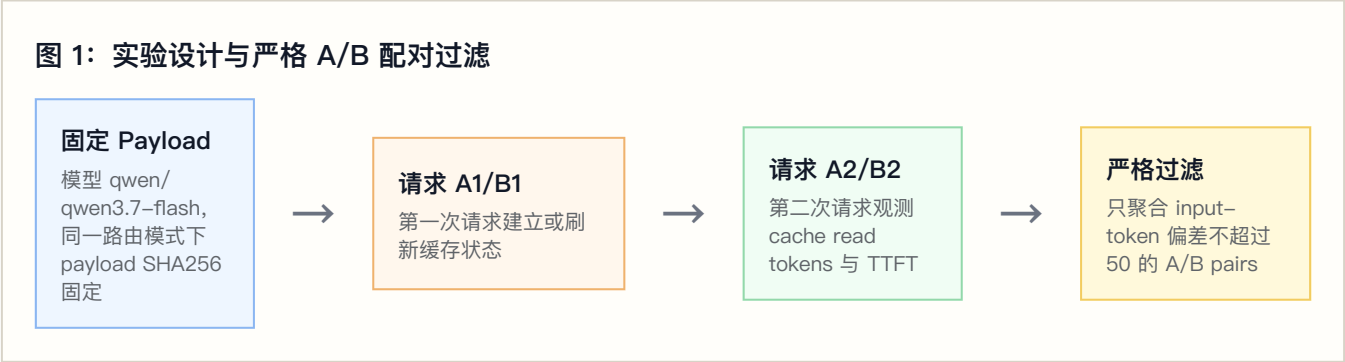
## 2. 方法：实验设计、数据集构造与控制变量

### 2.1 数据集生成方法

数据集名称为 `controlled_cache_probe`，覆盖 4 种 routing sort、2 个平台、4 个实验组、每组 50 轮。每轮包含 first/second 两次相同 Chat Completions 请求：第一次建立或刷新缓存状态，第二次观测 cache read tokens、TTFT 和端到端响应。

业务模板覆盖稳定长上下文场景，包括 RAG 客服、Agent 工具说明、营销自动化和代码审查等高复用 prompt 结构。

2.2 控制变量方法



控制变量方法：同一 `sort/group/round` 下，两个平台 `first/second` 两次请求的 `usage.prompt_tokens` 各自偏差必须不超过 50 tokens。总 Input Tokens 使用响应返回的 `usage.prompt_tokens`，不使用本地 tokenizer 估算。

2.3 指标定义

| 指标           | 定义                                                                      | 解释方向                   |
|--------------|-------------------------------------------------------------------------|------------------------|
| 调用级命中率       | 第二次请求 <code>cache_read_tokens &gt; 0</code> 的轮次占比                       | 越高表示越稳定触发缓存读取          |
| Token 级命中率   | 第二次请求 <code>cache read tokens</code> / 第二次请求 <code>prompt tokens</code> | 越高表示输入 token 复用比例越高    |
| 实际成本         | <code>first + second</code> 两次请求返回 <code>usage/cost</code> 的合计          | 越低越好                   |
| Throughput   | 响应 <code>completion tokens</code> / 请求 <code>latency seconds</code>     | 越高越好                   |
| E2E latency  | 每次请求完整响应耗时均值                                                            | 越低越好                   |
| TTFT         | <code>streaming</code> 下首包/首 token 到达时间均值                               | 越低越好                   |
| Reasoning 口径 | 响应 <code>usage</code> 中的 <code>reasoning token</code> 字段保留为观测变量         | 用于解释时延、吞吐和成本，不单独作为业务产出 |

3. 实验环境与数据质量控制

| 项目        | 配置                                                                                    |
|-----------|---------------------------------------------------------------------------------------|
| 模型        | <code>qwen/qwen3.7-flash</code>                                                       |
| 平台实际模型 ID | <code>infron: qwen/qwen3.7-flash</code> ; <code>openrouter: qwen/qwen3.7-flash</code> |
| 平台        | Infron、OpenRouter                                                                     |
| API 协议    | <code>/v1/chat/completions</code>                                                     |
| 路由模式      | 吞吐优先、价格优先、端到端时延优先、流式 TTFT 优先                                                          |
| 实验组       | 4                                                                                     |
| 每组轮数      | 50                                                                                    |
| Workers   | 24                                                                                    |
| 请求方式      | 流式 Chat Completions，采集 TTFT                                                           |

| 项目                      | 配置                                                                            |
|-------------------------|-------------------------------------------------------------------------------|
| Reasoning / Thinking 控制 | 未显式指定 reasoning/thinking 参数；保留模型与平台默认行为                                       |
| Prompt 长度分层             | <code>short</code> ≈1500、 <code>medium</code> ≈8000、 <code>long</code> ≈32000 |
| 剔除记录                    | 230                                                                           |

4. 结果：总体指标与主要发现

| 路由模式       | 平台         | 严格配对轮数 | 总 Input Tokens | Token 级缓存命中率 | 实际成本         | 吞吐量         | 端到端 E2E 时延 | 流式 TTFT    |
|------------|------------|--------|----------------|--------------|--------------|-------------|------------|------------|
| 吞吐优先       | Infron     | 163    | 5667484        | 53.89%       | \$0.14534700 | 71.44 tok/s | 5906.04 ms | 3006.71 ms |
| 吞吐优先       | OpenRouter | 163    | 5667484        | 67.40%       | \$0.20046654 | 5.97 tok/s  | 3016.26 ms | 2890.54 ms |
| 价格优先       | Infron     | 178    | 6497986        | 67.46%       | \$0.12428800 | 69.26 tok/s | 6287.51 ms | 3247.79 ms |
| 价格优先       | OpenRouter | 178    | 6497986        | 70.11%       | \$0.20870199 | 5.23 tok/s  | 3440.89 ms | 3286.44 ms |
| 端到端时延优先    | Infron     | 177    | 6086188        | 69.29%       | \$0.11321900 | 73.55 tok/s | 6072.71 ms | 3035.85 ms |
| 端到端时延优先    | OpenRouter | 177    | 6086188        | 69.13%       | \$0.19051714 | 5.85 tok/s  | 3077.13 ms | 2935.90 ms |
| 流式 TTFT 优先 | Infron     | 167    | 5711636        | 59.02%       | \$0.11308200 | 68.65 tok/s | 6134.60 ms | 3031.17 ms |
| 流式 TTFT 优先 | OpenRouter | 167    | 5711636        | 61.90%       | \$0.19892656 | 5.75 tok/s  | 3127.46 ms | 2988.47 ms |

4.1 尾延迟与显著性检验

尾延迟分位数补充均值无法表达的尾部风险。

| 路由模式       | 平台         | P50 Latency | P95 Latency | P99 Latency | P50 TTFT   | P95 TTFT   | P99 TTFT   |
|------------|------------|-------------|-------------|-------------|------------|------------|------------|
| 吞吐优先       | Infron     | 5699.36 ms  | 8905.14 ms  | 10907.52 ms | 2566.90 ms | 5920.58 ms | 7224.64 ms |
| 吞吐优先       | OpenRouter | 2837.99 ms  | 5214.80 ms  | 6625.83 ms  | 2720.70 ms | 5109.37 ms | 6027.52 ms |
| 价格优先       | Infron     | 6031.07 ms  | 9032.75 ms  | 12245.83 ms | 3066.21 ms | 5959.19 ms | 7922.48 ms |
| 价格优先       | OpenRouter | 3201.89 ms  | 6689.85 ms  | 8921.92 ms  | 3076.23 ms | 6177.10 ms | 8866.79 ms |
| 端到端时延优先    | Infron     | 5872.34 ms  | 8723.91 ms  | 9531.46 ms  | 2841.24 ms | 5575.12 ms | 6260.39 ms |
| 端到端时延优先    | OpenRouter | 2969.81 ms  | 5456.74 ms  | 7410.76 ms  | 2851.19 ms | 5340.58 ms | 7206.51 ms |
| 流式 TTFT 优先 | Infron     | 5929.55 ms  | 8870.69 ms  | 10394.01 ms | 2977.10 ms | 5491.02 ms | 6103.65 ms |
| 流式 TTFT 优先 | OpenRouter | 3014.78 ms  | 6096.69 ms  | 8425.05 ms  | 2844.58 ms | 5551.33 ms | 8139.81 ms |

均值差使用 bootstrap 95% CI, p-value 使用 paired sign-flip permutation test。

| 路由模式       | 指标                                   | 均值差                  | 95% CI                         | p-value | 配对数 | 解释                        |
|------------|--------------------------------------|----------------------|--------------------------------|---------|-----|---------------------------|
| 吞吐优先       | Latency: OpenRouter – Infron         | <b>-5779.54 ms</b>   | -6086.35 ms to -5471.26 ms     | <0.001  | 163 | 正值表示 Infron latency 更低    |
| 吞吐优先       | TTFT: OpenRouter – Infron            | <b>-232.34 ms</b>    | -453.01 ms to -0.10 ms         | 0.0500  | 163 | 正值表示 Infron TTFT 更低       |
| 吞吐优先       | Throughput: Infron – OpenRouter      | <b>66.0393 tok/s</b> | 63.6555 tok/s to 68.2486 tok/s | <0.001  | 163 | 正值表示 Infron throughput 更高 |
| 吞吐优先       | Cost: OpenRouter – Infron            | <b>\$0.00033816</b>  | \$0.00018829 to \$0.00049834   | <0.001  | 163 | 正值表示 Infron 成本更低          |
| 吞吐优先       | Token Cache Hit: Infron – OpenRouter | <b>-5.32 pp</b>      | -12.32 pp to 1.80 pp           | 0.1492  | 163 | 正值表示 Infron cache hit 更高  |
| 价格优先       | Latency: OpenRouter – Infron         | <b>-5693.25 ms</b>   | -6166.21 ms to -5252.16 ms     | <0.001  | 178 | 正值表示 Infron latency 更低    |
| 价格优先       | TTFT: OpenRouter – Infron            | <b>77.30 ms</b>      | -189.34 ms to 346.93 ms        | 0.5714  | 178 | 正值表示 Infron TTFT 更低       |
| 价格优先       | Throughput: Infron – OpenRouter      | <b>63.7745 tok/s</b> | 61.9940 tok/s to 65.4792 tok/s | <0.001  | 178 | 正值表示 Infron throughput 更高 |
| 价格优先       | Cost: OpenRouter – Infron            | <b>\$0.00047424</b>  | \$0.00031208 to \$0.00064485   | <0.001  | 178 | 正值表示 Infron 成本更低          |
| 价格优先       | Token Cache Hit: Infron – OpenRouter | <b>1.70 pp</b>       | -4.45 pp to 8.44 pp            | 0.6383  | 178 | 正值表示 Infron cache hit 更高  |
| 端到端时延优先    | Latency: OpenRouter – Infron         | <b>-5991.16 ms</b>   | -6341.65 ms to -5632.86 ms     | <0.001  | 177 | 正值表示 Infron latency 更低    |
| 端到端时延优先    | TTFT: OpenRouter – Infron            | <b>-199.90 ms</b>    | -412.01 ms to 14.55 ms         | 0.0650  | 177 | 正值表示 Infron TTFT 更低       |
| 端到端时延优先    | Throughput: Infron – OpenRouter      | <b>67.6055 tok/s</b> | 65.6004 tok/s to 69.3930 tok/s | <0.001  | 177 | 正值表示 Infron throughput 更高 |
| 端到端时延优先    | Cost: OpenRouter – Infron            | <b>\$0.00043671</b>  | \$0.00030013 to \$0.00058454   | <0.001  | 177 | 正值表示 Infron 成本更低          |
| 端到端时延优先    | Token Cache Hit: Infron – OpenRouter | <b>-1.34 pp</b>      | -7.30 pp to 4.31 pp            | 0.7091  | 177 | 正值表示 Infron cache hit 更高  |
| 流式 TTFT 优先 | Latency: OpenRouter – Infron         | <b>-6014.30 ms</b>   | -6454.41 ms to -5574.72 ms     | <0.001  | 167 | 正值表示 Infron latency 更低    |
| 流式 TTFT 优先 | TTFT: OpenRouter – Infron            | <b>-85.40 ms</b>     | -337.75 ms to 171.51 ms        | 0.5244  | 167 | 正值表示 Infron TTFT 更低       |
| 流式 TTFT 优先 | Throughput: Infron – OpenRouter      | <b>62.7361 tok/s</b> | 61.0764 tok/s to 64.4892 tok/s | <0.001  | 167 | 正值表示 Infron throughput 更高 |
| 流式 TTFT 优先 | Cost: OpenRouter – Infron            | <b>\$0.00051404</b>  | \$0.00033418 to \$0.00070593   | <0.001  | 167 | 正值表示 Infron 成本更低          |

| 路由模式       | 指标                                   | 均值差      | 95% CI              | p-value | 配对数 | 解释                       |
|------------|--------------------------------------|----------|---------------------|---------|-----|--------------------------|
| 流式 TTFT 优先 | Token Cache Hit: Infron – OpenRouter | -3.07 pp | -9.35 pp to 3.77 pp | 0.4054  | 167 | 正值表示 Infron cache hit 更高 |

4.2 Reasoning / Thinking 控制校验

本轮未显式指定 reasoning/thinking 参数，保留模型与平台默认行为；该表记录默认行为下的 reasoning telemetry。

| 路由模式       | 平台         | Reasoning Tokens | 平均 Reasoning Tokens/请求 | Reasoning 请求数 | 平均首 Reasoning Token | 平均 TTFT    | 平均 E2E 时延  |
|------------|------------|------------------|------------------------|---------------|---------------------|------------|------------|
| 吞吐优先       | Infron     | 134940           | 413.9264               | 326           | 3036.10 ms          | 3006.71 ms | 5906.04 ms |
| 吞吐优先       | OpenRouter | 5216             | 16.0000                | 326           | 2890.54 ms          | 2890.54 ms | 3016.26 ms |
| 价格优先       | Infron     | 152191           | 427.5028               | 356           | 3274.56 ms          | 3247.79 ms | 6287.51 ms |
| 价格优先       | OpenRouter | 5696             | 16.0000                | 356           | 3286.44 ms          | 3286.44 ms | 3440.89 ms |
| 端到端时延优先    | Infron     | 155291           | 438.6751               | 354           | 3060.04 ms          | 3035.85 ms | 6072.71 ms |
| 端到端时延优先    | OpenRouter | 5664             | 16.0000                | 354           | 2935.90 ms          | 2935.90 ms | 3077.13 ms |
| 流式 TTFT 优先 | Infron     | 137991           | 413.1467               | 334           | 3059.04 ms          | 3031.17 ms | 6134.60 ms |
| 流式 TTFT 优先 | OpenRouter | 5344             | 16.0000                | 334           | 2988.47 ms          | 2988.47 ms | 3127.46 ms |

4.3 API 协议兼容性矩阵

本轮 API 协议为 /v1/chat/completions；本表记录两家平台在该协议下的成功响应、usage、成本和缓存 telemetry 覆盖。

| API 协议           | Endpoint             | 平台         | 配对轮数 | 请求数  | 成功率     | Usage 覆盖 | Token Usage 覆盖 | 成本覆盖    | 缓存 Telemetry 覆盖 | HTTP 响应             |
|------------------|----------------------|------------|------|------|---------|----------|----------------|---------|-----------------|---------------------|
| chat_completions | /v1/chat/completions | Infron     | 800  | 1600 | 100.00% | 100.00%  | 100.00%        | 100.00% | 100.00%         | {"200": 1600}       |
| chat_completions | /v1/chat/completions | OpenRouter | 800  | 1600 | 92.81%  | 100.00%  | 100.00%        | 100.00% | 100.00%         | {"200": 1485,"4115} |



## 5. 结果可视化：按路由模式的核心指标变化

以下图表使用同一份严格配对后的 summary 数据驱动，统一展示路由模式、平台差异、成本、缓存、端到端 E2E 时延、流式 TTFT 和上游 Provider 分布。

## 5.1 核心指标图表总览

以下图表使用同一份严格配对后的 summary 数据生成，统一展示路由模式、平台差异、成本、缓存、端到端 E2E 时延、流式 TTFT 和上游 Provider 分布。

图 3-E2：归一化  
综合轮廓

五项指标统一转为  
0-100 且越高越好。

图 3-E3：成本-缓存  
效率平面

横轴为 Token 级缓存命中  
率，纵轴为总实际成本。

图 3-E1：路由模式级核心指标对比  
按路由模式并列展示 Infron 与 OpenRouter。





图 3-E4：端到端 E2E 时延与流式 TTFT

实线表示端到端 E2E 时延，虚线表示流式 TTFT。

图 3-E5：上游 Provider 分布

按路由模式展示主要上游路径占比。

模式级下钻图表

横轴表示相对优势百分比：右侧蓝色代表 Infron 优势，左侧橙色代表 OpenRouter 优势。

**图 4-E1: Throughput First 路由模式下的核心指标对比**

展示五项核心指标的相对优势方向与幅度。

**图 4-E2: Price First 路由模式下的核心指标对比**

展示五项核心指标的相对优势方向与幅度。

**图 4-E3: Latency First 路由模式下的核心指标对比**

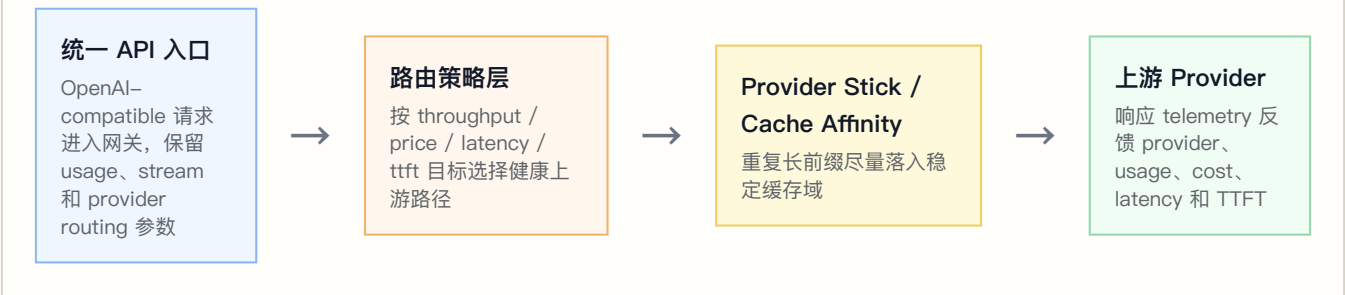
展示五项核心指标的相对优势方向与幅度。

**图 4-E4: TTFT First 路由模式下的核心指标对比**

展示五项核心指标的相对优势方向与幅度。

## 6. Infron 技术架构与缓存/成本机制解释

图 12: Infron 多 provider 路由与缓存控制面



### 6.1 多 provider 路由与可观测控制面

请求进入统一 API 后，路由策略层根据 throughput、price、latency 或 tft 目标选择健康上游路径。稳定长前缀请求是否落在相同缓存域，会直接影响第二次请求的 cache read tokens。

### 6.2 Provider Stick 与 Cache Affinity

Provider stick 是缓存亲和策略，不等于固定锁死 provider。它的目标是在健康和 SLA 约束下减少缓存域碎片化，使重复 prefix 更容易复用已有缓存。

### 6.3 成本控制路径

| 机制                              | 对 cache rate 的影响                | 对成本的影响             | 本次实验中的可观测信号                               |
|---------------------------------|---------------------------------|--------------------|-------------------------------------------|
| Stable prefix 识别                | 相同前缀更容易命中已有 cache               | 降低重复 prefill 的边际成本 | 同一 payload SHA256、第二次请求 cache read tokens |
| Provider stick / cache affinity | 降低跨 provider/cache domain 的缓存碎片 | 减少重复暖缓存            | provider 分布与 Token 级命中率共同变化               |
| 健康检查与 fallback                  | 保护可用性，必要时牺牲部分缓存收益               | 降低失败成本             | HTTP 状态、provider 分布和尾延迟变化                 |
| 成本感知 routing                    | 在健康约束下偏向低成本路径                   | 降低总成本和每轮成本         | 实际成本、cost breakdown 覆盖率、cache read tokens |

## 7. Provider/Route 下钻分析

| 路由模式    | 平台         | 总请求数 | 已归因请求数 | Provider 分布    |
|---------|------------|------|--------|----------------|
| 吞吐优先    | Infron     | 326  | 326    | alibaba/jp 326 |
| 吞吐优先    | OpenRouter | 326  | 326    | Alibaba 326    |
| 价格优先    | Infron     | 356  | 356    | alibaba/jp 356 |
| 价格优先    | OpenRouter | 356  | 356    | Alibaba 356    |
| 端到端时延优先 | Infron     | 354  | 354    | alibaba/jp 354 |



| 路由模式       | 平台         | 总请求数 | 已归因请求数 | Provider 分布    |
|------------|------------|------|--------|----------------|
| 端到端时延优先    | OpenRouter | 354  | 354    | Alibaba 354    |
| 流式 TTFT 优先 | Infron     | 334  | 334    | alibaba/jp 334 |
| 流式 TTFT 优先 | OpenRouter | 334  | 334    | Alibaba 334    |

上游 Provider 明细分布

| 路由模式       | 平台         | 上游 Provider | 请求数 | 占比      | first/second | 覆盖轮次 | Avg TTFT   | Avg Latency | Prompt Tokens | Completion Tokens | Reasoning Tokens | Cache Read Token |
|------------|------------|-------------|-----|---------|--------------|------|------------|-------------|---------------|-------------------|------------------|------------------|
| 吞吐优先       | Infron     | alibaba/jp  | 326 | 100.00% | 163/163      | 163  | 3006.71 ms | 5906.04 ms  | 5667484       | 137546            | 134940           | 27763            |
| 吞吐优先       | OpenRouter | Alibaba     | 326 | 100.00% | 163/163      | 163  | 2890.54 ms | 3016.26 ms  | 5667484       | 5868              | 5216             | 37593            |
| 价格优先       | Infron     | alibaba/jp  | 356 | 100.00% | 178/178      | 178  | 3247.79 ms | 6287.51 ms  | 6497986       | 155037            | 152191           | 43699            |
| 价格优先       | OpenRouter | Alibaba     | 356 | 100.00% | 178/178      | 178  | 3286.44 ms | 3440.89 ms  | 6497986       | 6408              | 5696             | 44256            |
| 端到端时延优先    | Infron     | alibaba/jp  | 354 | 100.00% | 177/177      | 177  | 3035.85 ms | 6072.71 ms  | 6086188       | 158119            | 155291           | 41475            |
| 端到端时延优先    | OpenRouter | Alibaba     | 354 | 100.00% | 177/177      | 177  | 2935.90 ms | 3077.13 ms  | 6086188       | 6372              | 5664             | 41985            |
| 流式 TTFT 优先 | Infron     | alibaba/jp  | 334 | 100.00% | 167/167      | 167  | 3031.17 ms | 6134.60 ms  | 5711636       | 140661            | 137991           | 36284            |
| 流式 TTFT 优先 | OpenRouter | Alibaba     | 334 | 100.00% | 167/167      | 167  | 2988.47 ms | 3127.46 ms  | 5711636       | 6012              | 5344             | 36627            |

7.1 缓存命中率与实际成本反向表现下钻

该表把 cache、cost、provider 分布和 reasoning telemetry 放在同一层级，解释每个路由模式的主要差异来源。

| 路由模式 | 缓存命中差值    | Infron 成本倍数 | Infron 主要路径        | OpenRouter 主要路径 | Reasoning Tokens 差异 | 主要归因                  |
|------|-----------|-------------|--------------------|-----------------|---------------------|-----------------------|
| 吞吐优先 | -13.51 pp | 0.73x       | alibaba/jp 100.00% | Alibaba 100.00% | +129724             | 缓存和成本方向存在分化，需结合速度指标判断 |

| 路由模式          | 缓存命中<br>差值      | Infron 成<br>本倍数 | Infron 主要路径                  | OpenRouter 主<br>要路径       | Reasoning<br>Tokens 差异 | 主要归因                      |
|---------------|-----------------|-----------------|------------------------------|---------------------------|------------------------|---------------------------|
| 价格优先          | -2.65 pp        | 0.60x           | <b>alibaba/jp</b><br>100.00% | <b>Alibaba</b><br>100.00% | +146495                | 缓存和成本方向存在分化，<br>需结合速度指标判断 |
| 端到端时<br>延优先   | <b>+0.16 pp</b> | 0.59x           | <b>alibaba/jp</b><br>100.00% | Alibaba<br>100.00%        | +149627                | Infron 缓存与成本同向占优          |
| 流式 TTFT<br>优先 | -2.88 pp        | 0.57x           | <b>alibaba/jp</b><br>100.00% | <b>Alibaba</b><br>100.00% | +132647                | 缓存和成本方向存在分化，<br>需结合速度指标判断 |

## 8. 分层结果：按 Prompt 长度的缓存表现

本节按 prompt 长度 tier 聚合第二次请求的 cache read tokens、Token 级缓存命中率、实际成本、端到端时延和流式 TTFT。加粗单元表示同一长度 tier 下表现更优的一方。

### Prompt 长度分层总览

| Prompt 长<br>度 tier | 目标<br>tokens | 平台         | 轮<br>数 | 第二次<br>Prompt<br>Tokens | 第二次<br>Cache Read<br>Tokens | Token 级<br>命中率 | 实际成本         | 平均 E2E<br>时延  | 平均<br>TTFT    |
|--------------------|--------------|------------|--------|-------------------------|-----------------------------|----------------|--------------|---------------|---------------|
| short              | 1500         | Infron     | 231    | 460111                  | 0                           | 0.00%          | \$0.02354300 | 5117.83<br>ms | 1788.12<br>ms |
| short              | 1500         | OpenRouter | 231    | 460111                  | 0                           | 0.00%          | \$0.02868774 | 2068.23<br>ms | 1915.67<br>ms |
| medium             | 8000         | Infron     | 232    | 2395822                 | 697728                      | 29.12%         | \$0.06336200 | 6656.13<br>ms | 2889.94<br>ms |
| medium             | 8000         | OpenRouter | 232    | 2395822                 | 695680                      | 29.04%         | \$0.11035802 | 3182.88<br>ms | 3038.52<br>ms |
| long               | 32000        | Infron     | 222    | 9125714                 | 6815232                     | 74.68%         | \$0.40903100 | 6553.02<br>ms | 4631.66<br>ms |
| long               | 32000        | OpenRouter | 222    | 9125714                 | 7363584                     | 80.69%         | \$0.65956648 | 4301.25<br>ms | 4177.56<br>ms |

### Prompt 长度 x 路由模式缓存命中率

| Prompt 长度 tier | 路由模式       | Infron | OpenRouter | 胜出方    |
|----------------|------------|--------|------------|--------|
| short          | 吞吐优先       | 0.00%  | 0.00%      | tie    |
| short          | 价格优先       | 0.00%  | 0.00%      | tie    |
| short          | 端到端时延优先    | 0.00%  | 0.00%      | tie    |
| short          | 流式 TTFT 优先 | 0.00%  | 0.00%      | tie    |
| medium         | 吞吐优先       | 46.51% | 45.01%     | Infron |
| medium         | 价格优先       | 30.84% | 19.63%     | Infron |

| Prompt 长度 tier | 路由模式       | Infron | OpenRouter | 胜出方        |
|----------------|------------|--------|------------|------------|
| medium         | 端到端时延优先    | 24.23% | 29.77%     | OpenRouter |
| medium         | 流式 TTFT 优先 | 14.25% | 21.99%     | OpenRouter |
| long           | 吞吐优先       | 58.64% | 76.96%     | OpenRouter |
| long           | 价格优先       | 79.66% | 85.91%     | OpenRouter |
| long           | 端到端时延优先    | 85.07% | 83.37%     | Infron     |
| long           | 流式 TTFT 优先 | 73.71% | 75.51%     | OpenRouter |

9. 分层结果：按实验组的稳定性检查

吞吐优先

| 平台         | 组别 | 轮数 | 成功轮数 | Token 命中率 | 实际成本         | P95 Latency | P95 TTFT   |
|------------|----|----|------|-----------|--------------|-------------|------------|
| Infron     | 1  | 48 | 48   | 52.96%    | \$0.04762900 | 8666.08 ms  | 5683.02 ms |
| Infron     | 2  | 30 | 30   | 45.17%    | \$0.02461800 | 7759.77 ms  | 6049.56 ms |
| Infron     | 3  | 44 | 44   | 57.45%    | \$0.03744000 | 9870.37 ms  | 6103.58 ms |
| Infron     | 4  | 41 | 41   | 57.93%    | \$0.03566000 | 8238.86 ms  | 5938.17 ms |
| OpenRouter | 1  | 48 | 48   | 67.37%    | \$0.07207349 | 4993.49 ms  | 4873.86 ms |
| OpenRouter | 2  | 30 | 30   | 73.60%    | \$0.03168526 | 5560.44 ms  | 5493.56 ms |
| OpenRouter | 3  | 44 | 44   | 57.96%    | \$0.05789421 | 5840.77 ms  | 5355.73 ms |
| OpenRouter | 4  | 41 | 41   | 72.59%    | \$0.03881359 | 4670.82 ms  | 4629.94 ms |

价格优先

| 平台         | 组别 | 轮数 | 成功轮数 | Token 命中率 | 实际成本         | P95 Latency | P95 TTFT   |
|------------|----|----|------|-----------|--------------|-------------|------------|
| Infron     | 1  | 50 | 50   | 69.92%    | \$0.03242800 | 8868.98 ms  | 5958.35 ms |
| Infron     | 2  | 37 | 37   | 82.69%    | \$0.02072400 | 8286.73 ms  | 5139.67 ms |
| Infron     | 3  | 49 | 49   | 53.45%    | \$0.03863600 | 9370.96 ms  | 6172.76 ms |
| Infron     | 4  | 42 | 42   | 67.35%    | \$0.03250000 | 10016.01 ms | 6200.28 ms |
| OpenRouter | 1  | 50 | 50   | 67.75%    | \$0.05904559 | 5330.42 ms  | 5267.33 ms |
| OpenRouter | 2  | 37 | 37   | 63.12%    | \$0.04862474 | 5749.84 ms  | 5587.03 ms |
| OpenRouter | 3  | 49 | 49   | 71.49%    | \$0.05522492 | 7698.67 ms  | 7418.68 ms |
| OpenRouter | 4  | 42 | 42   | 77.20%    | \$0.04580675 | 7145.65 ms  | 6966.98 ms |

端到端时延优先

| 平台         | 组别 | 轮数 | 成功轮数 | Token 命中率 | 实际成本         | P95 Latency | P95 TTFT   |
|------------|----|----|------|-----------|--------------|-------------|------------|
| Infron     | 1  | 44 | 44   | 71.92%    | \$0.02755200 | 8759.05 ms  | 5893.91 ms |
| Infron     | 2  | 45 | 45   | 67.47%    | \$0.03075500 | 7965.10 ms  | 5486.28 ms |
| Infron     | 3  | 41 | 41   | 60.29%    | \$0.02772500 | 9171.96 ms  | 5379.96 ms |
| Infron     | 4  | 47 | 47   | 76.84%    | \$0.02718700 | 8400.30 ms  | 4580.27 ms |
| OpenRouter | 1  | 44 | 44   | 56.18%    | \$0.04311926 | 5234.62 ms  | 5153.55 ms |
| OpenRouter | 2  | 45 | 45   | 71.13%    | \$0.05412047 | 5674.84 ms  | 5609.34 ms |
| OpenRouter | 3  | 41 | 41   | 77.61%    | \$0.04212614 | 4978.07 ms  | 4414.54 ms |
| OpenRouter | 4  | 47 | 47   | 70.54%    | \$0.05115127 | 4818.79 ms  | 4746.44 ms |

流式 TTFT 优先

| 平台         | 组别 | 轮数 | 成功轮数 | Token 命中率 | 实际成本         | P95 Latency | P95 TTFT   |
|------------|----|----|------|-----------|--------------|-------------|------------|
| Infron     | 1  | 47 | 47   | 57.88%    | \$0.03227800 | 8318.36 ms  | 5404.08 ms |
| Infron     | 2  | 38 | 38   | 47.51%    | \$0.02506900 | 8721.57 ms  | 5370.84 ms |
| Infron     | 3  | 38 | 38   | 66.97%    | \$0.02551800 | 9881.11 ms  | 5421.53 ms |
| Infron     | 4  | 44 | 44   | 62.19%    | \$0.03021700 | 9091.01 ms  | 5708.10 ms |
| OpenRouter | 1  | 47 | 47   | 62.75%    | \$0.05790167 | 5056.57 ms  | 4933.56 ms |
| OpenRouter | 2  | 38 | 38   | 77.32%    | \$0.03294962 | 4261.46 ms  | 4207.43 ms |
| OpenRouter | 3  | 38 | 38   | 54.10%    | \$0.05359975 | 7012.86 ms  | 6867.62 ms |
| OpenRouter | 4  | 44 | 44   | 55.54%    | \$0.05447553 | 5279.44 ms  | 5155.22 ms |

10. 讨论：业务价值、适用边界与工程启示

业务决策不应只看单一指标。稳定长上下文和高频模板请求优先关注缓存命中率与成本；实时交互应同时约束 TTFT 和端到端时延；后台批处理更重视吞吐与失败成本。

| 路由模式       | 主要业务目标              | 本轮数据体现                   | 适用场景                           | 注意事项                |
|------------|---------------------|--------------------------|--------------------------------|---------------------|
| 吞吐优先       | 最大化单位时间输出能力         | OpenRouter 综合占优 (3/5 指标) | 批量内容生成、离线摘要、后台数据加工             | 首包与完整响应更快，但需检查缓存和成本 |
| 价格优先       | 最小化单位请求和单位 token 成本 | Infron 综合占优 (3/5 指标)     | 高频模板化请求、客服自动化、营销触达、RAG 固定前缀    | 需要结合预算、SLA 和缓存稳定性决策 |
| 端到端时延优先    | 最小化完整响应等待时间         | Infron 综合占优 (3/5 指标)     | 在线聊天、Agent 调用链、IDE/写作辅助、实时运营工具 | 缓存和成本更稳，但仍需检查速度 SLA |
| 流式 TTFT 优先 | 最小化流式首包响应时间         | OpenRouter 综合占优 (3/5 指标) | 流式聊天、实时 Copilot、首屏反馈、长任务进度感知   | 首包与完整响应更快，但需检查缓存和成本 |

# 11. 结论

## 路由模式级结论

| 路由模式       | 目标                  | 缓存胜出       | 成本胜出   | 吞吐胜出   | E2E 时延胜出   | TTFT 胜出    | 解读                       |
|------------|---------------------|------------|--------|--------|------------|------------|--------------------------|
| 吞吐优先       | 最大化单位时间输出能力         | OpenRouter | Infron | Infron | OpenRouter | OpenRouter | OpenRouter 综合占优 (3/5 指标) |
| 价格优先       | 最小化单位请求和单位 token 成本 | OpenRouter | Infron | Infron | OpenRouter | Infron     | Infron 综合占优 (3/5 指标)     |
| 端到端时延优先    | 最小化完整响应等待时间         | Infron     | Infron | Infron | OpenRouter | OpenRouter | Infron 综合占优 (3/5 指标)     |
| 流式 TTFT 优先 | 最小化流式首包响应时间         | OpenRouter | Infron | Infron | OpenRouter | OpenRouter | OpenRouter 综合占优 (3/5 指标) |

# 12. 局限性、缺失数据与后续实验计划

| 缺失或不足            | 对结论的影响                                 | 后续补充方式                                                   | 当前处理方式                               |
|------------------|----------------------------------------|----------------------------------------------------------|--------------------------------------|
| 完整 routing trace | 无法逐跳证明每次请求的 provider 选择、fallback 和重试路径 | 补充 provider routing trace、decision log 和 fallback reason | 只使用响应中真实返回的 provider 字段和 provider 分布 |
| 更长时间窗口           | 4x50 能观察短期稳定性，但不能覆盖日级波动                | 增加 soak test 和跨时段重复实验                                    | 报告限定在本轮窗口内解释                         |
| 真实生产语料           | 内置模板不能覆盖全部业务分布                         | 使用脱敏生产语料分层抽样                                             | 当前只讨论代表性长上下文业务模板                     |
| 成本字段一致性          | 不同平台 cost 字段覆盖率和口径可能不同                 | 结合账单回查和 provider cost breakdown                          | 只统计响应明确返回的成本字段                       |

# 13. 可复现性附录

| 工件       | 路径                                                                                                                                                               |
|----------|------------------------------------------------------------------------------------------------------------------------------------------------------------------|
| Summary  | export/qwen3_7_flash_all_experiments/<br>routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions<br>summary.json             |
| 配对数据集    | export/qwen3_7_flash_all_experiments/<br>routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions<br>benchmark_pairs.csv      |
| 请求级数据集   | export/qwen3_7_flash_all_experiments/<br>routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions<br>benchmark_requests.jsonl |
| 过滤后结构化记录 | export/qwen3_7_flash_all_experiments/<br>routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions<br>records.json             |

| 工件                | 路径                                                                                                                                                           |
|-------------------|--------------------------------------------------------------------------------------------------------------------------------------------------------------|
| 剔除记录审计            | export/qwen3_7_flash_all_experiments/<br>routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completion<br>records_excluded.json |
| 测试源码              | tests/test_rerun_routing_sort_cache_cost_ab.py                                                                                                               |
| Benchmark<br>执行源码 | scripts/rerun_routing_sort_cache_cost_ab.py                                                                                                                  |
| HTML 报告<br>渲染源码   | scripts/render_glm52_deepseek_style_report.py                                                                                                                |
| 数据集引用             | business_representative 内置代表性业务模板；请求级导出见 benchmark_requests.jsonl                                                                                            |