

Infron 与 OpenRouter 路由、缓存、成本与流式性能 A/B 实验报告

摘要与结论大纲

关键词: Prompt Caching; A/B Testing; Provider Routing; Cache Affinity; Latency; Throughput; Cost Attribution; glm-4.7

摘要

本报告以 `z-ai/glm-4.7` 为对象, 评估 Infron 与 OpenRouter 在 Prompt Caching 场景下的缓存复用、实际成本、吞吐、端到端时延和流式 TTFT 表现。

核心结论是: Infron 在 1/4 个路由模式下缓存命中率占优, OpenRouter 在 3/4 个路由模式下占优, 0/4 个路由模式持平; Infron 在 3/4 个路由模式下实际成本占优, OpenRouter 在 1/4 个路由模式下占优, 0/4 个路由模式持平; OpenRouter 在所有路由模式下吞吐量占优; Infron 在所有路由模式下端到端 E2E 时延占优; OpenRouter 在所有路由模式下流式 TTFT 占优。

整体看, Infron 的跨模式优势主要体现在端到端 E2E 时延、实际成本, OpenRouter 的跨模式优势主要体现在吞吐、流式 TTFT、缓存复用。平台选择不应只看单一指标, 而应按业务目标在成本、缓存稳定性、吞吐和交互时延之间取舍。

图 0：核心能力归一化雷达图

五个雷达轴分别代表吞吐量、价格、端到端 E2E 时延、流式 TTFT 和缓存命中率。所有指标统一转为 0-100 分，且越外侧越好。

粗实线表示平台综合轮廓，半透明细线和点表示各路由模式下的表现。

结论总览：核心指标与路由模式胜出方

基于严格 A/B 配对样本。蓝色代表 Infron，橙色代表 OpenRouter；金色单元格表示该路由模式的目标指标胜出方。

吞吐量 OpenRouter 4/4 胜出 最大优势 17.41%，越高越好	实际成本 Infron 3/4 胜出 最大优势 3.97%，越低越好	端到端 E2E 时延 Infron 4/4 胜出 最大优势 8.39%，越低越好	流式 TTFT OpenRouter 4/4 胜出 最大优势 89.31%，越低越好	缓存命中率 OpenRouter 3/4 胜出 最大优势 2.79%，越高越好
---	---	---	---	--

路由模式	吞吐目标	成本目标	时延目标	TTFT 目标	缓存结果
吞吐优先 throughput	OpenRouter 优势 17.41%	Infron 优势 3.97%	Infron 优势 8.39%	OpenRouter 优势 89.31%	OpenRouter 优势 2.79%
价格优先 price	OpenRouter 优势 12.90%	Infron 优势 0.79%	Infron 优势 3.35%	OpenRouter 优势 14.37%	OpenRouter 优势 0.16%
端到端时延优先 latency	OpenRouter 优势 27.40%	OpenRouter 优势 105.88%	Infron 优势 0.03%	OpenRouter 优势 18.74%	OpenRouter 优势 2.66%
流式 TTFT 优先 tft	OpenRouter 优势 12.11%	Infron 优势 3.22%	Infron 优势 1.51%	OpenRouter 优势 40.25%	Infron 优势 0.17%

结论大纲

研究维度	结论	证据位置
控制变量	同一 <code>sort/group/round</code> 下 <code>first/second usage.prompt_tokens</code> 偏差不超过 50 tokens；总 Input Tokens 使用响应 telemetry。	方法与数据质量章节
缓存复用	Infron 在 1/4 个路由模式下缓存命中率占优，OpenRouter 在 3/4 个路由模式下占优，0/4 个路由模式持平	总体指标与机制解释章节
实际成本	Infron 在 3/4 个路由模式下实际成本占优，OpenRouter 在 1/4 个路由模式下占优，0/4 个路由模式持平	总体指标与 Provider 下钻章节
性能表现	OpenRouter 在所有路由模式下吞吐量占优；Infron 在所有路由模式下端到端 E2E 时延占优；OpenRouter 在所有路由模式下流式 TTFT占优	结果可视化与统计检验章节
归因边界	报告只使用响应中可观测的 <code>usage</code> 、 <code>cost</code> 、 <code>TTFT</code> 、 <code>latency</code> 、 <code>provider</code> 字段和 <code>cache tokens</code> 。	Provider/Route 下钻分析章节
业务含义	长上下文、RAG 前缀、Agent 工具说明和高频模板请求应同时关注缓存命中率、成本、首包和端到端时延。	讨论与结论章节

路由模式级结论

路由模式	目标	缓存胜出	成本胜出	吞吐胜出	E2E 时延胜出	TTFT 胜出	解读
吞吐优先	最大化单位时间输出能力	OpenRouter	Infron	OpenRouter	Infron	OpenRouter	OpenRouter 综合占优 (3/5 指标)

路由模式	目标	缓存胜出	成本胜出	吞吐胜出	E2E 时延胜出	TTFT 胜出	解读
价格优先	最小化单位请求和单位 token 成本	OpenRouter	Infron	OpenRouter	Infron	OpenRouter	OpenRouter 综合占优 (3/5 指标)
端到端时延优先	最小化完整响应等待时间	OpenRouter	OpenRouter	OpenRouter	Infron	OpenRouter	OpenRouter 综合占优 (4/5 指标)
流式 TTFT 优先	最小化流式首包响应时间	Infron	Infron	OpenRouter	Infron	OpenRouter	Infron 综合占优 (3/5 指标)

1. 引言：背景、研究问题与贡献

LLM 推理平台的真实性能不仅由模型决定，也由 provider 路由、提示词缓存、流式响应、成本归因和 fallback 策略共同决定。本报告把平台视为可观测系统，以 A/B 配对方式评估速度、成本、缓存和首包体验的多目标权衡。

1.1 研究假设

假设	内容	验证指标
H1	重复稳定长前缀请求中，更强的 provider/cache affinity 会提升 Token 级缓存命中率。	第二次请求 cache read tokens、Token 级命中率
H2	更高缓存命中率会降低真实响应成本，但不必然降低 TTFT 或端到端 latency。	实际成本、平均 TTFT、平均 latency/请求
H3	不同 routing sort 会改变 provider 选择，从而形成不同的成本、吞吐和时延 Pareto 前沿。	provider 分布、throughput、latency、cost

1.2 本文贡献

- 使用响应返回的 `usage.prompt_tokens` 作为真实 input token 控制变量，并允许 50 tokens 内的小幅跨平台计数波动。
- 将 prompt caching 评估扩展到成本、吞吐、E2E latency、TTFT、provider 分布、reasoning telemetry 和配对统计检验。
- 所有结论只基于响应可观测 telemetry，不把平台内部私有 routing trace 当作已观测事实。


2. 方法：实验设计、数据集构造与控制变量

2.1 数据集生成方法

数据集名称为 `business_representative`，覆盖 4 种 routing sort、2 个平台、4 个实验组、每组 50 轮。每轮包含 first/second 两次相同 Chat Completions 请求：第一次建立或刷新缓存状态，第二次观测 cache read tokens、TTFT 和端到端响应。

业务模板覆盖稳定长上下文场景，包括 RAG 客服、Agent 工具说明、营销自动化和代码审查等高复用 prompt 结构。

2.2 控制变量方法



控制变量方法：同一 `sort/group/round` 下，两个平台 `first/second` 两次请求的 `usage.prompt_tokens` 各自偏差必须不超过 50 tokens。总 Input Tokens 使用响应返回的 `usage.prompt_tokens`，不使用本地 tokenizer 估算。

2.3 指标定义

指标	定义	解释方向
调用级命中率	第二次请求 <code>cache_read_tokens > 0</code> 的轮次占比	越高表示越稳定触发缓存读取
Token 级命中率	第二次请求 <code>cache read tokens</code> / 第二次请求 <code>prompt tokens</code>	越高表示输入 token 复用比例越高
实际成本	<code>first + second</code> 两次请求返回 <code>usage/cost</code> 的合计	越低越好
Throughput	响应 <code>completion tokens</code> / 请求 <code>latency seconds</code>	越高越好
E2E latency	每次请求完整响应耗时均值	越低越好
TTFT	streaming 下首包/首 token 到达时间均值	越低越好
Reasoning 口径	响应 <code>usage</code> 中的 <code>reasoning token</code> 字段保留为观测变量	用于解释时延、吞吐和成本，不单独作为业务产出

3. 实验环境与数据质量控制

项目	配置
模型	<code>z-ai/glm-4.7</code>
平台实际模型 ID	<code>infron: z-ai/glm-4.7</code> ; <code>openrouter: z-ai/glm-4.7</code>
平台	Infron、OpenRouter
API 协议	<code>/v1/chat/completions</code>
路由模式	吞吐优先、价格优先、端到端时延优先、流式 TTFT 优先
实验组	4
每组轮数	50
Workers	24
请求方式	流式 Chat Completions，采集 TTFT
Reasoning / Thinking 控制	未显式指定 <code>reasoning/thinking</code> 参数；保留模型与平台默认行为

项目	配置
Prompt 长度分层	short ≈1500、medium ≈8000、long ≈32000
剔除记录	16

4. 结果：总体指标与主要发现

路由模式	平台	严格配对轮数	总 Input Tokens	Token 级缓存命中率	实际成本	吞吐量	端到端 E2E 时延	流式 TTFT
吞吐优先	Infron	196	6340852	87.70%	\$2.35911200	2.61 tok/s	4815.56 ms	4237.16 ms
吞吐优先	OpenRouter	196	6340852	90.15%	\$11.72252143	48.12 tok/s	45202.33 ms	2238.17 ms
价格优先	Infron	197	6332778	97.16%	\$1.29962000	3.39 tok/s	3695.85 ms	3278.24 ms
价格优先	OpenRouter	197	6332778	97.32%	\$1.30994008	47.05 tok/s	16059.34 ms	2866.39 ms
端到端时延优先	Infron	200	6414682	96.85%	\$3.45964100	4.03 tok/s	3119.38 ms	2835.38 ms
端到端时延优先	OpenRouter	200	6414682	99.43%	\$1.68043559	5.13 tok/s	3120.18 ms	2387.82 ms
流式 TTFT 优先	Infron	199	6396238	90.65%	\$1.47298600	3.17 tok/s	3927.90 ms	3460.80 ms
流式 TTFT 优先	OpenRouter	199	6396238	90.50%	\$6.21110423	41.60 tok/s	9840.11 ms	2467.55 ms

4.1 尾延迟与显著性检验

尾延迟分位数补充均值无法表达的尾部风险。

路由模式	平台	P50 Latency	P95 Latency	P99 Latency	P50 TTFT	P95 TTFT	P99 TTFT
吞吐优先	Infron	3205.84 ms	15260.63 ms	27522.80 ms	2755.11 ms	14748.86 ms	26879.53 ms
吞吐优先	OpenRouter	1986.21 ms	488985.92 ms	978823.46 ms	1844.43 ms	5059.73 ms	5890.09 ms
价格优先	Infron	3175.76 ms	8392.18 ms	12749.50 ms	2778.86 ms	7766.03 ms	12389.07 ms
价格优先	OpenRouter	3223.35 ms	22306.38 ms	597046.76 ms	2420.72 ms	5461.09 ms	8349.43 ms
端到端时延优先	Infron	2356.66 ms	6139.54 ms	10955.27 ms	2168.31 ms	5550.92 ms	10530.32 ms
端到端时延优先	OpenRouter	2896.61 ms	5714.99 ms	7332.56 ms	2183.62 ms	4346.92 ms	5286.50 ms
流式 TTFT 优先	Infron	2817.32 ms	10246.12 ms	29526.18 ms	2313.33 ms	9510.77 ms	29429.36 ms
流式 TTFT 优先	OpenRouter	2542.11 ms	6319.66 ms	55239.59 ms	2048.63 ms	5144.78 ms	10020.13 ms

均值差使用 bootstrap 95% CI, p-value 使用 paired sign-flip permutation test。

路由模式	指标	均值差	95% CI	p-value	配对数	解释
吞吐优先	Latency: OpenRouter – Infron	80773.54 ms	48187.49 ms to 115069.98 ms	<0.001	196	正值表示 Infron latency 更低
吞吐优先	TTFT: OpenRouter – Infron	-3997.97 ms	-5040.73 ms to -3118.27 ms	<0.001	196	正值表示 Infron TTFT 更低
吞吐优先	Throughput: Infron – OpenRouter	-13.0327 tok/s	-15.4306 tok/s to -10.7098 tok/s	<0.001	196	正值表示 Infron throughput 更高
吞吐优先	Cost: OpenRouter – Infron	\$0.04777250	\$0.04158206 to \$0.05474179	<0.001	196	正值表示 Infron 成本更低
吞吐优先	Token Cache Hit: Infron – OpenRouter	-3.91 pp	-8.94 pp to 1.55 pp	0.1547	196	正值表示 Infron cache hit 更高
价格优先	Latency: OpenRouter – Infron	24726.98 ms	9517.45 ms to 42808.20 ms	<0.001	197	正值表示 Infron latency 更低
价格优先	TTFT: OpenRouter – Infron	-823.70 ms	-1358.63 ms to -275.83 ms	0.0030	197	正值表示 Infron TTFT 更低
价格优先	Throughput: Infron – OpenRouter	-5.0436 tok/s	-7.0884 tok/s to -3.2296 tok/s	<0.001	197	正值表示 Infron throughput 更高
价格优先	Cost: OpenRouter – Infron	\$0.00005239	\$-0.00230687 to \$0.00269302	0.9660	197	正值表示 Infron 成本更低
价格优先	Token Cache Hit: Infron – OpenRouter	-3.25 pp	-5.89 pp to -0.73 pp	0.0140	197	正值表示 Infron cache hit 更高
端到端时延优先	Latency: OpenRouter – Infron	1.61 ms	-607.85 ms to 509.31 ms	0.9955	200	正值表示 Infron latency 更低
端到端时延优先	TTFT: OpenRouter – Infron	-895.11 ms	-1460.28 ms to -439.17 ms	<0.001	200	正值表示 Infron TTFT 更低
端到端时延优先	Throughput: Infron – OpenRouter	-0.5847 tok/s	-1.0223 tok/s to -0.1315 tok/s	0.0177	200	正值表示 Infron throughput 更高
端到端时延优先	Cost: OpenRouter – Infron	\$-0.00889603	\$-0.01153673 to \$-0.00616604	<0.001	200	正值表示 Infron 成本更低
端到端时延优先	Token Cache Hit: Infron – OpenRouter	-1.46 pp	-3.96 pp to 1.22 pp	0.3007	200	正值表示 Infron cache hit 更高
流式 TTFT 优先	Latency: OpenRouter – Infron	11824.42 ms	674.68 ms to 27150.73 ms	0.1325	199	正值表示 Infron latency 更低
流式 TTFT 优先	TTFT: OpenRouter – Infron	-1986.49 ms	-2989.55 ms to -1004.35 ms	<0.001	199	正值表示 Infron TTFT 更低
流式 TTFT 优先	Throughput: Infron – OpenRouter	-3.1953 tok/s	-4.5543 tok/s to -2.1213 tok/s	<0.001	199	正值表示 Infron throughput 更高
流式 TTFT 优先	Cost: OpenRouter – Infron	\$0.02380964	\$0.01799208 to \$0.02969512	<0.001	199	正值表示 Infron 成本更低
流式 TTFT 优先	Token Cache Hit: Infron – OpenRouter	1.13 pp	-3.76 pp to 6.03 pp	0.6888	199	正值表示 Infron cache hit 更高

4.2 Reasoning / Thinking 控制校验

本轮未显式指定 reasoning/thinking 参数，保留模型与平台默认行为；该表记录默认行为下的 reasoning telemetry。

路由模式	平台	Reasoning Tokens	平均 Reasoning Tokens/请求	Reasoning 请求数	平均首 Reasoning Token	平均 TTFT	平均 E2E 时延
吞吐优先	Infron	0	0.0000	0	0.00 ms	4237.16 ms	4815.56 ms
吞吐优先	OpenRouter	852412	2174.5204	392	2238.17 ms	2238.17 ms	45202.33 ms
价格优先	Infron	0	0.0000	0	0.00 ms	3278.24 ms	3695.85 ms
价格优先	OpenRouter	300492	762.6701	394	2866.39 ms	2866.39 ms	16059.34 ms
端到端时延优先	Infron	0	0.0000	0	0.00 ms	2835.38 ms	3119.38 ms
端到端时延优先	OpenRouter	9454	23.6350	400	2387.82 ms	2387.82 ms	3120.18 ms
流式 TTFT 优先	Infron	0	0.0000	0	0.00 ms	3460.80 ms	3927.90 ms
流式 TTFT 优先	OpenRouter	164853	414.2035	398	2467.55 ms	2467.55 ms	9840.11 ms

4.3 API 协议兼容性矩阵

本轮 API 协议为 /v1/chat/completions；本表记录两家平台在该协议下的成功响应、usage、成本和缓存 telemetry 覆盖。

API 协议	Endpoint	平台	配对轮数	请求数	成功率	Usage 覆盖	Token Usage 覆盖	成本覆盖	缓存 Telemetry 覆盖	HTTP 状态
chat_completions	/v1/chat/completions	Infron	800	1600	100.00%	100.00%	100.00%	100.00%	100.00%	{"200": 1600}
chat_completions	/v1/chat/completions	OpenRouter	800	1600	99.94%	99.69%	99.69%	99.69%	100.00%	{"0": 1, "200": 1599}

5. 结果可视化：按路由模式的核心指标变化

以下图表使用同一份严格配对后的 summary 数据驱动，统一展示路由模式、平台差异、成本、缓存、端到端 E2E 时延、流式 TTFT 和上游 Provider 分布。

5.1 核心指标图表总览

以下图表使用同一份严格配对后的 summary 数据生成，统一展示路由模式、平台差异、成本、缓存、端到端 E2E 时延、流式 TTFT 和上游 Provider 分布。

图 3-E2：归一化
综合轮廓

五项指标统一转为
0-100 且越高越好。

图 3-E3：成本-缓存
效率平面

横轴为 Token 级缓存命中
率，纵轴为总实际成本。

图 3-E1：路由模式级核心指标对比
按路由模式并列展示 Infron 与 OpenRouter。

图 3-E4：端到端 E2E 时延与流式 TTFT

实线表示端到端 E2E 时延，虚线表示流式 TTFT。

图 3-E5：上游 Provider 分布

按路由模式展示主要上游路径占比。

模式级下钻图表

横轴表示相对优势百分比：右侧蓝色代表 Infron 优势，左侧橙色代表 OpenRouter 优势。

图 4-E1: Throughput First 路由模式下的核心指标对比

展示五项核心指标的相对优势方向与幅度。

图 4-E2: Price First 路由模式下的核心指标对比

展示五项核心指标的相对优势方向与幅度。

图 4-E3: Latency First 路由模式下的核心指标对比


展示五项核心指标的相对优势方向与幅度。

图 4-E4: TTFT First 路由模式下的核心指标对比

展示五项核心指标的相对优势方向与幅度。

6. Infron 技术架构与缓存/成本机制解释

图 12: Infron 多 provider 路由与缓存控制面



6.1 多 provider 路由与可观测控制面

请求进入统一 API 后，路由策略层根据 throughput、price、latency 或 tftt 目标选择健康上游路径。稳定长前缀请求是否落在相同缓存域，会直接影响第二次请求的 cache read tokens。

6.2 Provider Stick 与 Cache Affinity

Provider stick 是缓存亲和策略，不等于固定锁死 provider。它的目标是在健康和 SLA 约束下减少缓存域碎片化，使重复 prefix 更容易复用已有缓存。

6.3 成本控制路径

机制	对 cache rate 的影响	对成本的影响	本次实验中的可观测信号
Stable prefix 识别	相同前缀更容易命中已有 cache	降低重复 prefill 的边际成本	同一 payload SHA256、第二次请求 cache read tokens
Provider stick / cache affinity	降低跨 provider/cache domain 的缓存碎片	减少重复暖缓存	provider 分布与 Token 级命中率共同变化
健康检查与 fallback	保护可用性，必要时牺牲部分缓存收益	降低失败成本	HTTP 状态、provider 分布和尾延迟变化
成本感知 routing	在健康约束下偏向低成本路径	降低总成本和每轮成本	实际成本、cost breakdown 覆盖率、cache read tokens

7. Provider/Route 下钻分析

路由模式	平台	总请求数	已归因请求数	Provider 分布
吞吐优先	Infron	392	392	atlas-cloud 128, alibaba/cn 96, z-ai 85, deepinfra 83
吞吐优先	OpenRouter	392	392	Cerebras 275, StreamLake 43, DeepInfra 40, Google 34
价格优先	Infron	394	394	alibaba/cn 262, atlas-cloud 114, deepinfra 18
价格优先	OpenRouter	394	394	DeepInfra 373, StreamLake 21

路由模式	平台	总请求数	已归因请求数	Provider 分布
端到端时延优先	Infron	400	400	cerebras 224, atlas-cloud 176
端到端时延优先	OpenRouter	400	400	DeepInfra 336, Cerebras 61, Google 3
流式 TTFT 优先	Infron	398	398	cerebras 190, deepinfra 183, byteplus 25
流式 TTFT 优先	OpenRouter	398	398	Cerebras 184, DeepInfra 149, Google 57, StreamLake 5, Venice 3

上游 Provider 明细分布

路由模式	平台	上游 Provider	请求数	占比	first/second	覆盖轮次	Avg TTFT	Avg Latency	Prompt Tokens	Completion Tokens	Reasoning Tokens	Cost
吞吐优先	Infron	atlas-cloud	128	32.65%	57/71	71	3015.57 ms	3378.43 ms	2172789	1676	0	1.00
吞吐优先	Infron	alibaba/cn	96	24.49%	55/41	55	3523.03 ms	3881.86 ms	1343164	1184	0	9.00
吞吐优先	Infron	z-ai	85	21.68%	45/40	54	5791.82 ms	6227.12 ms	1386006	1025	0	1.00
吞吐优先	Infron	deepinfra	83	21.17%	39/44	53	5354.90 ms	6666.21 ms	1438893	1049	0	1.00
吞吐优先	OpenRouter	Cerebras	275	70.15%	137/138	163	1784.62 ms	1848.12 ms	4030603	4400	4400	3.00
吞吐优先	OpenRouter	StreamLake	43	10.97%	23/20	42	4411.22 ms	394378.19 ms	1064769	847035	846252	1.00
吞吐优先	OpenRouter	DeepInfra	40	10.20%	18/22	22	1993.00 ms	2727.93 ms	213119	640	932	2.00
吞吐优先	OpenRouter	Google	34	8.67%	18/16	31	3446.75 ms	4226.42 ms	1032361	544	828	5.00
价格优先	Infron	alibaba/cn	262	66.50%	132/130	139	3374.68 ms	3753.99 ms	4201868	3192	0	4.00
价格优先	Infron	atlas-cloud	114	28.93%	56/58	65	2982.92 ms	3405.47 ms	1840318	1534	0	1.00
价格优先	Infron	deepinfra	18	4.57%	9/9	9	3744.93 ms	4688.60 ms	290592	204	0	1.00
价格优先	OpenRouter	DeepInfra	373	94.67%	188/185	196	2684.14 ms	3596.74 ms	5907457	5968	9116	5.00
价格优先	OpenRouter	StreamLake	21	5.33%	9/12	20	6103.59 ms	237418.80 ms	425321	291735	291376	3.00

路由模式	平台	上游 Provider	请求数	占比	first/second	覆盖轮次	Avg TTFT	Avg Latency	Prompt Tokens	Completion Tokens	Reasoning Tokens	Cost
端到端时延优先	Infron	cerebras	224	56.00%	115/109	129	1669.54 ms	1820.29 ms	1423410	2784	0	1.00
端到端时延优先	Infron	atlas-cloud	176	44.00%	85/91	105	4319.17 ms	4772.76 ms	4991272	2238	0	4.00
端到端时延优先	OpenRouter	DeepInfra	336	84.00%	166/170	174	2524.43 ms	3381.79 ms	5897735	5376	8420	5.00
端到端时延优先	OpenRouter	Cerebras	61	15.25%	33/28	38	1655.31 ms	1714.24 ms	496719	976	976	4.00
端到端时延优先	OpenRouter	Google	3	0.75%	1/2	3	1982.30 ms	2407.21 ms	20228	48	58	1.00
流式 TTFT 优先	Infron	cerebras	190	47.74%	98/92	113	1579.81 ms	1718.75 ms	1098069	2250	0	1.00
流式 TTFT 优先	Infron	deepinfra	183	45.98%	86/97	109	3299.62 ms	4156.87 ms	4602829	2342	0	4.00
流式 TTFT 优先	Infron	byteplus	25	6.28%	15/10	22	18936.10 ms	19041.43 ms	695340	367	0	0.00
流式 TTFT 优先	OpenRouter	Cerebras	184	46.23%	93/91	113	1996.63 ms	2064.39 ms	2088233	2944	2944	1.00
流式 TTFT 优先	OpenRouter	DeepInfra	149	37.44%	74/75	87	2665.34 ms	3745.02 ms	2639463	2384	3831	2.00
流式 TTFT 优先	OpenRouter	Google	57	14.32%	28/29	47	2900.58 ms	3388.18 ms	1481877	912	1458	9.00
流式 TTFT 优先	OpenRouter	StreamLake	5	1.26%	3/2	5	7491.29 ms	553229.52 ms	130771	156626	156539	9.00

路由模式	平台	上游 Provider	请求数	占比	first/second	覆盖轮次	Avg TTFT	Avg Latency	Prompt Tokens	Completion Tokens	Reasoning Tokens
流式 TTFT 优先	OpenRouter	Venice	3	0.75%	1/2	3	4926.22 ms	6411.97 ms	55894	48	81

7.1 缓存命中率与实际成本反向表现下钻

该表把 cache、cost、provider 分布和 reasoning telemetry 放在同一层级，解释每个路由模式的主要差异来源。

路由模式	缓存命中差值	Infron 成本倍数	Infron 主要路径	OpenRouter 主要路径	Reasoning Tokens 差异	主要归因
吞吐优先	-2.45 pp	0.20x	atlas-cloud 32.65%	Cerebras 70.15%	-852412	缓存和成本方向存在分化，需结合速度指标判断
价格优先	-0.16 pp	0.99x	alibaba/cn 66.50%	DeepInfra 94.67%	-300492	缓存和成本方向存在分化，需结合速度指标判断
端到端时延优先	-2.58 pp	2.06x	cerebras 56.00%	DeepInfra 84.00%	-9454	OpenRouter 缓存更高且成本更低，主要看 provider/cache 域差异
流式 TTFT 优先	+0.15 pp	0.24x	cerebras 47.74%	Cerebras 46.23%	-164853	Infron 缓存与成本同向占优

8. 分层结果：按 Prompt 长度的缓存表现

本节按 prompt 长度 tier 聚合第二次请求的 cache read tokens、Token 级缓存命中率、实际成本、端到端时延和流式 TTFT。加粗单元表示同一长度 tier 下表现更优的一方。

Prompt 长度分层总览

Prompt 长度 tier	目标 tokens	平台	轮数	第二次 Prompt Tokens	第二次 Cache Read Tokens	Token 级命中率	实际成本	平均 E2E 时延	平均 TTFT
short	1500	Infron	266	468570	426208	90.96%	\$0.40699000	2062.10 ms	1753.08 ms
short	1500	OpenRouter	266	468570	438400	93.56%	\$1.14530131	6198.48 ms	1687.32 ms
medium	8000	Infron	263	2427115	2302784	94.88%	\$1.80182600	3563.12 ms	3122.63 ms
medium	8000	OpenRouter	263	2427115	2349728	96.81%	\$5.54600964	15638.37 ms	2252.96 ms

Prompt 长度 tier	目标 tokens	平台	轮数	第二次 Prompt Tokens	第二次 Cache Read Tokens	Token 级 命中率	实际成本	平均 E2E 时延	平均 TTFT
long	32000	Infron	263	9846590	9133536	92.76%	\$6.38254300	6052.63 ms	5492.40 ms
long	32000	OpenRouter	263	9846590	9234880	93.79%	\$14.23269038	33626.91 ms	3538.45 ms

Prompt 长度 x 路由模式缓存命中率

Prompt 长度 tier	路由模式	Infron	OpenRouter	胜出方
short	吞吐优先	85.41%	92.62%	OpenRouter
short	价格优先	91.77%	97.42%	OpenRouter
short	端到端时延优先	93.06%	94.03%	OpenRouter
short	流式 TTFT 优先	93.62%	90.29%	Infron
medium	吞吐优先	91.44%	93.48%	OpenRouter
medium	价格优先	94.34%	99.82%	OpenRouter
medium	端到端时延优先	98.21%	98.38%	OpenRouter
medium	流式 TTFT 优先	95.33%	95.34%	OpenRouter
long	吞吐优先	86.93%	89.25%	OpenRouter
long	价格优先	98.13%	96.67%	Infron
long	端到端时延优先	96.70%	99.96%	OpenRouter
long	流式 TTFT 优先	89.35%	89.31%	Infron

9. 分层结果：按实验组的稳定性检查

吞吐优先

平台	组别	轮数	成功轮数	Token 命中率	实际成本	P95 Latency	P95 TTFT
Infron	1	48	48	84.52%	\$0.20900000	15394.45 ms	14543.95 ms
Infron	2	49	49	79.53%	\$0.41033100	22335.58 ms	21558.06 ms
Infron	3	49	49	92.16%	\$0.92022400	13146.75 ms	12940.77 ms
Infron	4	50	50	94.70%	\$0.81955700	7774.10 ms	7350.46 ms
OpenRouter	1	48	48	93.31%	\$2.92280559	487720.79 ms	5337.85 ms
OpenRouter	2	49	49	77.90%	\$2.62445875	623230.31 ms	5314.08 ms
OpenRouter	3	49	49	94.84%	\$2.97944500	28482.04 ms	4926.91 ms

平台	组别	轮数	成功轮数	Token 命中率	实际成本	P95 Latency	P95 TTFT
OpenRouter	4	50	50	94.93%	\$3.19581209	44049.73 ms	4526.62 ms

价格优先

平台	组别	轮数	成功轮数	Token 命中率	实际成本	P95 Latency	P95 TTFT
Infron	1	48	48	91.88%	\$0.16758700	9304.59 ms	8268.21 ms
Infron	2	50	50	99.12%	\$0.33531200	7282.33 ms	7144.26 ms
Infron	3	49	49	98.17%	\$0.40023700	5469.66 ms	5079.31 ms
Infron	4	50	50	99.08%	\$0.39648400	10892.53 ms	10016.62 ms
OpenRouter	1	48	48	94.85%	\$0.52433344	42930.43 ms	5543.44 ms
OpenRouter	2	50	50	99.31%	\$0.37593736	23865.89 ms	5852.94 ms
OpenRouter	3	49	49	95.28%	\$0.25281960	6450.57 ms	4602.33 ms
OpenRouter	4	50	50	99.68%	\$0.15684968	8191.63 ms	5221.84 ms

端到端时延优先

平台	组别	轮数	成功轮数	Token 命中率	实际成本	P95 Latency	P95 TTFT
Infron	1	50	50	98.13%	\$0.87834400	5480.00 ms	5078.45 ms
Infron	2	50	50	94.96%	\$0.87516500	6819.94 ms	5605.96 ms
Infron	3	50	50	94.98%	\$0.86795900	6129.32 ms	5612.93 ms
Infron	4	50	50	99.49%	\$0.83817300	6073.53 ms	5363.47 ms
OpenRouter	1	50	50	99.65%	\$0.45228386	5727.80 ms	4333.76 ms
OpenRouter	2	50	50	98.54%	\$0.36502139	5821.87 ms	4263.78 ms
OpenRouter	3	50	50	99.69%	\$0.37872743	5397.15 ms	4378.57 ms
OpenRouter	4	50	50	99.89%	\$0.48440291	5531.57 ms	4154.45 ms

流式 TTFT 优先

平台	组别	轮数	成功轮数	Token 命中率	实际成本	P95 Latency	P95 TTFT
Infron	1	50	50	63.83%	\$0.80475000	28182.96 ms	28066.61 ms
Infron	2	49	49	98.63%	\$0.24074900	6190.14 ms	5378.94 ms
Infron	3	50	50	99.75%	\$0.20363800	6177.89 ms	5146.51 ms
Infron	4	50	50	99.80%	\$0.22384900	5185.56 ms	3845.64 ms
OpenRouter	1	50	50	94.85%	\$1.36985113	4181.53 ms	3503.71 ms
OpenRouter	2	49	49	75.58%	\$2.11139781	9203.58 ms	5565.45 ms
OpenRouter	3	50	50	99.34%	\$1.05860361	4848.89 ms	3330.83 ms

平台	组别	轮数	成功轮数	Token 命中率	实际成本	P95 Latency	P95 TTFT
OpenRouter	4	50	50	92.41%	\$1.67125168	8486.81 ms	5933.69 ms

10. 讨论：业务价值、适用边界与工程启示

业务决策不应只看单一指标。稳定长上下文和高频模板请求优先关注缓存命中率与成本；实时交互应同时约束 TTFT 和端到端时延；后台批处理更重视吞吐与失败成本。

路由模式	主要业务目标	本轮数据体现	适用场景	注意事项
吞吐优先	最大化单位时间输出能力	OpenRouter 综合占优 (3/5 指标)	批量内容生成、离线摘要、后台数据加工	适合吞吐优先任务，但成本和缓存需单独约束
价格优先	最小化单位请求和单位 token 成本	OpenRouter 综合占优 (3/5 指标)	高频模板化请求、客服自动化、营销触达、RAG 固定前缀	适合吞吐优先任务，但成本和缓存需单独约束
端到端时延优先	最小化完整响应等待时间	OpenRouter 综合占优 (4/5 指标)	在线聊天、Agent 调用链、IDE/写作辅助、实时运营工具	适合吞吐优先任务，但成本和缓存需单独约束
流式 TTFT 优先	最小化流式首包响应时间	Infron 综合占优 (3/5 指标)	流式聊天、实时 Copilot、首屏反馈、长任务进度感知	缓存和成本更稳，但仍需检查速度 SLA

11. 结论

路由模式级结论

路由模式	目标	缓存胜出	成本胜出	吞吐胜出	E2E 时延胜出	TTFT 胜出	解读
吞吐优先	最大化单位时间输出能力	OpenRouter	Infron	OpenRouter	Infron	OpenRouter	OpenRouter 综合占优 (3/5 指标)
价格优先	最小化单位请求和单位 token 成本	OpenRouter	Infron	OpenRouter	Infron	OpenRouter	OpenRouter 综合占优 (3/5 指标)
端到端时延优先	最小化完整响应等待时间	OpenRouter	OpenRouter	OpenRouter	Infron	OpenRouter	OpenRouter 综合占优 (4/5 指标)
流式 TTFT 优先	最小化流式首包响应时间	Infron	Infron	OpenRouter	Infron	OpenRouter	Infron 综合占优 (3/5 指标)

12. 局限性、缺失数据与后续实验计划

缺失或不足	对结论的影响	后续补充方式	当前处理方式
完整 routing trace	无法逐跳证明每次请求的 provider 选择、fallback 和重试路径	补充 provider routing trace、decision log 和 fallback reason	只使用响应中真实返回的 provider 字段和 provider 分布
更长时间窗口	4x50 能观察短期稳定性，但不能覆盖日级波动	增加 soak test 和跨时段重复实验	报告限定在本轮窗口内解释

缺失或不足	对结论的影响	后续补充方式	当前处理方式
真实生产语料	内置模板不能覆盖全部业务分布	使用脱敏生产语料分层抽样	当前只讨论代表性长上下文业务模板
成本字段一致性	不同平台 cost 字段覆盖率和口径可能不同	结合账单回查和 provider cost breakdown	只统计响应明确返回的成本字段

13. 可复现性附录

工件	路径
Summary	export/glm47_all_experiments/ routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions summary.json
配对数据集	export/glm47_all_experiments/ routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions benchmark_pairs.csv
请求级数据集	export/glm47_all_experiments/ routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions benchmark_requests.jsonl
过滤后结构化记录	export/glm47_all_experiments/ routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions records.json
剔除记录审计	export/glm47_all_experiments/ routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions records_excluded.json
测试源码	tests/test_rerun_routing_sort_cache_cost_ab.py
Benchmark 执行源码	scripts/rerun_routing_sort_cache_cost_ab.py
HTML 报告渲染源码	scripts/render_glm52_deepseek_style_report.py
数据集引用	business_representative 内置代表性业务模板；请求级导出见 benchmark_requests.jsonl