

# Infron 与 OpenRouter 路由、缓存、成本与流式性能 A/B 实验报告

## 摘要与结论大纲

关键词: Prompt Caching; A/B Testing; Provider Routing; Cache Affinity; Latency; Throughput; Cost Attribution; glm-5

### 摘要

本报告以 `z-ai/glm-5` 为对象, 评估 Infron 与 OpenRouter 在 Prompt Caching 场景下的缓存复用、实际成本、吞吐、端到端时延和流式 TTFT 表现。

核心结论是: Infron 在 1/4 个路由模式下缓存命中率占优, OpenRouter 在 3/4 个路由模式下占优, 0/4 个路由模式持平; Infron 在 2/4 个路由模式下实际成本占优, OpenRouter 在 2/4 个路由模式下占优, 0/4 个路由模式持平; OpenRouter 在所有路由模式下吞吐量占优; Infron 在 3/4 个路由模式下端到端 E2E 时延占优, OpenRouter 在 1/4 个路由模式下占优, 0/4 个路由模式持平; Infron 在 3/4 个路由模式下流式 TTFT 占优, OpenRouter 在 1/4 个路由模式下占优, 0/4 个路由模式持平。

整体看, Infron 的跨模式优势主要体现在流式 TTFT、端到端 E2E 时延, OpenRouter 的跨模式优势主要体现在吞吐、缓存复用。平台选择不应只看单一指标, 而应按业务目标在成本、缓存稳定性、吞吐和交互时延之间取舍。

**图 0：核心能力归一化雷达图**

五个雷达轴分别代表吞吐量、价格、端到端 E2E 时延、流式 TTFT 和缓存命中率。所有指标统一转为 0-100 分，且越外侧越好。

粗实线表示平台综合轮廓，半透明细线和点表示各路由模式下的表现。

## 结论总览：核心指标与路由模式胜出方

基于严格 A/B 配对样本。蓝色代表 Infron，橙色代表 OpenRouter；金色单元格表示该路由模式的目标指标胜出方。

|                                                      |                                                  |                                                        |                                                     |                                                      |
|------------------------------------------------------|--------------------------------------------------|--------------------------------------------------------|-----------------------------------------------------|------------------------------------------------------|
| <b>吞吐量</b><br>OpenRouter 4/4 胜出<br>最大优势 104.15%，越高越好 | <b>实际成本</b><br>Infron 2/4 胜出<br>最大优势 62.64%，越低越好 | <b>端到端 E2E 时延</b><br>Infron 3/4 胜出<br>最大优势 64.76%，越低越好 | <b>流式 TTFT</b><br>Infron 3/4 胜出<br>最大优势 47.57%，越低越好 | <b>缓存命中率</b><br>OpenRouter 3/4 胜出<br>最大优势 4.00%，越高越好 |
|------------------------------------------------------|--------------------------------------------------|--------------------------------------------------------|-----------------------------------------------------|------------------------------------------------------|

| 路由模式            | 吞吐目标                     | 成本目标                    | 时延目标                    | TTFT 目标                 | 缓存结果                   |
|-----------------|--------------------------|-------------------------|-------------------------|-------------------------|------------------------|
| 吞吐优先 throughput | OpenRouter<br>优势 7.85%   | OpenRouter<br>优势 62.64% | Infron<br>优势 10.78%     | Infron<br>优势 12.55%     | Infron<br>优势 1.72%     |
| 价格优先 price      | OpenRouter<br>优势 104.15% | OpenRouter<br>优势 20.72% | OpenRouter<br>优势 64.76% | OpenRouter<br>优势 47.57% | OpenRouter<br>优势 4.00% |
| 端到端时延优先 latency | OpenRouter<br>优势 19.66%  | Infron<br>优势 7.35%      | Infron<br>优势 3.14%      | Infron<br>优势 33.16%     | OpenRouter<br>优势 0.23% |
| 流式 TTFT 优先 ttft | OpenRouter<br>优势 9.81%   | Infron<br>优势 2.54%      | Infron<br>优势 12.04%     | Infron<br>优势 39.74%     | OpenRouter<br>优势 0.27% |

## 结论大纲

| 研究维度 | 结论                                                                                                                                                                 | 证据位置                  |
|------|--------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------|
| 控制变量 | 同一 sort/group/round 下 first/second usage.prompt_tokens 偏差不超过 50 tokens；总 Input Tokens 使用响应 telemetry。                                                              | 方法与数据质量章节             |
| 缓存复用 | Infron 在 1/4 个路由模式下缓存命中率占优，OpenRouter 在 3/4 个路由模式下占优，0/4 个路由模式持平                                                                                                   | 总体指标与机制解释章节           |
| 实际成本 | Infron 在 2/4 个路由模式下实际成本占优，OpenRouter 在 2/4 个路由模式下占优，0/4 个路由模式持平                                                                                                    | 总体指标与 Provider 下钻章节   |
| 性能表现 | OpenRouter 在所有路由模式下吞吐量占优；Infron 在 3/4 个路由模式下端到端 E2E 时延占优，OpenRouter 在 1/4 个路由模式下占优，0/4 个路由模式持平；Infron 在 3/4 个路由模式下流式 TTFT 占优，OpenRouter 在 1/4 个路由模式下占优，0/4 个路由模式持平 | 结果可视化与统计检验章节          |
| 归因边界 | 报告只使用响应中可观测的 usage、cost、TTFT、latency、provider 字段和 cache tokens。                                                                                                    | Provider/Route 下钻分析章节 |

|      |                                                      |         |
|------|------------------------------------------------------|---------|
| 研究维度 | 结论                                                   | 证据位置    |
| 业务含义 | 长上下文、RAG 前缀、Agent 工具说明和高频模板请求应同时关注缓存命中率、成本、首包和端到端时延。 | 讨论与结论章节 |

路由模式级结论

| 路由模式       | 目标                  | 缓存胜出       | 成本胜出       | 吞吐胜出       | E2E 时延胜出   | TTFT 胜出    | 解读                       |
|------------|---------------------|------------|------------|------------|------------|------------|--------------------------|
| 吞吐优先       | 最大化单位时间输出能力         | Infron     | OpenRouter | OpenRouter | Infron     | Infron     | Infron 综合占优 (3/5 指标)     |
| 价格优先       | 最小化单位请求和单位 token 成本 | OpenRouter | OpenRouter | OpenRouter | OpenRouter | OpenRouter | OpenRouter 综合占优 (5/5 指标) |
| 端到端时延优先    | 最小化完整响应等待时间         | OpenRouter | Infron     | OpenRouter | Infron     | Infron     | Infron 综合占优 (3/5 指标)     |
| 流式 TTFT 优先 | 最小化流式首包响应时间         | OpenRouter | Infron     | OpenRouter | Infron     | Infron     | Infron 综合占优 (3/5 指标)     |

1. 引言：背景、研究问题与贡献

LLM 推理平台的真实性能不仅由模型决定，也由 provider 路由、提示词缓存、流式响应、成本归因和 fallback 策略共同决定。本报告把平台视为可观测系统，以 A/B 配对方式评估速度、成本、缓存和首包体验的多目标权衡。

1.1 研究假设

| 假设 | 内容                                                         | 验证指标                                |
|----|------------------------------------------------------------|-------------------------------------|
| H1 | 重复稳定长前缀请求中，更强的 provider/cache affinity 会提升 Token 级缓存命中率。   | 第二次请求 cache read tokens、Token 级命中率  |
| H2 | 更高缓存命中率会降低真实响应成本，但不必然降低 TTFT 或端到端 latency。                 | 实际成本、平均 TTFT、平均 latency/请求          |
| H3 | 不同 routing sort 会改变 provider 选择，从而形成不同的成本、吞吐和时延 Pareto 前沿。 | provider 分布、throughput、latency、cost |

1.2 本文贡献

- 使用响应返回的 `usage.prompt_tokens` 作为真实 input token 控制变量，并允许 50 tokens 内的小幅跨平台计数波动。

- 将 prompt caching 评估扩展到成本、吞吐、E2E latency、TTFT、provider 分布、reasoning telemetry 和配对统计检验。
- 所有结论只基于响应可观测 telemetry，不把平台内部私有 routing trace 当作已观测事实。

## 2. 方法：实验设计、数据集构造与控制变量

### 2.1 数据集生成方法

数据集名称为 `business_representative`，覆盖 4 种 routing sort、2 个平台、4 个实验组、每组 50 轮。每轮包含 first/second 两次相同 Chat Completions 请求：第一次建立或刷新缓存状态，第二次观测 cache read tokens、TTFT 和端到端响应。

业务模板覆盖稳定长上下文场景，包括 RAG 客服、Agent 工具说明、营销自动化和代码审查等高复用 prompt 结构。

### 2.2 控制变量方法



控制变量方法：同一 `sort/group/round` 下，两个平台 first/second 两次请求的 `usage.prompt_tokens` 各自偏差必须不超过 50 tokens。总 Input Tokens 使用响应返回的 `usage.prompt_tokens`，不使用本地 tokenizer 估算。

### 2.3 指标定义

| 指标           | 定义                                                                      | 解释方向                   |
|--------------|-------------------------------------------------------------------------|------------------------|
| 调用级命中率       | 第二次请求 <code>cache_read_tokens &gt; 0</code> 的轮次占比                       | 越高表示越稳定触发缓存读取          |
| Token 级命中率   | 第二次请求 <code>cache read tokens</code> / 第二次请求 <code>prompt tokens</code> | 越高表示输入 token 复用比例越高    |
| 实际成本         | first + second 两次请求返回 <code>usage/cost</code> 的合计                       | 越低越好                   |
| Throughput   | 响应 <code>completion tokens</code> / 请求 <code>latency seconds</code>     | 越高越好                   |
| E2E latency  | 每次请求完整响应耗时均值                                                            | 越低越好                   |
| TTFT         | streaming 下首包/首 token 到达时间均值                                            | 越低越好                   |
| Reasoning 口径 | 响应 <code>usage</code> 中的 <code>reasoning token</code> 字段保留为观测变量         | 用于解释时延、吞吐和成本，不单独作为业务产出 |

### 3. 实验环境与数据质量控制

| 项目                      | 配置                                          |
|-------------------------|---------------------------------------------|
| 模型                      | z-ai/glm-5                                  |
| 平台实际模型 ID               | infron: z-ai/glm-5 ; openrouter: z-ai/glm-5 |
| 平台                      | Infron、OpenRouter                           |
| API 协议                  | /v1/chat/completions                        |
| 路由模式                    | 吞吐优先、价格优先、端到端时延优先、流式 TTFT 优先                |
| 实验组                     | 4                                           |
| 每组轮数                    | 50                                          |
| Workers                 | 24                                          |
| 请求方式                    | 流式 Chat Completions，采集 TTFT                 |
| Reasoning / Thinking 控制 | 未显式指定 reasoning/thinking 参数；保留模型与平台默认行为     |
| Prompt 长度分层             | short ≈1500、medium ≈8000、long ≈32000        |
| 剔除记录                    | 24                                          |

### 4. 结果： 总体指标与主要发现

| 路由模式       | 平台         | 严格配对轮数 | 总 Input Tokens | Token 级缓存命中率 | 实际成本         | 吞吐量        | 端到端 E2E 时延 | 流式 TTFT    |
|------------|------------|--------|----------------|--------------|--------------|------------|------------|------------|
| 吞吐优先       | Infron     | 200    | 6414682        | 99.79%       | \$1.61315300 | 2.52 tok/s | 5311.71 ms | 4992.94 ms |
| 吞吐优先       | OpenRouter | 200    | 6414682        | 98.10%       | \$0.99183578 | 2.72 tok/s | 5884.51 ms | 5619.75 ms |
| 价格优先       | Infron     | 195    | 6040276        | 95.70%       | \$0.99697000 | 1.52 tok/s | 8506.60 ms | 7224.73 ms |
| 价格优先       | OpenRouter | 195    | 6040283        | 99.53%       | \$0.82584095 | 3.10 tok/s | 5163.02 ms | 4895.85 ms |
| 端到端时延优先    | Infron     | 193    | 6273860        | 99.61%       | \$0.77495600 | 2.61 tok/s | 4966.67 ms | 3645.69 ms |
| 端到端时延优先    | OpenRouter | 193    | 6273860        | 99.84%       | \$0.83192194 | 3.12 tok/s | 5122.85 ms | 4854.43 ms |
| 流式 TTFT 优先 | Infron     | 200    | 6414682        | 99.56%       | \$0.84264400 | 2.73 tok/s | 4758.14 ms | 3596.32 ms |
| 流式 TTFT 优先 | OpenRouter | 200    | 6414682        | 99.83%       | \$0.86408455 | 3.00 tok/s | 5331.20 ms | 5025.52 ms |

4.1 尾延迟与显著性检验

尾延迟分位数补充均值无法表达的尾部风险。

| 路由模式       | 平台         | P50 Latency | P95 Latency | P99 Latency | P50 TTFT   | P95 TTFT    | P99 TTFT    |
|------------|------------|-------------|-------------|-------------|------------|-------------|-------------|
| 吞吐优先       | Infron     | 5019.43 ms  | 8949.33 ms  | 11000.97 ms | 4695.00 ms | 8587.00 ms  | 10897.81 ms |
| 吞吐优先       | OpenRouter | 5511.87 ms  | 9758.45 ms  | 12789.27 ms | 5324.60 ms | 9432.64 ms  | 12480.67 ms |
| 价格优先       | Infron     | 4307.77 ms  | 31280.13 ms | 93253.06 ms | 3325.72 ms | 22342.13 ms | 92413.82 ms |
| 价格优先       | OpenRouter | 5101.24 ms  | 7374.62 ms  | 8385.21 ms  | 4839.13 ms | 7071.70 ms  | 7957.55 ms  |
| 端到端时延优先    | Infron     | 4716.31 ms  | 7963.46 ms  | 9700.74 ms  | 3452.01 ms | 6130.44 ms  | 8077.04 ms  |
| 端到端时延优先    | OpenRouter | 5123.94 ms  | 7437.43 ms  | 8328.80 ms  | 4865.67 ms | 7124.79 ms  | 8211.71 ms  |
| 流式 TTFT 优先 | Infron     | 4371.01 ms  | 7859.70 ms  | 9668.50 ms  | 3308.84 ms | 6277.24 ms  | 8130.10 ms  |
| 流式 TTFT 优先 | OpenRouter | 5290.40 ms  | 7983.31 ms  | 8954.58 ms  | 5070.78 ms | 7718.23 ms  | 8577.17 ms  |

均值差使用 bootstrap 95% CI, p-value 使用 paired sign-flip permutation test。

| 路由模式    | 指标                                   | 均值差            | 95% CI                          | p-value | 配对数 | 解释                        |
|---------|--------------------------------------|----------------|---------------------------------|---------|-----|---------------------------|
| 吞吐优先    | Latency: OpenRouter – Infron         | 1145.60 ms     | 725.46 ms to 1593.91 ms         | <0.001  | 200 | 正值表示 Infron latency 更低    |
| 吞吐优先    | TTFT: OpenRouter – Infron            | 1253.63 ms     | 821.31 ms to 1704.47 ms         | <0.001  | 200 | 正值表示 Infron TTFT 更低       |
| 吞吐优先    | Throughput: Infron – OpenRouter      | -0.1442 tok/s  | -0.3115 tok/s to 0.0211 tok/s   | 0.0855  | 200 | 正值表示 Infron throughput 更高 |
| 吞吐优先    | Cost: OpenRouter – Infron            | -\$-0.00310659 | -\$-0.00390526 to \$-0.00242740 | <0.001  | 200 | 正值表示 Infron 成本更低          |
| 吞吐优先    | Token Cache Hit: Infron – OpenRouter | 1.01 pp        | -0.97 pp to 3.01 pp             | 0.2524  | 200 | 正值表示 Infron cache hit 更高  |
| 价格优先    | Latency: OpenRouter – Infron         | -6687.16 ms    | -10536.36 ms to -3483.40 ms     | <0.001  | 195 | 正值表示 Infron latency 更低    |
| 价格优先    | TTFT: OpenRouter – Infron            | -4657.75 ms    | -8398.45 ms to -1592.26 ms      | 0.0065  | 195 | 正值表示 Infron TTFT 更低       |
| 价格优先    | Throughput: Infron – OpenRouter      | -0.6011 tok/s  | -0.8364 tok/s to -0.3715 tok/s  | <0.001  | 195 | 正值表示 Infron throughput 更高 |
| 价格优先    | Cost: OpenRouter – Infron            | -\$-0.00087758 | -\$-0.00153961 to \$-0.00029056 | 0.0052  | 195 | 正值表示 Infron 成本更低          |
| 价格优先    | Token Cache Hit: Infron – OpenRouter | -4.48 pp       | -7.99 pp to -1.34 pp            | 0.0105  | 195 | 正值表示 Infron cache hit 更高  |
| 端到端时延优先 | Latency: OpenRouter – Infron         | 312.37 ms      | -91.12 ms to 681.67 ms          | 0.1197  | 193 | 正值表示 Infron latency 更低    |
| 端到端时延优先 | TTFT: OpenRouter – Infron            | 2417.48 ms     | 2093.52 ms to 2728.71 ms        | <0.001  | 193 | 正值表示 Infron TTFT 更低       |

| 路由模式       | 指标                                   | 均值差           | 95% CI                         | p-value | 配对数 | 解释                        |
|------------|--------------------------------------|---------------|--------------------------------|---------|-----|---------------------------|
| 端到端时延优先    | Throughput: Infron – OpenRouter      | -0.6766 tok/s | -0.8531 tok/s to -0.5050 tok/s | <0.001  | 193 | 正值表示 Infron throughput 更高 |
| 端到端时延优先    | Cost: OpenRouter – Infron            | \$0.00029516  | \$0.00021278 to \$0.00036663   | <0.001  | 193 | 正值表示 Infron 成本更低          |
| 端到端时延优先    | Token Cache Hit: Infron – OpenRouter | -0.21 pp      | -1.29 pp to 0.38 pp            | 1.0000  | 193 | 正值表示 Infron cache hit 更高  |
| 流式 TTFT 优先 | Latency: OpenRouter – Infron         | 1146.12 ms    | 764.77 ms to 1497.12 ms        | <0.001  | 200 | 正值表示 Infron latency 更低    |
| 流式 TTFT 优先 | TTFT: OpenRouter – Infron            | 2858.40 ms    | 2535.21 ms to 3162.86 ms       | <0.001  | 200 | 正值表示 Infron TTFT 更低       |
| 流式 TTFT 优先 | Throughput: Infron – OpenRouter      | -0.4132 tok/s | -0.5904 tok/s to -0.2386 tok/s | <0.001  | 200 | 正值表示 Infron throughput 更高 |
| 流式 TTFT 优先 | Cost: OpenRouter – Infron            | \$0.00010720  | \$-0.00023742 to \$0.00037466  | 0.5111  | 200 | 正值表示 Infron 成本更低          |
| 流式 TTFT 优先 | Token Cache Hit: Infron – OpenRouter | -0.62 pp      | -2.14 pp to 0.42 pp            | 0.5049  | 200 | 正值表示 Infron cache hit 更高  |

4.2 Reasoning / Thinking 控制校验

本轮未显式指定 reasoning/thinking 参数，保留模型与平台默认行为；该表记录默认行为下的 reasoning telemetry。

| 路由模式       | 平台         | Reasoning Tokens | 平均 Reasoning Tokens/请求 | Reasoning 请求数 | 平均首 Reasoning Token | 平均 TTFT    | 平均 E2E 时延  |
|------------|------------|------------------|------------------------|---------------|---------------------|------------|------------|
| 吞吐优先       | Infron     | 0                | 0.0000                 | 0             | 0.00 ms             | 4992.94 ms | 5311.71 ms |
| 吞吐优先       | OpenRouter | 6000             | 15.0000                | 400           | 5619.75 ms          | 5619.75 ms | 5884.51 ms |
| 价格优先       | Infron     | 0                | 0.0000                 | 0             | 0.00 ms             | 7224.73 ms | 8506.60 ms |
| 价格优先       | OpenRouter | 5835             | 14.9615                | 389           | 4895.85 ms          | 4895.85 ms | 5163.02 ms |
| 端到端时延优先    | Infron     | 0                | 0.0000                 | 0             | 0.00 ms             | 3645.69 ms | 4966.67 ms |
| 端到端时延优先    | OpenRouter | 5955             | 15.4275                | 386           | 4854.43 ms          | 4854.43 ms | 5122.85 ms |
| 流式 TTFT 优先 | Infron     | 0                | 0.0000                 | 0             | 0.00 ms             | 3596.32 ms | 4758.14 ms |



| 路由模式       | 平台         | Reasoning Tokens | 平均 Reasoning Tokens/请求 | Reasoning 请求数 | 平均首 Reasoning Token | 平均 TTFT    | 平均 E2E 时延  |
|------------|------------|------------------|------------------------|---------------|---------------------|------------|------------|
| 流式 TTFT 优先 | OpenRouter | 6153             | 15.3825                | 400           | 5025.52 ms          | 5025.52 ms | 5331.20 ms |

4.3 API 协议兼容性矩阵

本轮 API 协议为 /v1/chat/completions；本表记录两家平台在该协议下的成功响应、usage、成本和缓存 telemetry 覆盖。

| API 协议           | Endpoint             | 平台         | 配对轮数 | 请求数  | 成功率    | Usage 覆盖 | Token Usage 覆盖 | 成本覆盖    | 缓存 Telemetry 覆盖 | HTTP 状态              |
|------------------|----------------------|------------|------|------|--------|----------|----------------|---------|-----------------|----------------------|
| chat_completions | /v1/chat/completions | Infron     | 800  | 1600 | 99.62% | 100.00%  | 100.00%        | 100.00% | 100.00%         | {"0": 6,"200": 1594} |
| chat_completions | /v1/chat/completions | OpenRouter | 800  | 1600 | 99.44% | 100.00%  | 100.00%        | 100.00% | 100.00%         | {"0": 9,"200": 1591} |

5. 结果可视化：按路由模式的核心指标变化

以下图表使用同一份严格配对后的 summary 数据驱动，统一展示路由模式、平台差异、成本、缓存、端到端 E2E 时延、流式 TTFT 和上游 Provider 分布。

## 5.1 核心指标图表总览

以下图表使用同一份严格配对后的 summary 数据生成，统一展示路由模式、平台差异、成本、缓存、端到端 E2E 时延、流式 TTFT 和上游 Provider 分布。

图 3-E2：归一化  
综合轮廓

五项指标统一转为  
0-100 且越高越好。

图 3-E3：成本-缓存  
效率平面

横轴为 Token 级缓存命中  
率，纵轴为总实际成本。

图 3-E1：路由模式级核心指标对比  
按路由模式并列展示 Infron 与 OpenRouter。





图 3-E4：端到端 E2E 时延与流式 TTFT

实线表示端到端 E2E 时延，虚线表示流式 TTFT。

图 3-E5：上游 Provider 分布

按路由模式展示主要上游路径占比。

模式级下钻图表

横轴表示相对优势百分比：右侧蓝色代表 Infron 优势，左侧橙色代表 OpenRouter 优势。

**图 4-E1: Throughput First 路由模式下的核心指标对比**

展示五项核心指标的相对优势方向与幅度。

**图 4-E2: Price First 路由模式下的核心指标对比**

展示五项核心指标的相对优势方向与幅度。

**图 4-E3: Latency First 路由模式下的核心指标对比**

展示五项核心指标的相对优势方向与幅度。

**图 4-E4: TTFT First 路由模式下的核心指标对比**

展示五项核心指标的相对优势方向与幅度。

## 6. Infron 技术架构与缓存/成本机制解释



### 6.1 多 provider 路由与可观测控制面

请求进入统一 API 后，路由策略层根据 throughput、price、latency 或 tftt 目标选择健康上游路径。稳定长前缀请求是否落在相同缓存域，会直接影响第二次请求的 cache read tokens。

### 6.2 Provider Stick 与 Cache Affinity

Provider stick 是缓存亲和策略，不等于固定锁死 provider。它的目标是在健康和 SLA 约束下减少缓存域碎片化，使重复 prefix 更容易复用已有缓存。

### 6.3 成本控制路径

| 机制                              | 对 cache rate 的影响                | 对成本的影响             | 本次实验中的可观测信号                               |
|---------------------------------|---------------------------------|--------------------|-------------------------------------------|
| Stable prefix 识别                | 相同前缀更容易命中已有 cache               | 降低重复 prefill 的边际成本 | 同一 payload SHA256、第二次请求 cache read tokens |
| Provider stick / cache affinity | 降低跨 provider/cache domain 的缓存碎片 | 减少重复暖缓存            | provider 分布与 Token 级命中率共同变化               |
| 健康检查与 fallback                  | 保护可用性，必要时牺牲部分缓存收益               | 降低失败成本             | HTTP 状态、provider 分布和尾延迟变化                 |
| 成本感知 routing                    | 在健康约束下偏向低成本路径                   | 降低总成本和每轮成本         | 实际成本、cost breakdown 覆盖率、cache read tokens |

## 7. Provider/Route 下钻分析

| 路由模式    | 平台         | 总请求数 | 已归因请求数 | Provider 分布                  |
|---------|------------|------|--------|------------------------------|
| 吞吐优先    | Infron     | 400  | 400    | novita 400                   |
| 吞吐优先    | OpenRouter | 400  | 400    | StreamLake 400               |
| 价格优先    | Infron     | 390  | 390    | deepinfra 340, alibaba/cn 50 |
| 价格优先    | OpenRouter | 390  | 390    | StreamLake 389, GMICloud 1   |
| 端到端时延优先 | Infron     | 386  | 386    | deepinfra 386                |



| 路由模式       | 平台         | 总请求数 | 已归因请求数 | Provider 分布                           |
|------------|------------|------|--------|---------------------------------------|
| 端到端时延优先    | OpenRouter | 386  | 386    | StreamLake 356, DeepInfra 30          |
| 流式 TTFT 优先 | Infron     | 400  | 400    | deepinfra 400                         |
| 流式 TTFT 优先 | OpenRouter | 400  | 400    | StreamLake 362, DeepInfra 31, Baidu 7 |

上游 Provider 明细分布

| 路由模式       | 平台         | 上游 Provider | 请求数 | 占比      | first/second | 覆盖轮次 | Avg TTFT    | Avg Latency | Prompt Tokens | Completion Tokens | Reasoning Tokens |
|------------|------------|-------------|-----|---------|--------------|------|-------------|-------------|---------------|-------------------|------------------|
| 吞吐优先       | Infron     | novita      | 400 | 100.00% | 200/200      | 200  | 4992.94 ms  | 5311.71 ms  | 6414682       | 5357              | 0                |
| 吞吐优先       | OpenRouter | StreamLake  | 400 | 100.00% | 200/200      | 200  | 5619.75 ms  | 5884.51 ms  | 6414682       | 6400              | 6000             |
| 价格优先       | Infron     | deepinfra   | 340 | 87.18%  | 165/175      | 175  | 3392.45 ms  | 4571.01 ms  | 5509975       | 4395              | 0                |
| 价格优先       | Infron     | alibaba/cn  | 50  | 12.82%  | 30/20        | 30   | 33284.25 ms | 35268.63 ms | 530301        | 642               | 0                |
| 价格优先       | OpenRouter | StreamLake  | 389 | 99.74%  | 194/195      | 195  | 4890.95 ms  | 5158.59 ms  | 6002831       | 6224              | 5835             |
| 价格优先       | OpenRouter | GMICloud    | 1   | 0.26%   | 1/0          | 1    | 6803.91 ms  | 6883.60 ms  | 37452         | 16                | 0                |
| 端到端时延优先    | Infron     | deepinfra   | 386 | 100.00% | 193/193      | 193  | 3645.69 ms  | 4966.67 ms  | 6273860       | 5003              | 0                |
| 端到端时延优先    | OpenRouter | StreamLake  | 356 | 92.23%  | 179/177      | 179  | 5045.97 ms  | 5284.98 ms  | 6114026       | 5696              | 5340             |
| 端到端时延优先    | OpenRouter | DeepInfra   | 30  | 7.77%   | 14/16        | 16   | 2581.47 ms  | 3198.99 ms  | 159834        | 480               | 615              |
| 流式 TTFT 优先 | Infron     | deepinfra   | 400 | 100.00% | 200/200      | 200  | 3596.32 ms  | 4758.14 ms  | 6414682       | 5201              | 0                |
| 流式 TTFT 优先 | OpenRouter | StreamLake  | 362 | 90.50%  | 181/181      | 182  | 5283.54 ms  | 5564.29 ms  | 6332869       | 5792              | 5430             |
| 流式 TTFT 优先 | OpenRouter | DeepInfra   | 31  | 7.75%   | 15/16        | 17   | 2314.80 ms  | 2897.23 ms  | 62022         | 496               | 611              |

| 路由模式       | 平台         | 上游 Provider | 请求数 | 占比    | first/second | 覆盖轮次 | Avg TTFT   | Avg Latency | Prompt Tokens | Completion Tokens | Reasoning Tokens |
|------------|------------|-------------|-----|-------|--------------|------|------------|-------------|---------------|-------------------|------------------|
| 流式 TTFT 优先 | OpenRouter | Baidu       | 7   | 1.75% | 4/3          | 5    | 3686.97 ms | 4056.14 ms  | 19791         | 112               | 112              |

7.1 缓存命中率与实际成本反向表现下钻

该表把 cache、cost、provider 分布和 reasoning telemetry 放在同一层级，解释每个路由模式的主要差异来源。

| 路由模式       | 缓存命中差值   | Infron 成本倍数 | Infron 主要路径       | OpenRouter 主要路径    | Reasoning Tokens 差异 | 主要归因                                                 |
|------------|----------|-------------|-------------------|--------------------|---------------------|------------------------------------------------------|
| 吞吐优先       | +1.69 pp | 1.63x       | novita 100.00%    | StreamLake 100.00% | -6000               | Infron 缓存更高但成本更高，需检查上游单价、completion/reasoning tokens |
| 价格优先       | -3.83 pp | 1.21x       | deepinfra 87.18%  | StreamLake 99.74%  | -5835               | OpenRouter 缓存更高且成本更低，主要看 provider/cache 域差异          |
| 端到端时延优先    | -0.23 pp | 0.93x       | deepinfra 100.00% | StreamLake 92.23%  | -5955               | 缓存和成本方向存在分化，需结合速度指标判断                                |
| 流式 TTFT 优先 | -0.27 pp | 0.98x       | deepinfra 100.00% | StreamLake 90.50%  | -6153               | 缓存和成本方向存在分化，需结合速度指标判断                                |

8. 分层结果：按 Prompt 长度的缓存表现

本节按 prompt 长度 tier 聚合第二次请求的 cache read tokens、Token 级缓存命中率、实际成本、端到端时延和流式 TTFT。加粗单元表示同一长度 tier 下表现更优的一方。

Prompt 长度分层总览

| Prompt 长度 tier | 目标 tokens | 平台         | 轮数  | 第二次 Prompt Tokens | 第二次 Cache Read Tokens | Token 级命中率 | 实际成本         | 平均 E2E 时延  | 平均 TTFT    |
|----------------|-----------|------------|-----|-------------------|-----------------------|------------|--------------|------------|------------|
| short          | 1500      | Infron     | 265 | 466794            | 451616                | 96.75%     | \$0.17568300 | 4717.31 ms | 3737.61 ms |
| short          | 1500      | OpenRouter | 265 | 466794            | 457728                | 98.06%     | \$0.15285428 | 4144.39 ms | 3863.12 ms |
| medium         | 8000      | Infron     | 265 | 2445560           | 2377760               | 97.23%     | \$0.80691000 | 5713.62 ms | 4668.79 ms |
| medium         | 8000      | OpenRouter | 265 | 2445560           | 2414592               | 98.73%     | \$0.71005725 | 5368.63 ms | 5127.16 ms |

| Prompt 长度 tier | 目标 tokens | 平台         | 轮数  | 第二次 Prompt Tokens | 第二次 Cache Read Tokens | Token 级命中率 | 实际成本         | 平均 E2E 时延  | 平均 TTFT    |
|----------------|-----------|------------|-----|-------------------|-----------------------|------------|--------------|------------|------------|
| long           | 32000     | Infron     | 258 | 9659396           | 9579360               | 99.17%     | \$3.24513000 | 7236.92 ms | 6211.62 ms |
| long           | 32000     | OpenRouter | 258 | 9659396           | 9613888               | 99.53%     | \$2.65077169 | 6657.73 ms | 6349.72 ms |

Prompt 长度 x 路由模式缓存命中率

| Prompt 长度 tier | 路由模式       | Infron | OpenRouter | 胜出方        |
|----------------|------------|--------|------------|------------|
| short          | 吞吐优先       | 96.63% | 98.10%     | OpenRouter |
| short          | 价格优先       | 93.95% | 98.10%     | OpenRouter |
| short          | 端到端时延优先    | 98.98% | 98.10%     | Infron     |
| short          | 流式 TTFT 优先 | 97.53% | 97.94%     | OpenRouter |
| medium         | 吞吐优先       | 99.86% | 96.88%     | Infron     |
| medium         | 价格优先       | 92.42% | 98.37%     | OpenRouter |
| medium         | 端到端时延优先    | 98.30% | 99.87%     | OpenRouter |
| medium         | 流式 TTFT 优先 | 98.37% | 99.86%     | OpenRouter |
| long           | 吞吐优先       | 99.92% | 98.40%     | Infron     |
| long           | 价格优先       | 96.68% | 99.91%     | OpenRouter |
| long           | 端到端时延优先    | 99.96% | 99.92%     | Infron     |
| long           | 流式 TTFT 优先 | 99.96% | 99.92%     | Infron     |

9. 分层结果：按实验组的稳定性检查

吞吐优先

| 平台         | 组别 | 轮数 | 成功轮数 | Token 命中率 | 实际成本         | P95 Latency | P95 TTFT    |
|------------|----|----|------|-----------|--------------|-------------|-------------|
| Infron     | 1  | 50 | 50   | 99.62%    | \$0.62126500 | 8914.84 ms  | 8587.00 ms  |
| Infron     | 2  | 50 | 50   | 99.85%    | \$0.33495900 | 7957.49 ms  | 7805.95 ms  |
| Infron     | 3  | 50 | 50   | 99.84%    | \$0.33214400 | 9439.19 ms  | 9017.67 ms  |
| Infron     | 4  | 50 | 50   | 99.84%    | \$0.32478500 | 8212.44 ms  | 8029.86 ms  |
| OpenRouter | 1  | 50 | 50   | 99.84%    | \$0.30959630 | 12487.28 ms | 12033.90 ms |
| OpenRouter | 2  | 50 | 50   | 98.73%    | \$0.22781642 | 7022.19 ms  | 6776.78 ms  |
| OpenRouter | 3  | 50 | 50   | 94.10%    | \$0.24543220 | 9107.64 ms  | 8817.53 ms  |

| 平台         | 组别 | 轮数 | 成功轮数 | Token 命中率 | 实际成本         | P95 Latency | P95 TTFT   |
|------------|----|----|------|-----------|--------------|-------------|------------|
| OpenRouter | 4  | 50 | 50   | 99.84%    | \$0.20899086 | 7794.67 ms  | 7290.17 ms |

价格优先

| 平台         | 组别 | 轮数 | 成功轮数 | Token 命中率 | 实际成本         | P95 Latency | P95 TTFT    |
|------------|----|----|------|-----------|--------------|-------------|-------------|
| Infron     | 1  | 45 | 45   | 87.04%    | \$0.32151800 | 87203.15 ms | 82998.06 ms |
| Infron     | 2  | 50 | 50   | 98.79%    | \$0.26056300 | 10749.09 ms | 7560.04 ms  |
| Infron     | 3  | 50 | 50   | 95.09%    | \$0.22211700 | 7220.94 ms  | 5011.36 ms  |
| Infron     | 4  | 50 | 50   | 99.68%    | \$0.19277200 | 5882.42 ms  | 4402.77 ms  |
| OpenRouter | 1  | 45 | 45   | 99.81%    | \$0.17744723 | 7879.73 ms  | 7585.10 ms  |
| OpenRouter | 2  | 50 | 50   | 98.73%    | \$0.22302410 | 7733.01 ms  | 7034.32 ms  |
| OpenRouter | 3  | 50 | 50   | 99.84%    | \$0.21637876 | 6704.80 ms  | 6390.40 ms  |
| OpenRouter | 4  | 50 | 50   | 99.84%    | \$0.20899086 | 7257.05 ms  | 7153.45 ms  |

端到端时延优先

| 平台         | 组别 | 轮数 | 成功轮数 | Token 命中率 | 实际成本         | P95 Latency | P95 TTFT   |
|------------|----|----|------|-----------|--------------|-------------|------------|
| Infron     | 1  | 50 | 50   | 98.73%    | \$0.19645000 | 8331.75 ms  | 6502.38 ms |
| Infron     | 2  | 45 | 45   | 99.91%    | \$0.18854500 | 7858.70 ms  | 5589.52 ms |
| Infron     | 3  | 49 | 49   | 99.91%    | \$0.19837800 | 7133.50 ms  | 5437.50 ms |
| Infron     | 4  | 49 | 49   | 99.90%    | \$0.19158300 | 8337.99 ms  | 6631.28 ms |
| OpenRouter | 1  | 50 | 50   | 99.84%    | \$0.20897198 | 6611.28 ms  | 6450.22 ms |
| OpenRouter | 2  | 45 | 45   | 99.86%    | \$0.19904936 | 7447.01 ms  | 7141.62 ms |
| OpenRouter | 3  | 49 | 49   | 99.84%    | \$0.21566118 | 7305.77 ms  | 7092.93 ms |
| OpenRouter | 4  | 49 | 49   | 99.84%    | \$0.20823942 | 7455.78 ms  | 7164.70 ms |

流式 TTFT 优先

| 平台         | 组别 | 轮数 | 成功轮数 | Token 命中率 | 实际成本         | P95 Latency | P95 TTFT   |
|------------|----|----|------|-----------|--------------|-------------|------------|
| Infron     | 1  | 50 | 50   | 99.68%    | \$0.19290200 | 6925.38 ms  | 4657.72 ms |
| Infron     | 2  | 50 | 50   | 98.79%    | \$0.22294100 | 7377.62 ms  | 5495.93 ms |
| Infron     | 3  | 50 | 50   | 99.91%    | \$0.23476100 | 8549.03 ms  | 7605.03 ms |
| Infron     | 4  | 50 | 50   | 99.90%    | \$0.19204000 | 7022.95 ms  | 5339.84 ms |
| OpenRouter | 1  | 50 | 50   | 99.84%    | \$0.20960816 | 8273.97 ms  | 8007.52 ms |
| OpenRouter | 2  | 50 | 50   | 99.85%    | \$0.22287306 | 7871.29 ms  | 7588.82 ms |
| OpenRouter | 3  | 50 | 50   | 99.84%    | \$0.21622772 | 8257.15 ms  | 7862.65 ms |

| 平台         | 组别 | 轮数 | 成功轮数 | Token 命中率 | 实际成本         | P95 Latency | P95 TTFT   |
|------------|----|----|------|-----------|--------------|-------------|------------|
| OpenRouter | 4  | 50 | 50   | 99.81%    | \$0.21537561 | 7708.44 ms  | 7375.08 ms |

## 10. 讨论：业务价值、适用边界与工程启示

业务决策不应只看单一指标。稳定长上下文和高频模板请求优先关注缓存命中率与成本；实时交互应同时约束 TTFT 和端到端时延；后台批处理更重视吞吐与失败成本。

| 路由模式       | 主要业务目标              | 本轮数据体现                  | 适用场景                           | 注意事项                 |
|------------|---------------------|-------------------------|--------------------------------|----------------------|
| 吞吐优先       | 最大化单位时间输出能力         | Infron 综合占优（3/5 指标）     | 批量内容生成、离线摘要、后台数据加工             | 适合吞吐优先任务，但成本和缓存需单独约束 |
| 价格优先       | 最小化单位请求和单位 token 成本 | OpenRouter 综合占优（5/5 指标） | 高频模板化请求、客服自动化、营销触达、RAG 固定前缀    | 首包与完整响应更快，但需检查缓存和成本  |
| 端到端时延优先    | 最小化完整响应等待时间         | Infron 综合占优（3/5 指标）     | 在线聊天、Agent 调用链、IDE/写作辅助、实时运营工具 | 适合吞吐优先任务，但成本和缓存需单独约束 |
| 流式 TTFT 优先 | 最小化流式首包响应时间         | Infron 综合占优（3/5 指标）     | 流式聊天、实时 Copilot、首屏反馈、长任务进度感知   | 适合吞吐优先任务，但成本和缓存需单独约束 |

## 11. 结论

### 路由模式级结论

| 路由模式       | 目标                  | 缓存胜出       | 成本胜出       | 吞吐胜出       | E2E 时延胜出   | TTFT 胜出    | 解读                      |
|------------|---------------------|------------|------------|------------|------------|------------|-------------------------|
| 吞吐优先       | 最大化单位时间输出能力         | Infron     | OpenRouter | OpenRouter | Infron     | Infron     | Infron 综合占优（3/5 指标）     |
| 价格优先       | 最小化单位请求和单位 token 成本 | OpenRouter | OpenRouter | OpenRouter | OpenRouter | OpenRouter | OpenRouter 综合占优（5/5 指标） |
| 端到端时延优先    | 最小化完整响应等待时间         | OpenRouter | Infron     | OpenRouter | Infron     | Infron     | Infron 综合占优（3/5 指标）     |
| 流式 TTFT 优先 | 最小化流式首包响应时间         | OpenRouter | Infron     | OpenRouter | Infron     | Infron     | Infron 综合占优（3/5 指标）     |

## 12. 局限性、缺失数据与后续实验计划

| 缺失或不足            | 对结论的影响                                 | 后续补充方式                                                   | 当前处理方式                               |
|------------------|----------------------------------------|----------------------------------------------------------|--------------------------------------|
| 完整 routing trace | 无法逐跳证明每次请求的 provider 选择、fallback 和重试路径 | 补充 provider routing trace、decision log 和 fallback reason | 只使用响应中真实返回的 provider 字段和 provider 分布 |
| 更长时间窗口           | 4x50 能观察短期稳定性，但不能覆盖日级波动                | 增加 soak test 和跨时段重复实验                                    | 报告限定在本轮窗口内解释                         |

| 缺失或不足   | 对结论的影响                 | 后续补充方式                          | 当前处理方式           |
|---------|------------------------|---------------------------------|------------------|
| 真实生产语料  | 内置模板不能覆盖全部业务分布         | 使用脱敏生产语料分层抽样                    | 当前只讨论代表性长上下文业务模板 |
| 成本字段一致性 | 不同平台 cost 字段覆盖率和口径可能不同 | 结合账单回查和 provider cost breakdown | 只统计响应明确返回的成本字段   |

13. 可复现性附录

| 工件             | 路径                                                                                                                                                      |
|----------------|---------------------------------------------------------------------------------------------------------------------------------------------------------|
| Summary        | export/glm5_all_experiments/<br>routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions<br>summary.json             |
| 配对数据集          | export/glm5_all_experiments/<br>routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions<br>benchmark_pairs.csv      |
| 请求级数据集         | export/glm5_all_experiments/<br>routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions<br>benchmark_requests.jsonl |
| 过滤后结构化记录       | export/glm5_all_experiments/<br>routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions<br>records.json             |
| 剔除记录审计         | export/glm5_all_experiments/<br>routing_sort_cache_cost_ab_4x50_stream_ttft_reasoning_default_length_tiers_chat_completions<br>records_excluded.json    |
| 测试源码           | tests/test_rerun_routing_sort_cache_cost_ab.py                                                                                                          |
| Benchmark 执行源码 | scripts/rerun_routing_sort_cache_cost_ab.py                                                                                                             |
| HTML 报告渲染源码    | scripts/render_glm52_deepseek_style_report.py                                                                                                           |
| 数据集引用          | business_representative 内置代表性业务模板；请求级导出见 benchmark_requests.jsonl                                                                                       |